AI 在金融交易中的应用：一份可落地的研究综述

从信息到可交易缝隙——方法族、评测口径与复现状态

叨客宁宁

摘要

这篇文章收拢了从 1950 年代资产定价计量到 2026 年大模型交易智能体之间，关于“人工智能如何被用进金融交易”的论文、预印本、官方仓库与基准报告。我不打算把它写成一份方法清单，而是先立一个能把整条链路串起来的命题：交易的本质是“信息 → 定价偏差 → 可交易缝隙”的识别与收割，AI 的每一种应用，无非是在这条链条的某一环替换或增强了人的表示学习、预测或决策能力；因此它的能力上限，由“信息存量的天花板”和“执行摩擦的地板”共同夹住。这个命题解释了一件长期被回避的事——为什么论文里动辄年化几十个百分点的策略，一旦落到真实账户上就大面积缩水。

正文用一张“方法族 × 交易环节”的双轴框架来组织。纵轴是六个方法族：监督学习与 alpha 挖掘、深度学习与序列建模、强化学习、自然语言处理与大模型、生成式模型、图神经网络；横轴是五个交易环节：信号生成、组合构建、交易执行、风险管理、另类数据与微观结构。每一族都按“问题设定 → 原理 → 落地要素 → 复现状态 → 失效边界”走一遍，而不是停在“某方法在某数据集上取得了更好指标”。

落地是我写得最用力的部分。第 12 章的**证据表**收录了超过 80 条核心来源，全部链回 DOI / arXiv / 官方仓库；第 13 章的**统一比较矩阵**把“数据、样本区间、任务、方法、样本外检验、交易成本口径、评测协议、开源许可”逐项对齐，好让跨论文的数字有可比的基础；第 14 章专门审计评测污染——幸存者偏差、前瞻偏差、数据窥探、多重检验、回测过拟合；第 15 章的**复现状态核验表**把 Qlib、FinRL 等公开基准和一批代表性工作逐一标注为“可复现 / 部分复现 / 不可复现”并给出原因；第 16 章给出一套按 P0–P3 分级的可复现实验方案，配套的参考实现骨架放在随附的 `code/` 目录里。结论附置信度分级，边界条件如实写明。

目录

1 引言与综述口径 **5**

1.1 为什么用“信息 → 定价偏差 → 可交易缝隙”这条链 6

1.2 综述边界 7

1.3 检索策略与证据链 7

1.4 与已有综述的关系 8

1.5 这篇综述的读法 9

2 交易的信息论基础与 AI 的作用位置 **9**

2.1 有效市场之争留下的，不是一个“是不是有效”的答案 9
2.2 信息如何进入价格：微观结构的视角 10
2.3 低信噪比：金融预测与其它机器学习任务的根本差别 10
2.4 从预测到收益：摩擦如何把缝隙削窄 10
2.5 缝隙存在的一个必要条件 11
2.6 AI 在这条链条上的三个作用位置 12
2.7 一个同构性的看法 13

3 综述框架：方法族与交易环节的双轴 13
3.1 两条轴 13
3.2 双轴映射矩阵 14
3.3 每一族的统一审查口径 14
3.4 一条贯穿的判据 14

4 监督学习与 alpha 挖掘 15
4.1 问题设定 15
4.2 从线性到非线性：一条可复现的演进线 15
4.3 落地要素 16
4.4 复现状态与失效边界 16

5 深度学习与序列建模 17
5.1 问题设定：预测精度不等于交易绩效 17
5.2 架构谱系 17
5.3 一个常被忽略的落地点：订单簿与微观结构 18
5.4 落地要素 18
5.5 复现状态与失效边界 18

6 强化学习：执行、组合与做市 18
6.1 问题设定 19
6.2 三个主要落地方向 19
6.3 落地要素 19
6.4 复现状态与失效边界 20

7 自然语言处理与大模型：从情绪到交易智能体 20
7.1 第一代：情绪与词典 20

7.2 第二代：预训练编码器 20
7.3 第三代：大模型与交易智能体 20
7.4 落地要素 21
7.5 复现状态与失效边界 21

8 生成式模型：合成数据、场景生成与市场仿真 22
8.1 问题设定与三种用途 22
8.2 方法与判据：什么叫“像” 22
8.3 生成质量的评估清单 23
8.4 生成器当训练环境时的耦合风险 23
8.5 落地要素 24
8.6 复现状态与失效边界 24

9 图神经网络：关系结构与跨资产信息 24
9.1 问题设定 24
9.2 一条从“关系”到“可交易”的证据线 25
9.3 边怎么定义：五种做法的取舍 25
9.4 一个可执行的关系消融协议 25
9.5 落地要素 26
9.6 复现状态与失效边界 26

10 另类数据与微观结构：信号的上游 26
10.1 另类数据的谱系 27
10.2 微观结构：最接近“物理真实”的数据 27
10.3 落地要素：另类数据的四个隐性成本 27
10.4 制度约束的特殊性：以 A 股为例 27
10.5 复现状态与失效边界 28

11 交易环节的横向整合：从预测到仓位、执行与风控 28
11.1 组合构建：把预测翻译成权重 28
11.2 一个成本分解的示意计算 29
11.3 交易执行：摩擦的管理学 30
11.4 风险管理：AI 的另一条战线 30
11.5 环节耦合：本文最想强调的一点 30

12 证据表（核心来源清单） 31

13 统一比较矩阵 39

14 评测数据污染与不可比设定审计 41

14.1 幸存者偏差与上市偏差 . . . 42
14.2 前瞻偏差（look-ahead） . . . 42
14.3 数据窥探与多重检验 . . . 42
14.4 回测过拟合与选择性报告 . . . 42
14.5 AI 时代的新污染：模型知道答案 . . . 43
14.6 跨论文不可比设定 . . . 43
14.7 一个最低可接受的评测协议 . . . 43
14.8 审计结论 . . . 44

15 复现状态核验表 44

15.1 公开工具与基准的仓库核验 . . . 45
15.2 代表性论文的复现状态 . . . 46
15.3 为什么复现状态如此分化 . . . 46
15.4 一个可操作的结论 . . . 46

16 可复现实验方案：从 P0 到 P3 47

16.1 P0：把数据、成本、评价三层统一钉死 . . . 47
16.2 P1：统一评测协议 . . . 47
16.3 P2：多重检验纪律 . . . 48
16.4 P3：前沿方法的公平对照 . . . 48
16.5 协议条款与参考实现的对照 . . . 48
16.6 参考实现骨架 . . . 48

17 开源生态与工具链 50

17.1 量化研究平台 . . . 50
17.2 回测与评测工具 . . . 50
17.3 市场仿真环境 . . . 51
17.4 数据与公开基准 . . . 51
17.5 生态的缺口 . . . 51

18 结论置信度分级 **51**

19 局限性摘要与反方证据 **53**

19.1 本综述自身的局限 53

19.2 反方证据 53

19.3 本文的立场，修正后 53

20 研究现状、遗留课题与未来路线图 **54**

20.1 当前研究现状 54

20.2 遗留课题 54

20.3 研究路线图（Phase 0–4） 55

21 复核清单：已执行结果与剩余待办 **56**

21.1 检索与来源池 56

21.2 参考实现实跑记录（P0–P2） 56

21.3 真实数据最小实证（P0–P2） 57

21.4 可实施性核查：成本、换手与市场暴露 60

21.5 核验状态约定 62

21.6 剩余待办与已知缺口 62

22 术语表 **63**

1 引言与综述口径

金融交易这门行当，过去几十年一直在做同一件事：把某种别人还没用上的信息，变成一张能赚钱的仓位。早年间这信息可能是纽约港的货船到港记录，可能是交易所大厅里一个熟人的手势，也可能只是比别人早半小时看到报价纸带。到了机器学习的年代，这件事第一次变得可以被规模化地自动化——模型替人去看海量的价量数据、新闻、财报电话会记录、订单簿挂单流，再从里头找出统计规律并落成买卖指令。

问题也正出在这里。学术论文和行业报告里，“用深度学习/强化学习/大语言模型做交易”的标题几乎是取之不尽的，报告的样本内收益动辄年化几十个百分点，可真正落到账户上的东西，往往少得可怜。这个落差不是靠“模型还不够大”就能补上的，它是真正值得写一篇综述去弄清楚的事。

这篇文章想回答两个问题。第一，人工智能在这条“信息 $\rightarrow$ 定价偏差 $\rightarrow$ 可交易缝隙”的链条上，到底站在哪个位置，能做什么，不能做什么。第二，现有研究的成果里，哪些经得起重读，哪些经得起复现，哪些只是样本内的偶然。

1.1 为什么用“信息 → 定价偏差 → 可交易缝隙”这条链

把交易拆成三段，能让很多混乱的讨论立刻清楚起来。

第一段是**信息**。市场里存在一些别人还没反映进价格的信息，这是交易能赚钱的前提。信息的存量不是无限的：信息含量越高的信息越早被人抢走，剩下的边际信息越来越稀薄。

第二段是**定价偏差**。信息要能变成钱，前提是价格还没有把这信息充分反映进去，或者反映得过火了。偏差的存在，一半来自人（行为、情绪、注意力约束），一半来自制度（流动性、摩擦、套利限制）。

第三段是**可交易缝隙**。就算前两段都成立，这个偏差还得足够大、足够持久、能扛住交易成本和冲击成本，才是一道能真正落袋的缝。缝隙的宽度是被执行摩擦从两头削出来的。

关于“可交易缝隙”这个说法

有必要先把用词交代清楚。“信息”与“定价偏差”都是文献里的成熟概念（后者即 mispricing），“可交易缝隙”**不是**。它是本文为了方便组织全篇而临时采用的一个**工作术语**，指代的却是文献里早已有、只是分散在若干名目下面对应的同一件事。本文不打算为它争一个正式名分，也不把它当作一个有出处的概念引用；之所以仍要用它，是因为“错误定价”这个词过于平静，容易让人忘记那道缝隙是被摩擦从两头削出来的——而这一点恰恰是全篇的论证重心。下面这张对齐表说明它对应到哪些既有概念，免得读者误以为它是某个新提出来的理论对象。

表 1: “可交易缝隙”及其相关提法与既有概念的对应

本文提法	文献中的标准概念	代表来源	差异说明
定价偏差	mispricing（错误定价）	通行概念，无需特指	本文与文献用法一致
可交易缝隙	profitable trading opportunity；在套利受限语境下最接近“可交易性”这一侧	Shleifer & Vishny（1997）[5]	文献通常只说“机会”，本文强调其宽度由摩擦决定
缝隙被摩擦削窄	market impact、transaction cost	Almgren & Chriss（2000）[8]	概念一致；本文把它写成对缝隙宽度的直接扣减
缝隙随参与者增多而变薄	alpha decay、因子发表后收益衰减	McLean & Pontiff（2016）[22]	概念一致；本文用信息租金耗散机制解释其成因
缝隙存在判据 $\delta_0 > c$	与“alpha 必须覆盖成本”的工程口径同构	本文自推，非文献标准结果	**本文提出**，见第 2 章命题 2.1

需要如实说明两点：其一，“可交易缝隙”与判据 $\delta_0 > c$ 均为本文自造或自推，不是引自任何文献，若引用请引本文；其二，如果你更习惯既有说法，把下文所有“缝隙”替换成“可交易错误定价”不会改变任何结论——术语是包装，判据才是内容。

AI 的价值，就落在“把这三段各自做得更好”上：更好地表示信息（特征学习、另类数据）、更好地估计偏差（预测模型）、更好地决策收割（执行、组合、风控）。而它的能力上限，恰好被第一条和第三条夹住——这就是为什么本文在全篇反复回到“信息存量的天花板”和“执行摩擦的地板”这两个约束上。这个框架还有一个好处，它天然解释了为什么不同方法族的“看起来好”并不等价：有的方法是在把信息榨得更干（天花板提升），有的方法是在把摩擦降得更低（地板下移），二者需要分开评估。

1.2 综述边界

- **时间范围**：方法学源头可追溯到 Markowitz（1952）与现代组合理论；主体覆盖 1990 年代统计套利、2010 年后深度学习与强化学习、2020 年后大模型与生成式模型，至 2026 年 10 月的预印本。
- **资产类别**：股票（美股、A 股、日股、欧股、新兴市场）、期货与商品、外汇、固定收益、加密货币；以股票与期货为主，其余作对照。
- **交易环节**：信号生成（alpha）、组合构建、交易执行（含做市与最优执行）、风险管理、另类数据与微观结构。
- **来源类型**：同行评审期刊论文、工作论文（NBER/SSRN）、arXiv 预印本、会议论文（NeurIPS/ICML/ICLR/ICAIF/AAAI）、官方开源仓库与基准报告。
- **排除**：与交易无关的通用机器学习方法介绍；纯营销材料与无实证或无理论贡献的二手转述；把“预测准确率”当作终点、不涉及任何交易环节的纯预测工作只作背景引用。

1.3 检索策略与证据链

检索采用多源交叉核验，所有元数据来自接口真实返回，未编造 DOI 或年份。为便于独立复现，检索式、脚本与全部中间产物一并给出（脚本见 `scripts/retrieve_sources.py`，原始返回见 `outputs/sources.json`）。三个源的分工是：

1. **OpenAlex API**（47 条标题检索）：按标题检索经典金融与计量期刊文献（*Journal of Finance*、*Review of Financial Studies*、*Journal of Financial Economics*、*Management Science*、*Quantitative Finance* 等），记录 DOI、发表年份、被引数与来源期刊。
2. **arXiv API**（45 条关键词检索）：检索 q-fin 与 cs 分类下的预印本，覆盖六个方法族（alpha 挖掘、序列建模、强化学习、NLP/LLM、生成式、图神经网络）与五个交易环节（执行、组合、风控、微观结构、另类数据），并专门检索评测方法论（数据窥探、回测过拟合、缩水夏普、复现危机）。
3. **Crossref**（10 条书目检索）：对前两源命中但元数据缺失或存疑的条目做书目级补核验（`verify_refs2.py`、`verify_refs3.py`），并以 GitHub API 核验官方开源仓库的可用性与许可。

表 2: 检索与筛选流程及计数

阶段	记录数	说明
识别（识别命中）	556	OpenAlex 154 + arXiv 375 + Crossref 27（接口返回的记录条数）
去重（按 DOI/arXiv 编号）	528	合并同一 DOI 与同一 arXiv 编号的重复记录
纳入（按边界与排除标准）	90	按六方法族与五环节筛选；剔除超出边界、无实证或无理论贡献者
入表	90	全部进入证据表；其中元数据层已核验 86 条、部分核验 4 条

检索与筛选流程（PRISMA 式）

代表性检索式举例（完整清单见脚本）：OpenAlex 标题如 `Empirical Asset Pricing via Machine Learning`、`Optimal Execution of Portfolio Transactions`；arXiv 关键词如 `abs:"reinforcement learning" AND abs:"optimal execution"`、`abs:"large language model" AND abs:"stock" AND abs:"trading"`、`abs:"backtest overfitting" AND cat:q-fin`。检索执行日为 2026-10-09，未设起始年份限制，纳入截止于当日可见的预印本。

两条口径约定

（一）年份口径：期刊与会议条目记**正式发表年**；若工作先以预印本发布后正式发表，以正式发表年为准（如 TimesFM 记 2024 年，其 arXiv 首发为 2023 年）；未正式发表者记 arXiv 首发年。正文中的“作者（年份）”均遵循此约定，读者若按 arXiv 首发年检索，可能相差一年。

（二）核验等级：本文只用两级——已核验（DOI / arXiv / 官方链接与元数据互证）、部分核验（元数据确认，但样本区间、模型参数等细节待全文复核）。**不设“待复核”一档：**凡无法确证元数据者，一律不入表。需要强调的是，已核验仅指**元数据层**，与结论是否可靠无关——结论的可靠性请对照证据表 B 的“复现状态”列。

1.4 与已有综述的关系

“AI + 金融”并不缺综述，但既有综述大致分三类，各有一块盲区。

第一类是**文献计量与主题建模型**综述，统计发文量、主题词与引用网络（如 [90]），它告诉你这个领域多热、热点在哪，却几乎不回答“哪些结果可信”。第二类是**方法罗列型**综述，把模型按代际排开（线性 → 树 → 深度 → 大模型）逐一介绍结构与改进（如 [89]），读起来像教科书目录，但很少触及成本、样本外与复现。第三类是**经济学实证传统**的方法学工作，把机器学习放进资产定价的经验研究里（如 [28]），讨论严谨，但覆盖面集中在横截面收益预测，对执行、做市、生成式与 LLM 智能体这些更靠近“摩擦”的方向着墨有限。

本文的三点不同：

1. **用一条判据贯穿全篇**。不是按“方法新旧”排序，而是按“是否在扣成本、扣多重检验后仍然为正”的统一判据（第 2 章）评估每一族。因此本文会明确写出“这一族在当前口径下增量不可判定”，而不是含糊地说“有潜力”。
2. **把评测本身当作研究对象**。第 14 章的污染审计与第 15 章的复现核验，占据的篇幅不亚于方法介绍。因为对落地者而言，“哪些能重跑”比“有哪些新方法”更决定成败。
3. **区分架构事实与判断结论**。凡属可验证的架构/协议事实（如某基准公开了哪些指标、某仓库的许可与活跃度），本文给出可核验依据；凡属判断性结论（如“RL 在组合管理上证据薄弱”），本文标明置信度与边界条件。

同样要说清楚本文**不做**什么：不做文献计量统计，不追求覆盖每一篇边际改进，也不对未公开数据/模型的结论给出超出“不可独立验证”的判断。这三条既是本文的边界，也是它能把力气花在“可落地”上的原因。

1.5 这篇综述的读法

如果你只关心“哪些方法能落地”，从第 3 章的双轴框架和第 15 章的复现状态核验表读起，再跳到第 16 章的实验方案。如果你想搞清楚“AI 到底改变了什么”，先读第 2 章，那里把交易的数学底座和 AI 的作用位置讲清楚，后面每一族方法都是它的实例。如果你怀疑现有研究的可靠性，第 14 章的评测污染审计和第 18 章的置信度分级会给你一把尺子。

有一句话我想先放在开头，后面会一次次用到它：**在金融里，一个模型能把样本内拟合得多好，往往和它能不能赚钱关系不大；真正相关的是它抓到的信息还有多少没被别人用掉，以及它赚到的钱够不够付摩擦的账。**

2 交易的信息论基础与 AI 的作用位置

在谈任何模型之前，得先把交易这件事本身说清楚。这一章不介绍算法，只回答一个问题：在一个由人和机器共同参与的市场里，凭信息赚钱这件事，数学上被允许到什么程度？只有把这个边界画出来，后面每一族方法的能力与失效条件才有参照。

2.1 有效市场之争留下的，不是一个“是不是有效”的答案

Fama（1970）[2] 把有效市场分成弱式、半强式、强式三档，本质是把“价格是否已反映某类信息”变成一个可检验命题。半个世纪过去，这场争论真正留下的结论不是“市场有效”，而是一个更微妙的东西：**价格对新信息的反应速度快到让大多数慢半拍的人赚不到钱，但快的人能赚到——而快是有成本的。**

Grossman 与 Stiglitz（1980）[3] 的悖论把这个微妙之处变成了严格的逻辑：如果价格已经充分反映所有信息，那么没有人有动力去花费成本获取信息；可一旦没人去获取，价格又不可能充分反映信息。于是市场只能停在一个不动点上——价格足够有效率，使得获取信息的边际成本恰好等于边际收益，而**这个均衡里必然留着一部分未被消除的定价偏差**，它就是所有主动交易的利润来源。Shleifer 与 Vishny（1997）[5] 进一步指出，即便偏差被人看见，套利者也会因为资金约

束与噪声交易者风险而无法把它立刻消除，这正是偏差能长期存在的原因。这个结论对本文至关重要：它意味着“AI 能不能赚钱”这个问题问错了，正确的问题是“AI 相对其他参与者，在信息获取的边际上是不是更便宜、更快、或者更强”。

2.2 信息如何进入价格：微观结构的视角

Kyle（1985）[4] 的模型给出了信息进入价格的最简机制。市场里有一类知情交易者掌握私有信息，一类噪声交易者随机下单，做市商只能看到净订单流并从中间接推断信息。均衡下，价格以某个速率（即 Kyle 的 λ，价格冲击系数）向真实价值收敛：

$$\lambda = \frac{1}{2}\sqrt{\frac{\Sigma_0}{\sigma_u^2}}, \tag{1}$$

其中 Σ_0 是私有信息的先验方差，σ_u^2 是噪声交易的方差。这个式子说的是：**知情交易者越多、信息越有价值，价格对订单流就越敏感，单位信息能换取的利润就越薄**。这是一种自动的“信息租金耗散”机制——它和 Grossman–Stiglitz 讲的是同一件事，只是从订单流的层面重新讲了一遍。

对 AI 交易而言，这条机制的含义是：任何被公开、被广泛使用的信号，其毛利都会被 λ 自动压薄。这解释了为什么大量“因子被发表后收益衰减”的经验现象（McLean & Pontiff 2016[22]）不是意外，而是结构性必然。也解释了为什么纯“回测漂亮”的策略在实盘上失效——回测里的 λ 往往被设成一个常数甚至零。

2.3 低信噪比：金融预测与其它机器学习任务的根本差别

把机器学习搬到金融上，最先撞上的不是算法问题，而是信噪比问题。图像分类里，像素与标签之间有相当强的确定性关系；而在月度股票收益预测里，最强的模型能解释的方差也只有千分之几。

Gu、Kelly 与 Xiu（2020）[28] 用一整套机器学习方法（含树模型与神经网络）预测美股横截面收益，报告的样本外 R^2 量级只有**约 0.3%–0.4%**（月度）。这个数字单看小得可笑，但换算成年化多空组合的收益与夏普，已经相当可观。它揭示的道理是：**金融里“解释力低”和“能赚钱”并不矛盾，因为杠杆和横截面聚合可以放大微弱的信号；但反过来，“样本内 R^2 高”也几乎不能说明任何问题，因为任何一个过参数化模型都能把噪声拟合得很漂亮。**

低信噪比带来三个连锁后果。其一，过拟合的风险被放到最大，任何在样本内调参的自由度都是一种“数据窥探”（White 2000[19]）。其二，模型比较的统计功效很低，两个模型的 R^2 差异常常落在噪声里。其三，信噪比低意味着**模型的边际信息增量必须以“经济上可交易”来检验**，而不是以统计指标来检验——这正是评测污染审计（第 14 章）要处理的问题。

2.4 从预测到收益：摩擦如何把缝隙削窄

即便一个信号真的抓到了信息，它离“赚到钱”还隔着两段：组合构建与交易执行。

组合构建这一端，Markowitz（1952）[1] 的均值–方差框架给出了最优权重：

$$w^\star = \arg\max_{w} \; \Big(w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w \Big), \tag{2}$$

其中 μ 是预期收益，Σ 是协方差，γ 是风险厌恶。问题在于，μ 的估计误差会被 Σ^{-1} 放大——低信噪比地区，估计误差主导结论，这就是“误差最大化”（error maximization）的经典困境。机器学习对组合构建的贡献，很大程度上是在更稳健地估计 μ（和 Σ）。

执行这一端，Almgren 与 Chriss（2000）[8] 把“想卖一大笔”分解成两个互相拉扯的成本：等待太慢会让价格漂移（时机风险），抛得太快会砸盘（冲击成本）。最优执行路径是二者的折中，总成本是一支关于成交速度的 U 形曲线。这条路后来被强化学习重新打开（第 6 章）。

把两端合起来，就能给“可交易缝隙”（本文工作术语，其与既有概念的对应见第 1 章 §1.1 的对齐表）一个可操作的定义。

定义 2.1 (可交易缝隙)**.** *设策略 π 在风险预算下产生预期超额收益 $\mathbb{E}[r_\pi]$、交易成本与冲击成本 $C(\pi)$、以及与所承担风险相称的补偿 λ_π。称该策略存在可交易缝隙，当且仅当扣除摩擦后的净风险调整收益*

$$G(\pi) = \mathbb{E}[r_\pi] - C(\pi) - \lambda_\pi \tag{3}$$

在多重检验校正后仍然显著大于零，且在样本外与跨市场不反号。

这个定义里每一个词都有分量。$C(\pi)$ 不是可以事后忽略的尾项，它常常是决定生死的那一项（Martin & Schöneborn 2011 的说法很直白：均值回归能赚，但要付成本 [86]）。“多重检验校正后”是因为在一个你试验了一万次的策略空间里，总能挑出一条回测最好的——“显著”必须相对于你试过多少次而言（Harvey、Liu & Zhu 2016[21]）。“样本外不反号”是最后的诚实检验。

2.5 缝隙存在的一个必要条件

把可交易缝隙再推一步，可以得到一条能解释很多现象的必要条件。设某信号在 t 时刻的残余预测力（可转化为毛收益的部分）按 t 指数衰减，幅度为

$$\delta(t) = \delta_0\, e^{-\lambda t}, \tag{4}$$

其中 λ 是信息被市场吸收的速率（本章微观结构一节的 Kyle λ 决定了它）；记单次调仓的比例成本为 c。若按固定周期 Δ 调仓，则单位时间的净收益是毛收益减成本再除以周期：

$$g(\Delta) = \frac{\delta_0\, e^{-\lambda \Delta} - c}{\Delta}. \tag{5}$$

令 $x = \lambda\Delta$，一阶条件整理为

$$(1 + x)\, e^{-x} = \frac{c}{\delta_0} =: \rho. \tag{6}$$

而 $(1+x)e^{-x}$ 在 $x \geq 0$ 上从 1 单调递减，因此：

命题 2.1 (缝隙存在的必要条件)**.** *在上述模型下，存在使 $g(\Delta) > 0$ 的调仓周期，当且仅当 $\delta_0 > c$；最优调仓周期为 $\Delta^\star = x^\star/\lambda$，其中 $x^\star$ 是方程 $(1+x)e^{-x} = \rho$ 的正根。*

这个命题只有两行推导，却把三件事绑在了一起：**信号的初始幅度 δ_0 必须超过交易成本 c，否则再好的模型、再聪明的调仓节奏都无力回天；最优调仓频率随信息衰减速度 λ 上升而上升（衰减越快越要抢在信息消失前交易）；随成本占比 ρ 上升而下降（越贵越要少动）**。这解释了为什么高频策略对成本极度敏感、也解释了为什么低频信号在成本上升时会被迫降频甚至停摆。

不过，只有把判据里的两个量估出来，它才不是一个同义反复——否则“$\delta_0 > c$”就等于“能赚钱的策略就能赚钱”。两者都可以用可核验的方式估：

- c **的估计**：用交易记录直接算——每笔成交均价与决策时点参考价的差额，加上佣金与税费，再除以成交金额，即得该笔的比例成本；多笔取中位数，避免极端单笔带偏。
- δ_0 **的估计**：用“事件窗平均实现收益”作代理——在信号触发后的 k 期内，按信号方向构建的多空组合的平均超额收益，取事件样本均值 $\hat{\delta}_0$。它衡量的是“信号在信息尚未衰减时能兑现多少”。

估计误差如何影响判据。$\hat{\delta}_0$ 的标准误大致随事件数 m 与单事件收益的分散度 σ_r 变化，量级约为 $\sigma_r/\sqrt{m}$；k 越大，$\hat{\delta}_0$ 越被信息衰减压低，因此 k 应取信息半衰期的量级。由于两个量都有误差，判据应当用**置信下界**而非点估计来判断：

$$\hat{\delta}_0 - z_\alpha \,\widehat{\mathrm{SE}}(\hat{\delta}_0) \;>\; \hat{c}, \tag{7}$$

其中 z_α 取单侧分位（如 5% 对应约 1.645）。这一改动看似保守，却是必要的：在事件数少、分散度大的情形下，用点估计判断会**系统性地高估**缝隙的存在性，而这正是大量小样本研究所犯的错误。

它还给出一个实用的诊断：当你发现某策略“样本内很好、实盘亏钱”时，先按上面的办法估 $\hat{\delta}_0$ 与 $\hat{c}$；若置信下界已经落在 $\hat{c}$ 之下，问题不在模型，而在缝隙根本不存在。

2.6 AI 在这条链条上的三个作用位置

用上面这套语言，AI 的应用可以归成三个位置，它们的能力上限各不相同：

1. **表示学习（改变信息的天花板）**。把非结构化数据（新闻、财报、订单簿、卫星图、电话会录音）转成可用的数值特征。这一环直接决定“信息存量”能用出多少——文本与订单簿这类数据的信噪比未必高，但存量极大，且长期被低估。深度学习、图神经网络、大模型主要在这里发力。
2. **偏差估计（把信号做成预测）**。在给定特征下估计未来收益的条件分布。这里的天花板由市场效率与 λ 决定，AI 能做的通常是“更充分、更非线性地利用已有信息”，而非创造新信息。监督学习、序列模型主要在这里。
3. **决策收割（把预测做成仓位）**。决定买多少、什么时候买、怎么执行、如何风控。这一环的天花板由摩擦决定，AI 的贡献是把摩擦降得更低、把动态决策做得更优。强化学习、最优执行、组合优化主要在这里。

这三个位置不是并列的三选一，而是一条流水线：表示学习决定了信息能榨出多少，偏差估计决定了信号有多准，决策收割决定了信号能变现多少。一个方法在某篇论文里表现好，往往是因为它在其中某一环做得比对手好，而不是“AI 更强”。把这一点想清楚，后面读任何一篇“AI 交易”论文时，就不会被它的指标牵着走。

2.7 一个同构性的看法

如果跳出金融，会发现这三个作用位置和推荐系统、广告竞价、供应链优化里的“感知–预测–决策”分层是同一套结构。差别只在约束：金融这边，**信噪比更低、分布更非平稳、环境是对抗性的（你的对手会针对你的模型调整）、并且可用于学习的“样本”受限于有限的历史**。这四条约束里，前三条在其他领域可以被工程手段缓解，唯独第四条无法绕过——历史只有一份，而且它是由一个会因你的参与而改变的过程生成的。这也是为什么金融机器学习的“样本量”问题，本质上不是数据不够大，而是**有效的、独立的样本不够多**。第五章起的每一族方法，都会回到这条约束上。

最后落一句本章要记住的话：**AI 在金融里不是一台印钞机，它是一台更高效的“信息–预测–决策”转化装置；装置效率再高，也受制于喂进去的信息还剩多少、以及转化出来的东西够不够付摩擦的账。**

3 综述框架：方法族与交易环节的双轴

第 2 章把 AI 的作用拆成了表示、预测、决策三个位置。这一章把它落成一张可以逐格检查的表格，好让后面每一章都有明确的位置感，不至于写成“某方法的介绍”。

3.1 两条轴

纵轴是方法族，按技术谱系分六类：

1. **监督学习与 alpha 挖掘**：线性/正则化回归、树模型、集成学习，把横截面收益预测形式化为一个回归/排序问题。
2. **深度学习与序列建模**：RNN/LSTM、TCN、Transformer、以及 2024 年后的时序基础模型，处理序列依赖与长上下文。
3. **强化学习**：把交易当作序贯决策，直接优化执行成本、组合效用或交易收益。
4. **自然语言处理与大模型**：从词典法情绪、FinBERT 类编码器，到 LLM 抽取信号与 LLM 智能体。
5. **生成式模型**：GAN/VAE/扩散模型，用于合成数据、场景生成与市场仿真。
6. **图神经网络**：把公司、资产、产业链、跨资产的关系建成图，做关系感知的预测。

横轴是交易环节，按一条完整的策略生命周期分五段：

1. **信号生成（alpha）**：从数据出发产生对未来的预测。
2. **组合构建**：把预测翻译成权重，处理风险预算、约束与交易成本。
3. **交易执行**：决定下单路径、择时与做市报价，核心是摩擦管理。
4. **风险管理**：控制回撤、尾部风险与暴露，动态化风险预算。
5. **另类数据与微观结构**：订单簿、逐笔成交、非传统数据源，是信号与执行的共同上游。

3.2 双轴映射矩阵

下表是本文的组织地图。每一格后面的方括号给出对应章节。空白处不作为：它表示该“方法族 × 环节”组合在文献中确有实质工作，只是本文将其并入相邻章节讨论，以避免重复。

表 3: 方法族 × 交易环节映射矩阵

方法族	信号生成	组合构建	交易执行	风险管理	另类数据/微结构
监督学习	核心 [4]	辅助 [11]	—	辅助 [11]	消费端 [10]
深度学习/序列	核心 [5]	辅助 [5]	辅助 [5]	辅助 [11]	核心 [5]
强化学习	辅助 [6]	核心 [6]	核心 [6]	辅助 [6]	执行侧 [6]
NLP/大模型	核心 [7]	辅助 [7]	辅助 [7]	辅助 [7]	新闻/文本 [7]
生成式模型	辅助 [8]	辅助 [8]	仿真 [8]	压力测试 [8]	合成数据 [8]
图神经网络	核心 [9]	辅助 [9]	—	传染风险 [9]	关系结构 [9]

这张表要传递的信息是：**方法族与交易环节不是一对一的关系**。同一个方法族可以在多个环节发力，同一个环节也可以被多个方法族改进。因此“某方法好不好”这个问题没有意义，必须问“在哪个环节、相对什么基线、扣掉什么成本之后”。这也是本文后面统一比较矩阵的出发点。

3.3 每一族的统一审查口径

为避免六章写成六套不同标准，本文对每一族都用同一套五个问题去审：

1. **问题设定**：它到底在预测/优化什么目标？目标与“赚钱”之间差了几层？
2. **原理**：方法的机制是什么，为什么它可能有效（而不只是“跑了一遍”）？
3. **落地要素**：需要什么数据（频率、覆盖、许可）、什么特征、什么训练/推断成本？
4. **复现状态**：有没有公开代码、公开基准、独立复现？复现结论是否与原文一致（详见第 15 章）？
5. **失效边界**：在什么条件下它会失效？是信息耗尽、非平稳、成本吞噬，还是数据泄漏？

这五个问题里，**第四和第五个是最容易被论文和报告略过的，也是本文花笔墨最多的地方**。因为对想落地的人而言，方法好不好用，取决于这两项，而不是取决于原文的样本内指标。

3.4 一条贯穿的判据

把第 2 章的可交易缝隙定义带到每一族，就得到本文反复使用的判据：一族方法的真实增量，等于它在统一口径下相对最强基线的 $G(\pi)$ 之差（见式 2.3），而不是它的样本内指标之差。凡是原

文未报告成本、样本外与多重检验的，本文一律在证据表与比较矩阵里标注为“增量不可判定”。这不是苛刻，而是这份综述存在的意义——把“看起来有效”和“确实可交易”分开。

本章要记住的一句话是：**方法族的名字不重要，重要的是它在交易链条的哪一环、替谁省下了信息成本或摩擦成本，以及这个节省有没有被独立复现过。**

4 监督学习与 alpha 挖掘

监督学习是最早进入量化、也最容易被低估的一族。它做的事情听起来很朴素：给定一批特征，预测下一期的横截面收益，然后按预测排序构建多空组合。可正是这个最朴素的问题，逼出了金融机器学习里最本质的几组矛盾——低信噪比下的过拟合、预测目标与交易目标的错位、以及“因子被发表后收益衰减”。

4.1 问题设定

形式化地，在每个调仓时点 t，观察到每只资产 i 的特征向量 $x_{i,t} \in \mathbb{R}^p$（估值、动量、质量、流动性等），要预测其下一期收益 $r_{i,t+1}$。学习目标是

$$\hat{f} = \arg\min_{f \in \mathcal{H}} \sum_{t} \sum_{i} \mathcal{L}\big(r_{i,t+1},\, f(x_{i,t})\big) + \Omega(f), \tag{8}$$

$\mathcal{L}$ 是损失（均方或排序），Ω 是正则项。这一步看似标准，但**目标函数与“赚钱”之间隔着三层**：预测的是收益而非风险调整收益；以横截面为单位而非以组合为单位；没有把交易成本写进去。三层之外还有一层的错位——调仓频率决定了标签的构造（未来 1 期还是 k 期），而标签构造会反过来决定模型学到的是动量还是反转。

4.2 从线性到非线性：一条可复现的演进线

线性基准。Fama–French 三因子/五因子模型是这一族的天花板之一，也是所有非线性模型必须超越的基线。它们本质上是把 $\hat{f}$ 限制成少数暴露的线性组合。符号上简单，但“用哪些暴露、怎么组合”始终是个开放问题。

正则化回归。当候选特征从几个扩到几百个，问题立刻变成高维信号的挑选。Feng、Giglio 与 Xiu（2020）[32] 用双重选择 Lasso（double-selection）来处理“因子动物园”问题，思路是先控制住一大片潜在因子，再判断新因子是否有增量，这与 Harvey、Liu 与 Zhu（2016）[21] 的多重检验警示是同一件事的两面。

树模型与集成。梯度提升树（GBRT）与随机森林在金融横截面上的表现常好于线性模型，原因是它们能自然处理非线性和交互，并对异常值不敏感。Krauss、Do 与 Huck（2017）[33] 在标普 500 成分股上系统比较了深度神经网络、梯度提升树与随机森林三种方法做统计套利，发现集成方法在多数设定下稳定占优——这是把“到底哪种模型好”放到公开口径下比较的早期代表作之一。

神经网络。Gu、Kelly 与 Xiu（2020）[28] 是这一族的基准文献。他们用同样的特征集，把线性回归、正则化回归、GBRT、随机森林与多种神经网络放在一起比较，报告的样本外月度 R^2

只有约 0.3%–0.4%，但由此构建的多空组合的夏普与累计收益显著。这一结果确立了这一族最重要的经验事实：**解释力极小不等于不可用，关键在于是否把微弱信号稳定地转化为组合收益**。他们还报告了神经网络相对树模型的优势，并强调这一优势来自对交互与非线性的刻画，而非模型复杂度本身。

把无套利约束写进网络。Chen、Pelger 与 Zhu（2024）[30] 的做法是把资产定价的无套利结构（因子定价的线性结构）直接编码进深度网络的架构，让网络在“定价核”层面学习而非在收益层面自由拟合。这类方法的价值在于**把经济结构当作先验注入模型**，从而在低信噪比下减少需要估计的自由度——这与纯黑箱拟合是两种哲学。

“复杂性红利”的争议。Kelly、Malamud 与 Zhou（2024）[31] 提出“复杂性的价值”（virtue of complexity）：在高维但结构稀疏的设定下，一个参数数量远大于样本量的岭回归反而能有更好的样本外表现。这个结论在文献里争议不小——支持者认为它挑战了“奥卡姆剃刀”，反对者指出它对信号强度与协方差结构做了较强假设，且在高频、真实的交易成本下未必成立。本文在此不站队，只把它列为**证据强度中等、边界条件明确**的一类主张。

4.3 落地要素

要复现这一族的任何工作，最容易被忽略、也最致命的是三件事：

- **时点对齐（point-in-time）**。财报数据必须用实际披露日，而非报告期；任何“用当期财报预测当期收益”的设定都是前瞻偏差。这是这一族数据管线里最容易出错的地方。
- **横截面中性化**。把行业、市值、风格暴露从预测里剥掉，否则模型学到的可能只是“小盘/成长”这些已知风险溢价，而非新 alpha。
- **交易成本口径**。横截面策略的换手率高，成本对净值曲线的影响常常是决定性的。不报告成本的样本外夏普，与报告成本后的夏普，可能相差一个量级。

4.4 复现状态与失效边界

这一族是六族里复现基础最好的：Microsoft Qlib[87] 公开了 Alpha158/Alpha360 两个特征集与一批模型在 CSI300 上的基准结果，Grinold–Kahn 风格的因子研究也有成熟的开源工具链（Alphalens 等）。但“能跑通”不等于“能赚钱”：Gu、Kelly 与 Xiu 的样本外结论在换到 A 股、换到更近的样本区间后是否成立，公开的独立复现并不多（详见第 15 章）。

失效边界主要有四条，且都可检验：

1. **信息耗尽**。任何被广泛使用的特征，其边际信息会被 Kyle 型的价格冲击机制压薄（McLean & Pontiff 2016[22] 记录了这一衰减）。
2. **非平稳**。特征与收益的关系随市场制度漂移，固定模型会在制度切换后失效。
3. **成本吞噬**。高换手策略在真实成本下的净收益可能为负。
4. **数据窥探**。在几百个特征与几十个模型里挑最好的，样本内冠军往往是噪声冠军。

本章要记住的一句话是：**监督学习在金融里的真正难点，从来不是“用什么模型”，而是“在**

信息耗尽、分布漂移、成本与多重检验的四重约束下，还能剩下多少稳定的、可交易的增量”。

5 深度学习与序列建模

如果说监督学习那章讨论的是“在横截面上找规律”，这一章讨论的是“在时间轴上找规律”。两者看似只差一个维度，实际却把问题换了个性质：横截面预测关心的是同一时点上资产之间的相对高低，时序预测关心的是同一资产在不同时刻的演化。后者的难点，一半来自序列本身，一半来自金融时间序列那点特殊的坏脾气。

5.1 问题设定：预测精度不等于交易绩效

序列建模的目标通常是预测未来的价格、收益或波动率。这里必须先把一件事分清楚，否则后面全乱：**预测精度（如 RMSE、方向准确率）与交易绩效不是一回事**。一个能把价格拟合得很准的模型，可能因为预测的方向变化太频繁、幅度太小、或者领先/滞后关系不对，而在扣掉成本后赚不到钱。大量“LSTM 预测股价”的论文只报告了精度指标，却从未把它接到一个带成本的交易回测上——这类工作在本文里只作背景，不计入可交易证据。

5.2 架构谱系

循环网络。Fischer 与 Krauss（2018）[34] 用 LSTM 预测标普 500 成分股的次日方向，报告了约 0.46% 量级的日度方向准确率提升与对应的回测结果，是 LSTM 进入金融预测的代表作。它的意义不只在于结果，更在于它示范了一种做法：**把预测接到一个明确的交易规则上，并报告成本敏感性**，而不是停在精度上。

卷积与混合结构。一维卷积（TCN）与卷积–循环混合结构在捕捉局部模式上有优势，常被用作对循环结构的替代或补充。

注意力与 Transformer。Vaswani 等（2017）[41] 的注意力机制进入时序领域后，出现了两类工作：一类是通用的长序列预测架构（Informer[44]、Autoformer[45] 等），另一类是为多变量、带已知协变量的预测设计的结构，如 Temporal Fusion Transformer（Lim 等 2021[43]），后者因其可解释的变量选择与门控机制，在含外生变量的金融场景里被较多采用。

这里要专门提一个反证。Zeng 等（2023）[46] 指出，在多个通用时序预测基准上，一个极其简单的线性模型（DLinear）就能追平甚至超过上述复杂 Transformer，说明“注意力带来的收益”有时被高估了。这个结论针对的是通用时序基准，不能直接外推到金融，但它给的警示是普适的：**在比较模型时，一个强线性基线不可缺少；既然低信噪比会放大复杂度带来的过拟合，金融场景里尤其如此。**

时序基础模型。2023 年后出现了一批在跨领域大规模时序上预训练的“基础模型”，如 Chronos（Ansari 等 2024[47]）、TimesFM（Das 等 2024[48]）、Lag-Llama（Rasul 等 2023[49]）。它们的目标是零样本/少样本预测。金融是这类模型最诱人、也最危险的应用场：诱人在于数据量大、任务多；危险在于金融序列的非平稳与对抗性，与这些模型预训练时的“平稳、可重复”假设相冲突。目前公开的、在严格样本外协议下把时序基础模型接到可交易策略上的证据仍然稀

少，本文将其列为**证据强度低–中、需要独立复现**的方向。

5.3 一个常被忽略的落地点：订单簿与微观结构

序列建模在金融里最干净的落地场景，其实不是日频价格预测，而是**订单簿建模**。订单簿数据的样本量以十亿计，信噪比虽不高但相对稳定，且预测目标（下一笔成交方向、未来的短时价格漂移）与执行决策直接挂钩。Zhang、Zohren 与 Roberts（2019）[36] 的 DeepLOB 用卷积加 LSTM 处理限价订单簿，Sirignano（2019）[39] 提出面向订单簿的空间网络结构，Tsantekidis 等（2017）[37] 用卷积网络从订单簿预测价格方向，这些工作之所以相对可信，正是因为它们的数据与评测协议比日频选股要干净得多。本文把订单簿建模放在这一族，是因为它的方法论贡献（如何把高维、非平稳的微观结构序列喂给网络）对其他环节也有借鉴价值；而把它与“用 LSTM 预测股价”区分开，是因为二者的可复现性不在一个量级上。

5.4 落地要素

- **标签构造决定一切**。用未来 1 日、5 日还是 20 日收益作标签，等价于选择了不同的预测尺度，动量和反转会跟着翻转。报告结果时必须写清楚。
- **标准化要按时间在线进行**。用全样本均值方差做标准化，是把未来信息泄漏进训练集的典型错误。
- **验证集要用滚动/前向切分**。随机切分在时序问题上等同于作弊。
- **对齐交易时点**。信号在 t 收盘算出、却假设在 t 开盘成交，是最常见的隐性前瞻偏差。

5.5 复现状态与失效边界

这一族的开源实现很多（各类 LSTM/Transformer 选股仓库），但真正带完整成本模型、样本外协议与独立复核的很少。DeepLOB 因为数据来源（FI-2010[38] 等公开订单簿数据集）与代码相对透明，复现状态较好；而多数“深度模型选股”论文的复现状态为**部分复现或不可复现**。

失效边界可归纳为三条：**非平稳**（模型学到的时序模式在制度切换后失效）、**过参数化**（在低信噪比下把噪声当信号）、以及**目标错位**（优化预测精度而非交易绩效）。本章要记住的一句话是：**在金融序列上，模型能不能“预测得准”和能不能“赚到钱”是两件事，而绝大多数标题党式的深度学习论文，恰恰混淆了这两件事。**

6 强化学习：执行、组合与做市

前面两族都在做预测：先猜未来收益，再把预测变成仓位。强化学习（RL）换了个思路，直接学“在什么状态下该做什么动作”，把预测和决策合成一个目标。这个转向对交易尤其自然，因为交易本来就是序贯决策——今天的仓位决定明天的可选空间，执行成本随下单节奏变化，而目标（终值效用）不是单期收益的简单加总。

6.1 问题设定

把交易写成马尔可夫决策过程 $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$：状态 s_t 含持仓、行情、特征，动作 a_t 是下单/调仓/报价，奖励 r_t 是区间收益扣除成本，目标是最大化期望折扣回报

$$J(\theta) = \mathbb{E}_{\pi_\theta}\Big[\sum_{t=0}^{T} \gamma^t r_t\Big]. \tag{9}$$

形式上干净，但金融场景下这条式子埋着三个坑：$\mathcal{P}$（环境转移）未知且不可反复采样，$\mathcal{R}$ 里成本项一旦设错就被“利用”，而 γ 与 T 的设定会改变策略是短视还是长视。**RL 的危险不在于学不会，而在于它会精确地学会你设定的那个目标——包括目标里的错误。**

6.2 三个主要落地方向

（一）最优执行。这是 RL 最早、也最成功的应用。Nevmyvaka、Feng 与 Kearns（2006）[52] 用 RL 学习在限价订单簿中的下单时机，是对 Almgren–Chriss 解析解的第一次数据驱动挑战。这一方向的优势在于：环境相对稳定、目标清晰（最小化执行成本）、且有成熟的基线（VWAP/TWAP 与 Almgren–Chriss）可对照。近年一批工作把它做成深度 RL，并在含真实成本与市场冲击的模拟器里评测。Cartea、Jaimungal 与 Penalva（2015）[40] 的系统论述为这一方向提供了理论底座。

（二）组合管理。Jiang、Xu 与 Liang（2017）[50] 提出用深度 RL 做组合管理，网络直接输出各资产的权重，绕开了“先预测再优化”的两段式。Deng 等（2017）[35] 提出直接 RL 做金融信号表示与交易，把特征学习与决策学习连成一段。这一类工作后来被开源框架 FinRL（Liu 等 [51]）系统化，FinRL 提供了环境、数据管线与多种 RL 基线，是这一族可复现性最好的资产之一。但需要指出：**FinRL 的价值主要在于“把流程标准化”，而不在于“证明 RL 能赚钱”**——用它跑出来的高收益，很大一部分取决于环境与成本设定，而非算法本身。

（三）做市。做市是 RL 的天然场：报价是连续动作，目标是赚取买卖价差同时管理库存风险。Guéant 与 Manziuk（2019）[54] 用深度 RL 做做市，Spooner 等（2018）[53] 用 RL 学习做市报价，均报告在模拟环境中优于传统报价基线。做市方向的可信度相对高，因为目标（库存调整后的价差收益）与模拟环境（一笔笔订单流）能做得比较接近现实。

6.3 落地要素

- **模拟器就是一切**。RL 学出的策略的好坏，几乎完全取决于训练环境与真实环境的接近程度。用历史数据回放（backtest-as-environment）训练，等于让策略去拟合“如果我的下单不影响市场”这个假世界。
- **成本与冲击必须内生化**。若把成本当成固定费率，策略会学会疯狂交易；只有让冲击随参与率上升，策略才会学会“慢下来”。
- **奖励设计要抗 Hack**。只给收益奖励，策略会学会承担尾部风险换取高均值；只给夏普，又会在样本内择时。
- **样本效率**。金融历史只有一份，RL 需要在有限交互下学到稳定策略，这与游戏/机器人动辄上亿次交互的场景根本不同。

6.4 复现状态与失效边界

FinRL[51] 与若干做市/执行仓库提供了代码与数据处理，复现状态为**部分复现**：流程可跑通，但原文报告的收益在换数据、换成本口径后常不能保持。失效边界主要有三条。第一，**环境错配**——训练用的历史回放让策略“假设自己不影响市场”，实盘一放大参与率就失效。第二，**过拟合到制度**——RL 在单一制度下学到的策略在制度切换后崩溃，且因为它可以在大量参数组合里搜索，多重检验问题比监督学习更严重。第三，**奖励与真实目标的偏离**——奖励里的任何近似（成本、风险、折扣）都可能被策略放大成致命的行为。

本章要记住的一句话是：**强化学习在交易上最大的诱惑，是它把“预测–决策”一步到位；最大的风险，也是它把决策直接学进了你对世界的假设里——假设错了，它比你更彻底地错。**

7 自然语言处理与大模型：从情绪到交易智能体

文本是金融市场里信噪比最微妙的一类数据：单条新闻的噪声极大，但它承载的信息（基本面变化、预期修正、情绪）是价量数据里没有的。这一族的演进，恰好可以按“信息抽取的粒度”分成三代——词典、编码器、大模型，每一代都扩展了可用的信息，也带来了新的、更隐蔽的泄漏风险。

7.1 第一代：情绪与词典

Tetlock（2007）[16] 用报纸专栏的用词来度量投资者情绪，发现负面措辞与随后的价格下行相关，是“文本 → 交易信号”的早期实证。Baker 与 Wurgler（2006）[17] 构造了综合情绪指数并检验其与横截面收益的关系。这一代的技术核心是词典法：Loughran 与 McDonald（2011）[18] 指出通用情感词典在金融文本上会严重误判（“liability”“tax”“cost”在金融语境下中性，在通用词典里可能是负面），并构建了金融专用情感词典，成为此后几乎所有金融文本研究的标准工具。

这一代的问题很清楚：**词典无法处理否定、语境与隐含表达**，它能抓到的是“词的极性”，而不是“句子的意思”。

7.2 第二代：预训练编码器

FinBERT 类模型把金融文本理解推进到上下文级别。Araci（2019）[55]、Yang 等（2020）[56] 与 Huang、Wang、Yang（2023）[57] 分别在金融语料上继续预训练 BERT，在情感分类与信息抽取任务上超过通用模型与词典法。这一代的贡献是双重的：它提升了文本信号的质量，也确立了“先在金融语料上预训练、再在下游任务上微调”的范式。但它仍受限于标注数据、任务特定的输出格式（分类标签），且**只能处理被专门训练过的任务**。

7.3 第三代：大模型与交易智能体

大语言模型把这一族推向两个新方向。

（一）LLM 直接抽取收益信号。Lopez-Lira 与 Tang（2023）[60] 用 ChatGPT 读公司新闻标题，把输出映射成交易信号并回测，报告了显著的多空收益。Ke、Kelly 与 Xiu（2019）[61] 更早地用文本数据预测收益，是把文本转成收益信号的代表性实证。这类工作的吸引力在于**无需标注数据、可零样本迁移**，但它的最大隐患也在这里：**如果用于回测的新闻落在模型的预训练语料覆盖期内，模型“知道”结果，回测收益就是数据泄漏的产物。**一个设计严谨的 LLM 回测，必须要么使用模型训练截止日之后的样本，要么严格证明测试文本不在训练语料中。这一点在 2023–2025 年的大量 LLM 交易论文中被系统性忽视，是本文审计（第 14 章）里最严重的一类污染。

金融专用大模型（BloombergGPT[58]、FinGPT[59] 等）试图通过领域预训练提升金融任务表现，其价值在信息抽取类任务上较明确，在“直接预测收益”上的证据则弱得多。

（二）LLM 交易智能体。FinMem[62]、FinAgent、TradingAgents、StockAgent 等工作把 LLM 当作一个能记忆、能推理、能调用工具并做多步决策的智能体，让它在“看新闻–查指标–做决策–复盘”的循环里自主交易。这类工作是当前研究最热的区域，故事也最动听。近期也出现了一批试图把评测标准化的基准与长周期检验工作（StockBench[67]、InvestorBench[68]、长周期对照 [66]），方向对，但整体仍处早期。本文对其持保留态度，理由有三：其一，**评测协议普遍薄弱**，很多工作只在小样本、短区间上报告，且缺少与强基线的公平对照；其二，**数据泄漏难以排除**，LLM 的预训练语料若覆盖回测期，智能体的“先知”能力无法与“推理”能力分离；其三，**成本与可复现性问题突出**，LLM 的推理成本高、API 版本漂移导致同一代码在不同时间给出不同结果，直接破坏可复现性。

7.4 落地要素

- **严格的时间戳对齐。**所有文本必须带“市场首次可见时间”，并按该时间进入策略；用发布时间之前的信息是前瞻，用之后但含糊处理同样有问题。
- **训练语料截止日的红线。**任何用 LLM 做回测的工作，必须报告模型的知识截止日与样本期的关系，否则结论不可信。
- **幻觉与可追溯性。**LLM 生成的“事实”需要回到原文核验；用于交易的抽取结果应可溯源到具体文本片段。
- **成本核算。**逐条新闻调用 LLM 的成本远高于一次向量化，必须计入策略净收益。

7.5 复现状态与失效边界

具有讽刺意味的是，这一族是六族里可复现性最差的。词典法（Loughran–McDonald）与开源编码器（FinBERT 系列）的复现状态较好，因为词典与权重是固定的；而所有依赖商业 LLM 的工作，都面临“模型升级导致结果变化”的系统性问题——用 GPT-3.5 得到的结论，在 GPT-4 上未必复现，却没人愿意公开承认这一点。因此本文把“LLM 智能体交易”的整体证据强度定为**低**，并建议任何以此为据的落地尝试，必须自建前向（forward）样本——只相信模型截止日之后的数据。

失效边界除通用三条（信息耗尽、非平稳、成本）外，这一族还多一条**泄漏**：LLM 知道答案。本章要记住的一句话是：**大模型让“读懂文本”这件事的门槛大幅下降，但它同时让“回测里有**

多少是推理、有多少是背诵”变得极难分辨——在证明自己没有泄漏之前，任何 LLM 交易回测都只能算一个假设。

8 生成式模型：合成数据、场景生成与市场仿真

生成式模型在这一族里的角色和前几族不同：它不直接预测收益，也不直接做决策，而是**生产数据**。这个角色看似边缘，实则在交易链条上占着一个战略位置——因为前面几族都需要“样本”，而金融恰恰是最缺样本的领域。合成数据、场景生成与市场仿真，本质都是在试图人造样本，以缓解“历史只有一份”这条硬约束。

8.1 问题设定与三种用途

生成式模型（GAN、VAE、扩散模型）学习数据分布 p_{data} 并采样出新样本。在交易场景里，它有三种用法：

1. **数据增强**：为罕见事件（极端行情、流动性枯竭）或样本稀薄的资产/市场生成补充样本。
2. **场景与压力测试**：生成“可能发生但历史上还没发生”的市场路径，用于评估策略与组合的尾部表现。
3. **市场仿真**：构建一个能对交易行为作出反应的虚拟市场，为强化学习提供训练环境（第 6 章反复强调“模拟器就是一切”，生成式模型正是造模拟器的主要工具）。

8.2 方法与判据：什么叫“像”

金融时序生成有一把特殊的尺子，叫**风格化事实**（stylized facts）：收益的肥尾、波动率聚集、杠杆效应、绝对收益的长记忆、成交量的相关性等。一个好生成器必须在统计上复现这些事实，而不仅仅是“目测像”。

GAN 一代。Wiese 等（2020）[69] 提出的 Quant GANs 用（时序）卷积结构生成金融路径，并系统地以风格化事实作为验收标准，是这一方向被引用最多的工作之一。Takahashi 等（2019）[70] 用 GAN 建模金融时序。Yoon、Jarrett 与 van der Schaar（2019）[71] 的 TimeGAN 提出了“监督式”生成，把时序的动态与静态特征分开建模，是通用时序生成的代表。这一代的共同局限是训练不稳定、模式坍缩（只会生成少数几种路径），对齐尾部与波动率聚集尤其困难。

扩散模型一代。2023 年后，扩散模型因其训练更稳定、覆盖分布更广，被引入金融时序与订单流生成。相对于 GAN，扩散模型在复现尾部与多模态分布上更有优势，但采样成本高。这一代目前在交易上的公开、可复现证据仍有限。

与对冲/执行的结合。Buehler 等（2019）[72] 的 Deep Hedging 把生成模型与对冲策略联合训练：先生成市场路径，再在该分布上学一个对冲策略。它的价值在于把“不确定性建模”与“决策优化”接在一起，是生成式模型进入交易决策的干净范例。

市场仿真与智能体。另一条路是自底向上的仿真：用多智能体（agent-based）模型复现市场的涌现行为，ABIDES（Byrd 等 2020[73]）是较完整的开源离散事件市场模拟器。2023 年后，“生

成式智能体”（Park 等 2023[74]）的思路被迁移到市场仿真，用 LLM 扮演各类投资者，试图生成更真实的市场微结构。这类工作前景诱人，但目前主要是“生成更逼真的行为”，把它作为交易策略的可信验证环境还为时过早。

8.3 生成质量的评估清单

“像不像”需要一把可核查的尺子。参照文献里较通用的做法，本文把金融序列生成的质量评估归成四层，越往下越接近交易实用：

1. **边缘分布层**：收益的均值、方差、偏度与非正态（肥尾）；波动率（绝对收益）的自相关是否复现。这一层是必要条件，但很容易通过。
2. **联合结构层**：跨资产的相关系数矩阵、尾部相依（极端行情下的相关性上升）、波动率聚集与杠杆效应。这一层是多数生成器的分水岭。
3. **路径层**：长记忆性、跳跃与波动率聚集的时序形态、是否出现“平滑得不真实”的路径。GAN 的模式坍缩常在此暴露。
4. **下游任务层**：用合成数据训练一个策略或风险模型，看它在**真实数据**上的表现与用真实数据训练相比如何。这是唯一有交易意义的验收，却最常被跳过。

四层里，前三层可以自动化（一套统计检验即可），第四层需要真实数据的对照实验。一个常见误区是把前三层当成全部，于是得到一个“统计上很像、训练起来没用”的生成器。

8.4 生成器当训练环境时的耦合风险

生成式模型最诱人的用法，是“造一个环境给强化学习练”（第 6 章）。这条路有一个结构性风险：**策略会和生成器一起过拟合到生成器自身的偏差上**——生成器造不出的场景，策略自然学不会；生成器造得过多的场景，策略会学得过重。等到接上真实市场，两者一起失效。

缓解办法有三条，都不是新技术，而是纪律：

1. **生成器与策略交替更新，而不是一次冻结**。生成器一旦冻结，退化成了固定的历史回放；交替训练至少让环境随策略演化，逼近对抗关系。
2. **保留一段真实数据做最终裁判**。用它训练的策略都在合成环境里调参，但最终验收必须在未参与训练的真实留出段上完成，且口径与 P0–P2 一致。
3. **报告“分布外表现”**。明确给出策略在生成器覆盖范围之外（更极端波动、更低流动性）的表现；如果只在训练分布内有效，应直接判为“生成器偏差”，而不是“策略有效”。

一句话总结这条纪律：**用合成环境训练可以提高样本效率，但不能用它来证明策略有效；证明的那一步，永远要在真实数据上、用第 16 章的口径完成。**

8.5 落地要素

- **保真度评估要下沉到下游任务**。风格化事实通过了，不代表用它训练的策略就有效。必须做“下游任务保真”：用合成数据训练一个策略，看它在真实数据上的表现，而这一步恰恰最常被省略。
- **绝不能“用生成数据证明策略有效”**。如果策略在合成数据上表现好，只能说明策略适配了这个生成器的假设，不能说明它在真实市场有效。这是评估合成数据价值的红线。
- **尾部与相关性优先**。对交易而言，均值和方差容易对，难的是尾部与跨资产的依赖结构；而后者恰恰是风险管理的命脉。

8.6 复现状态与失效边界

Quant GANs[69] 与 TimeGAN[71] 有公开实现，复现状态为**部分复现**；扩散模型在金融生成上的工作复现状态普遍为**待复核**（缺代码、缺标准数据集）。失效边界最关键的一条是**“只学历史分布”**：生成模型的训练集是历史，它能造出的“极端场景”，其极端程度不可能超过它见过的范围——用一个在平静期训练的生成器做压力测试，会系统性低估风险，因为它根本没学过平静期之外的世界。这构成了一个悖论式的局限：**你最需要合成数据的时刻（从未发生过的危机），恰恰是生成模型最不可信的时刻。**

本章要记住的一句话是：**生成式模型缓解了“历史只有一份”的样本焦虑，却无法制造真正的、未曾发生过的历史——它能把已知的分布采样得更好，但把未知当作已知来生成，正是最危险的那类错误。**

9 图神经网络：关系结构与跨资产信息

前面几族大多把每只资产当成独立的样本：给资产 i 一组特征，预测资产 i 的收益。但市场的现实是资产之间相互牵连——供应商的坏消息会传到客户，同行业龙头的估值会带动板块，共同股东的流动性冲击会同时打中好几只票。图神经网络（GNN）的价值，就是把这层“谁和谁有关系”的结构显式地建进模型。

9.1 问题设定

把市场建成图 $\mathcal{G}=(\mathcal{V},\mathcal{E})$：节点 $\mathcal{V}$ 是资产/公司，边 $\mathcal{E}$ 是某种经济关系（行业、供应链、共同股东、新闻共现、价格相关）。GNN 通过消息传递更新节点表示：

$$h_i^{(l+1)}=\sigma\Big(\sum_{j\in\mathcal{N}(i)}\alpha_{ij}\,W\,h_j^{(l)}\Big), \tag{10}$$

α_{ij} 是边权（注意力，如 GAT[42]）。对交易而言，“图”提供了横截面之外的**结构性先验**：它规定了信息沿哪些通道传导，从而在低信噪比下减少搜索空间。

9.2 一条从“关系”到“可交易”的证据线

经济关系的可预测性（前 GNN 时代）。Cohen 与 Frazzini（2008）[15] 发现供应链上的动量会从供应商传导到客户，是“关系 → 可交易收益”的经典证据。这条证据很重要，因为它说明图上的边不只是建模便利，而是有真实的经济内容。

GNN 进入股票预测。Feng 等（2019）[76] 的时序关系排序模型把公司间的时序关系建进排序学习；Chen、Wei 与 Huang（2018）[77] 用图卷积引入公司关系；Matsunaga、Suzumura 与 Takahashi（2019）[75] 系统检验了 GNN 在股票预测上的表现，是较早的严格对照研究之一。这些工作确认了一个结论：**关系结构确实带来增量，但增量的大小高度依赖于“边是怎么定义的”。**

注意力与异质图。Xu 等（2021）[78] 的 HATS 用层次化图注意力建模个股与概念/行业的多层关系；Wang 等（2021）[79] 用时序异质图同时建模多种关系；Sawhney 等（2020）[80] 把社交媒体文本与公司相关图结合做股价动向预测。这一代的趋势是把“单一关系图”升级成“多关系、时变的异质图”，逼近真实市场的复杂度。

9.3 边怎么定义：五种做法的取舍

这一族最实际、也最少被系统讨论的问题，是“边从哪来”。不同的边构造方式，直接决定了模型能捕捉什么、以及会不会制造假增量。

表 4: 常见边构造方式的取舍

边类型	构造方式	优点	主要风险
行业/板块	官方分类标签	稳定、全市场可观测	粒度粗，信息多已被价格反映
供应链	供应商–客户披露	经济含义强、传导机制清楚	披露稀疏、滞后，覆盖有限
共同股东/机构持仓	13F 等持仓数据	反映资金联动	财报/持仓有季度级滞后
价格相关	滚动相关系数	覆盖全、易获得	信息已在价内，易产生假增量
新闻/文本共现	语义相似度建边	覆盖广、更新快	噪声大，时点对齐困难

取舍原则很朴素：**越有经济含义的边越可信，但越稀疏、越滞后；越容易构造的边越有“假增量”风险，因为价格相关的信息大多已经被价格吸收。**因此一个务实的做法是“多种边并用 + 分别做消融”，确认增量到底来自哪一种边——如果去掉价格相关边后增量消失，那这个“图”的贡献就值得怀疑。

9.4 一个可执行的关系消融协议

“图有没有用”这个问题，光靠报告一个更好的指标回答不了，需要一套消融设计。建议按下面四步做，并用同一口径（同数据、同成本、同评测协议）比较：

1. **基线**：与目标模型同架构、但不含任何图结构（把邻居信息去掉）。这是判断“图是否带来增量”的唯一参照。
2. **只加经济含义边**：仅用行业分类、供应链披露、共同股东这类有经济内容的边重建模型。
3. **再加价格相关边**：在第 2 步基础上加入滚动相关边，看是否有进一步提升。
4. **安慰剂检验**：把边随机重连（保持度分布）后重跑。若“随机图”也带来同样提升，说明所谓的增量来自模型容量而非关系信息。

判定规则可以直接写死：**只有当第 2 步显著优于第 1 步、且第 4 步不显著优于第 1 步时，图结构的贡献才算成立**。如果增量主要来自第 3 步的价格相关边，则应如实报告“增量来自价格相关性的再编码”，而不是“关系信息带来了新 alpha”——这两句话在交易上含义完全不同，前者几乎必然在扣成本后消失。

9.5 落地要素

- **边的时点必须可观测**。用“今天的行业分类”去回测十年前，是典型的前瞻偏差——公司的主营、供应链关系都在变。行业分类、供应链披露、共同股东名单，都必须用当时已知的版本。
- **边不能太“软”**。用价格相关性构图最省事，但价格相关本身已被价格反映，用它会制造“信息已在价内”的假增量。有经济含义的边（供应链、共同股东）更可信也更难得。
- **图规模与计算成本**。全市场图的消息传递计算量随节点数增长，日频更新在工程上需要权衡。

9.6 复现状态与失效边界

这一族多数工作在公开数据集（如基于新闻共现的公司关系集）上评测，但**数据集的时间划分、是否含退市股、关系是否 point-in-time，往往披露不足**，导致“同一方法不同论文结论相反”。因此复现状态整体为**部分复现**：架构可复现，结论不可直接比较。

失效边界有两条比较特殊。第一，**关系被价格吸收**：如果某种关系早已被市场定价，则把它写进图不产生新信息，只增加过拟合自由度。第二，**图是人为选定的**：你决定建哪些边，就等于先验地决定了信息沿哪些通道流动——**把假设藏进图结构，是这一族最容易被忽视的自欺**。本章要记住的一句话是：**图的价值在于把有经济含义的关系显式写进模型，而它的风险也恰在于——你写进去的关系，可能只是你自己的假设。**

10 另类数据与微观结构：信号的上游

前九章讨论的方法，都需要“特征”。这一章讨论特征从哪来。另类数据（alternative data）和微观结构数据是这一代量化最重要的信息增量来源——它们不是新算法，而是**把原本没有被数字化、或者没有被充分利用的信息，变成可计算的特征**。用第 2 章的话说，它们动的是“信息存量的天花板”，而不是“把已有信息利用得更充分”。

10.1 另类数据的谱系

- **卫星与遥感**：停车场车流量、油罐储量、夜间灯光、农作物长势。Katona 等（2018）[83] 讨论了卫星数据进入资本市场的机制与后果。
- **消费与支付**：信用卡交易、App 使用、电商价格与库存、外卖订单。
- **人力与组织**：招聘职位数、员工流动、专利与研发活动。Zhu（2019）[81] 研究了大数据（含招聘与员工评价数据）如何影响公司治理。
- **众包与网络**：众包盈利预测、社交媒体、搜索引擎热度。Jame 等（2016）[82] 检验了众包盈利预测的预测力。
- **资金与持仓流**：ETF 申赎、机构持仓、期权暗池流。

10.2 微观结构：最接近“物理真实”的数据

如果要在这份综述里挑一类数据，说它“最适合与机器学习结合且最可信”，会是限价订单簿与逐笔成交。原因有三：样本量以十亿计；生成机制相对稳定（撮合规则是明确的）；且预测目标与执行决策直接挂钩。DeepLOB[36]、Tsantekidis 等（2017）[37] 一类工作证明了深度学习能从订单簿中提取出可用的短时价格信息；Ntakaris 等（2018）[38] 提供了公开基准数据集，使得这一方向的复现性在六族之外一枝独秀。订单簿数据的“贵”在于获取与存储成本，而非稀缺——交易所逐笔数据可以买，只是很贵。

10.3 落地要素：另类数据的四个隐性成本

另类数据看起来是“多一类特征”这么简单，实际落地要跨越四道关：

1. **许可与合规**。数据的使用权（尤其涉及个人信息的信用卡、定位数据）有严格的法律边界，很多数据源在合规审查下不可用。
2. **覆盖率与偏差**。一种支付数据可能只覆盖某一人群或某一地区，用它预测全体公司，会引入样本选择偏差。
3. **时点与修订**。数据源本身可能事后修订历史值，若不保存“当时看到的那份”，就会产生前视偏差。
4. **成本与容量**。另类数据订阅费用高昂，且信号容量（能承载的资金规模）有限，必须与成本一起评估。

10.4 制度约束的特殊性：以 A 股为例

前文的讨论以美股语境为主，但交易制度会把同一套方法的结果改得面目全非。中文市场的读者尤其需要注意下面几点差异。

- **涨跌停**：主板 ±10%，创业板与科创板 ±20%。触及涨跌停的股票当日不可买入（涨停）或不可卖出（跌停）；在极端行情中大量个股同时触板，组合调仓会在最需要它的时刻被冻结。若回测忽略这一点，等于假设自己在最拥挤的时刻仍能自由成交。

- **T+1**：当日买入的股票次日才能卖出。任何依赖日内反转或快速止盈的短周期策略，在 A 股必须重写持有期约束。
- **融券约束**：个股做空渠道有限、成本高、券源不稳。教科书式的“多空对称”组合在 A 股往往不可实现，多数策略实际只能做多头增强或以股指期货对冲。
- **散户占比与情绪**：情绪与舆情类信号在 A 股的边际信息可能更强，但衰减也更快；这既解释了部分信号的有效性，也提示其易拥挤。
- **数据可得性**：本地通达信日线（含主力连续与持仓量）可作为低成本的历史底座；财务数据必须按实际披露日对齐——A 股披露集中在特定窗口，容易在截面上造成“同一时点信息高度相关”，进而高估模型的独立信息量。

复现上的含义很直接：把在美股验证过的方法搬到 A 股，必须重做制度掩码与成本口径（对应第 16 章 P0 的“交易制度掩码”条款）；不重做，结论之间不可比，也不可用。

10.5 复现状态与失效边界

另类数据是六族之外可复现性最差的一类，原因与算法无关：数据本身是私有的。私有数据上的结果，外部研究者无法独立验证，只能依赖发表方的自述。这不是学术缺陷，而是这类研究的天然属性，但它意味着**任何基于私有另类数据的高收益声明，都应被视为“无法独立验证的经验”而非“科学结论”。**

失效边界里最该警惕的是**衰减速度**：另类数据一旦被证明有效，就会有更多资金涌入（Grossman–Stiglitz 的老故事），超额收益迅速收窄。卫星图像、信用卡数据在 2010 年代中后期曾是显著 alpha，如今多数已相当拥挤。相反，微观结构数据因为需要工程能力与基础设施，衰减相对慢，这也是它长期有价值的原因。本章要记住的一句话是：**另类数据卖的不是数据，是时间差——它值钱只因为你比别人早用上，而一旦人人都在用，它就变成了新的“公开信息”并被价格吞掉。**

11 交易环节的横向整合：从预测到仓位、执行与风控

前面按方法族竖着切了一遍，这一章横着切：沿一条完整策略的生命周期，看每个环节上 AI 做了什么、环节之间又怎么互相牵制。写这一章的理由是，**落地失败常常不发生在上游的预测，而发生在预测到仓位、仓位到成交、成交到风控这几段衔接处。**

11.1 组合构建：把预测翻译成权重

一个微弱的收益预测，要靠组合优化放大成可观的夏普，就得处理均值–方差框架里那个老问题：μ 的估计误差被 Σ^{-1} 放大（“误差最大化”）。机器学习在这一环的贡献有三条路径。

第一是**更稳健的协方差与收缩估计**。Ledoit 与 Wolf（2004）[12] 的收缩估计把样本协方差向结构化目标收缩，显著降低高维下的估计噪声，这几乎是所有现代组合管线的标配。

第二是**端到端学习组合权重**。Zhang、Zohren 与 Roberts（2020）[85] 直接用深度网络输出权

重并优化组合效用，Costa 与 Iyengar（2022）[84] 提出端到端风险预算组合。端到端的吸引力在于它不再“先预测、再优化”两段分家，而把交易成本与风险预算直接写进目标；代价是可解释性下降、对训练数据的依赖加深。

第三是**把约束写进学习**。现实里权重受再多约束——不卖空、行业上限、单票上限、换手限制——两段式做法无法保证预测最优能转成可行权重。约束感知的学习（在损失里加惩罚、或直接参数化可行域）是这一环的前沿。

这里有一条容易被忽视的量化关系：**组合的换手率由预测的“信噪比”和优化器的“锐度”共同决定**。预测噪声大时，最优权重对噪声极度敏感，换手率飙升；很多“理论夏普很高”的策略，成本后归零，原因就在这。第 21.3 节给出了这条关系的一组实测对照：同一批特征里，年化换手 14 倍的候选在成本后仍有夏普 1.01，而 182 倍的候选被压到 -1.49——换手相差一个数量级，结局相反。

11.2 一个成本分解的示意计算

为了把“摩擦如何吃掉 alpha”说得具体，这里给一个**示意性**计算——所有假设都明示，它是算术演示，不是实证结果。

设日度截面信号 IC$=0.05$，个股日收益的截面标准差 $\sigma_{cs}=2\%$，组合转移系数 $\tau\approx 0.5$，则组合的期望毛收益约为

$$\mathbb{E}[r_{\text{gross}}/\text{日}] \approx \text{IC}\times\sigma_{cs}\times\tau = 0.05\times 0.02\times 0.5 = 5\text{bp}. \tag{11}$$

成本按固定 5bp 加平方根冲击计算，冲击率 $=0.02\sqrt{\text{参与率}}$；取参与率 1%（对应 ADV 10^9、单票约 10^7），得冲击率 20bp，于是每次调仓的成本率 $=25\text{bp}\times$ 单边换手率。三种调仓频率下：

留意这里 ADV $=10^9$ 只是**示意假设**，不是普适值。ADV 该取什么，取决于交易的标的：第 21.3 节在 A 股样本上取逐个股成交额中位数，其中位数为 7.46×10^7 元，比这个示意值小一个量级；参与率随之抬高，冲击成本按平方根律放大。用常数 ADV 套所有标的，是最容易把成本算轻的一种做法。

表 5: 同一信号在不同调仓频率下的净收益（示意计算）

调仓频率	单边换手率	持有期毛收益	持有期成本	持有期净收益
每日	40%	5.0bp	10.0bp	-5.0bp
每周	15%	25.0bp	3.8bp	$+21.2$bp
每月	6%	105.0bp	1.5bp	$+103.5$bp

需说明：表中假设信息衰减慢，因而毛收益随持有期近似线性增长；若信号半衰期很短（例如两三天），长持有期的毛收益会被显著高估，结论需重算。即便如此，方向性结论是稳的——**同一个信号，在日频下净收益为负，降频到周频以上才转正**。这说明“信号好不好”与“频率选得对不对”是两回事。AI 最常犯的错，恰恰是把一个只有周频价值的信号，放到日频上去交易，再用样本内的零成本回测证明它“有效”。

11.3 交易执行：摩擦的管理学

执行环节的目标只有一个：把想交易的量，以尽可能低的总成本变成成交。总成本是时机风险与冲击成本的折中（Almgren–Chriss[8]）。这一环上 AI 的作用是把解析解换成数据驱动的动态策略，落地要点有三：

- **冲击模型必须内生化**。市场冲击大致服从平方根律（Grinold & Kahn 的工程经验与 Almgren 等 2005[9] 的直接估计都支持这一形态），策略若假设线性冲击，会系统性高估大单的可执行性。
- **用真实的订单簿数据训练**。逐笔成交与订单簿（第 10 章）是执行策略唯一可信的训练场。
- **把执行嵌入策略而非事后附加**。最优做法是让信号直接知道“交易它会花多少成本”，否则会生成大量“看起来能赚、扣完成本为负”的信号。

11.4 风险管理：AI 的另一条战线

风险管理不比信号生成简单，而且它更依赖对“尾部”的刻画，而尾部恰恰是样本最少的地方。

波动率与相关性建模。GARCH 一族（Bollerslev 1986[6]）与现代已实现波动率模型是基础；机器学习改进的是对波动率与相关性的动态预测，以及在高维下的稳健估计。

尾部风险。CVaR（Rockafellar & Uryasev 2000[10]）与极值理论（McNeil & Frey 2000[11]）给出了尾部风险的度量与估计框架；机器学习（分位数回归、深度分位数网络）让条件尾部的预测能吸收更多特征。这一环的困难在于**尾部事件样本极少，任何在此处的过拟合都极其危险**。

回撤控制与波动率目标化。Chekhlov、Uryasev 与 Zabarankin（2005）[13] 提出回撤约束的优化；Harvey 等（2018）[14] 系统论证了波动率目标化对组合的影响。监督式/强化式的回撤控制是近年的活跃方向，但其样本外稳健性同样受制于尾部样本稀缺。

制度识别。Hamilton（1989）[7] 的 regime-switching 模型与基于聚类/HMM 的方法，用来判断当前市场处于哪种制度，进而切换风险预算。这一环与本文反复出现的“非平稳”约束直接对应——**制度识别做得好，等于给所有上游模型加了一个“当前学到的规律还成立吗”的开关**。

11.5 环节耦合：本文最想强调的一点

把五个环节放在一起看，会发现它们的优化目标互相冲突，而 AI 若只在单环节优化，往往会把冲突放大到别的环节：

这张表想说的是：**端到端学习之所以被寄予厚望，正是因为它有机会在同一个目标下协调这些冲突；但它之所以难，也正因为它把这些冲突全部塞进了一个更难训练、更难诊断的黑箱**。对落地而言，一个务实的态度是：**理解耦合、显式地在上游为目标函数留出下游的代价，而不是把全部希望寄托在端到端上**。

本章要记住的一句话是：**一笔交易的成败，往往不在你能不能预测对方向，而在你把预测翻译成仓位、把仓位执行成成交、再把暴露管到明天的这三段衔接里——而这三段，恰恰是论文最**

表 6: 交易环节之间的典型冲突

耦合对	冲突	后果
信号 vs 执行	追求信号锐度会提高换手	成本吞噬 alpha；低信噪比下尤甚
信号 vs 风控	追求收益会集中在高暴露	回撤放大，尾部风险上升
组合 vs 执行	连续权重在小资金/高成本下不可行	理论组合与可实现组合差距大
风控 vs 收益	波动率目标化会削峰	长期夏普可能改善但牛市落后
制度识别 vs 上游	制度切换时上游模型失效	若不联动，模型在错误制度上继续下注

不愿意细写的地方。

12 证据表（核心来源清单）

证据表由两张以 **E 编号**为主键的子表构成：证据表 A 记元数据，证据表 B 记评测属性；两张表用同一套 E 编号互指，比较矩阵（第 13 章）的每一行也标注对应的 E 编号。这样拆表是为了让“来源是什么”与“评测是否严谨”两条信息都能在同一宽度内读清，而不必把两者挤进一张宽表。

核验等级约定（两级）：已核验 =DOI/arXiv/官方链接与元数据互证；部分核验 = 元数据确认、样本区间或参数细节待全文复核。**已核验仅指元数据层，不代表结论可靠**——结论是否可靠请对照证据表 B 的“复现状态”列。来源类型标注该条目是期刊、会议、预印本还是专著，便于读者自行判断同行评审状态。

链接说明：链接指向 DOI、arXiv 或官方来源；对无 DOI 的经典条目（专著、会议、杂志）标注“无 DOI”，不附替代链接；少数经典条目的链接为开放获取副本，已在“来源”列注明“OA 副本”。

表 7: 证据表 A：元数据

ID	族	标题（作者，年）	来源	年	类型	核验
E1	原理	Portfolio Selection（Markowitz, 1952）	DOI	1952	期刊	已核验
E2	原理	Efficient Capital Markets: A Review of Theory and Empirical Work（Fama, 1970）	DOI	1970	期刊	已核验
E3	原理	On the Impossibility of Informationally Efficient Markets（Grossman Stiglitz, 1980）	OA 副本	1980	期刊	已核验
E4	原理	Continuous Auctions and Insider Trading（Kyle, 1985）	DOI	1985	期刊	已核验
E5	原理	The Limits of Arbitrage（Shleifer Vishny, 1997）	DOI	1997	期刊	已核验

表 7: 证据表 A：元数据

ID	族	标题（作者，年）	来源	年	类型	核验
E6	原理	Mean Reversion Pays, but Costs（Martin Schöneborn, 2011）	arXiv	2011	预印本	已核验
E7	监督	Empirical Asset Pricing via Machine Learning（Gu 等, 2020）	DOI	2020	期刊	已核验
E8	监督	Autoencoder Asset Pricing Models（Gu 等, 2021）	DOI	2021	期刊	已核验
E9	监督	Deep Learning in Asset Pricing（Chen 等, 2024）	DOI	2024	期刊	已核验
E10	监督	The Virtue of Complexity in Return Prediction（Kelly 等, 2024）	DOI	2024	期刊	已核验
E11	监督	Taming the Factor Zoo: A Test of New Factors（Feng 等, 2020）	DOI	2020	期刊	已核验
E12	监督	Deep Neural Networks, Gradient-Boosted Trees, Random Forests: Statistical Arbitrage on the S&P 500（Krauss 等, 2017）	DOI	2017	期刊	已核验
E13	深度	Deep Learning with Long Short-Term Memory Networks for Financial Market Predictions（Fischer Krauss, 2018）	DOI	2018	期刊	已核验
E14	深度	DeepLOB: Deep Convolutional Neural Networks for Limit Order Books（Zhang 等, 2019）	DOI	2019	期刊	已核验
E15	深度	Forecasting Stock Prices from the Limit Order Book Using Convolutional Neural Networks（Tsantekidis 等, 2017）	DOI	2017	会议	已核验
E16	深度	Benchmark Dataset for Mid-Price Forecasting of Limit Order Book Data with Machine Learning Methods（Ntakaris 等, 2018）	DOI	2018	期刊	已核验
E17	深度	Deep Learning for Limit Order Books（Sirignano, 2019）	DOI	2019	期刊	已核验
E18	深度	Attention Is All You Need（Vaswani, 2017）	arXiv	2017	会议	已核验
E19	深度	Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting（Lim 等, 2021）	arXiv	2021	期刊	已核验
E20	深度	Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting（Zhou, 2021）	arXiv	2021	会议	已核验
E21	深度	Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting（Wu 等, 2021）	arXiv	2021	会议	已核验
E22	深度	Are Transformers Effective for Time Series Forecasting?（Zeng 等, 2023）	arXiv	2023	会议	已核验
E23	深度	Chronos: Learning the Language of Time Series（Ansari, 2024）	arXiv	2024	期刊	已核验
E24	深度	A Decoder-Only Foundation Model for Time-Series Forecasting（Das 等, 2024）	arXiv	2024	会议	已核验
E25	深度	Lag-Llama: Towards Foundation Models for Probabilistic Time Series Forecasting（Rasul, 2023）	arXiv	2023	预印本	已核验

表 7: 证据表 A：元数据

ID	族	标题（作者，年）	来源	年	类型	核验
E26	强化	Deep Direct Reinforcement Learning for Financial Signal Representation and Trading（Deng 等, 2017）	DOI	2017	期刊	已核验
E27	强化	A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem（Jiang 等, 2017）	arXiv	2017	预印本	已核验
E28	强化	FinRL: A Deep Reinforcement Learning Library for Automated Stock Trading in Quantitative Finance（Liu, 2020）	arXiv	2020	预印本	已核验
E29	强化	Reinforcement Learning for Optimized Trade Execution（Nevmyvaka 等, 2006）	DOI	2006	会议	已核验
E30	强化	Market Making via Reinforcement Learning（Spooner 等, 2018）	arXiv	2018	会议	已核验
E31	强化	Deep Reinforcement Learning for Market Making in Corporate Bonds（Guéant Manziuk, 2019）	arXiv	2019	期刊	已核验
E32	NLP	Giving Content to Investor Sentiment: The Role of Media in the Stock Market（Tetlock, 2007）	DOI	2007	期刊	已核验
E33	NLP	Investor Sentiment and the Cross-Section of Stock Returns（Baker Wurgler, 2006）	DOI	2006	期刊	已核验
E34	NLP	When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks（Loughran McDonald, 2011）	DOI	2011	期刊	已核验
E35	NLP	FinBERT: Financial Sentiment Analysis with Pre-Trained Language Models（Araci, 2019）	arXiv	2019	预印本	已核验
E36	NLP	FinBERT: A Pretrained Language Model for Financial Communications（Yang 等, 2020）	arXiv	2020	预印本	已核验
E37	NLP	FinBERT: A Large Language Model for Extracting Information from Financial Text（Huang 等, 2023）	DOI	2023	期刊	已核验
E38	NLP	BloombergGPT: A Large Language Model for Finance（Wu, 2023）	arXiv	2023	预印本	已核验
E39	NLP	FinGPT: Open-Source Financial Large Language Models（Yang 等, 2023）	arXiv	2023	预印本	已核验
E40	NLP	Can ChatGPT Forecast Stock Price Movements? Return Predictability and Large Language Models（Lopez-Lira Tang, 2023）	DOI	2023	期刊	已核验
E41	NLP	Predicting Returns with Text Data（Ke 等, 2019）	DOI	2019	期刊	已核验
E42	NLP	FinMem: A Performance-Enhanced LLM Trading Agent with Layered Memory and Character Design（Yu 等, 2023）	arXiv	2023	预印本	已核验
E43	NLP	Large Language Model Agent in Financial Trading: A Survey（Ding, 2024）	arXiv	2024	预印本	已核验

表 7: 证据表 A：元数据

ID	族	标题（作者，年）	来源	年	类型	核验
E44	NLP	Assessing Look-Ahead Bias in Stock Return Predictions Generated by GPT Sentiment Analysis（Glasserman Lin, 2023）	DOI	2023	期刊	已核验
E45	NLP	Can LLM-Based Financial Investing Strategies Outperform the Market in the Long Run?（Li, 2025）	arXiv	2025	预印本	部分核验
E46	NLP	StockBench: Can LLM Agents Trade Stocks Profitably in Real-World Markets?（Wang, 2025）	arXiv	2025	预印本	部分核验
E47	NLP	INVESTORBENCH: A Benchmark for Financial Decision-Making Tasks with LLM-Based Agent（Li, 2025）	DOI	2025	会议	已核验
E48	生成	Quant GANs: Deep Generation of Financial Time Series（Wiese 等, 2020）	DOI	2020	期刊	已核验
E49	生成	Modeling Financial Time-Series with Generative Adversarial Networks（Takahashi 等, 2019）	DOI	2019	期刊	已核验
E50	生成	Time-Series Generative Adversarial Networks（Yoon 等, 2019）	无 DOI	2019	会议	已核验
E51	生成	Deep Hedging（Buehler 等, 2019）	arXiv	2019	期刊	已核验
E52	生成	ABIDES: Towards High-Fidelity Market Simulation for AI Research（Byrd 等, 2020）	arXiv	2020	预印本	已核验
E53	生成	Generative Agents: Interactive Simulacra of Human Behavior（Park, 2023）	arXiv	2023	会议	已核验
E54	图网络	Economic Links and Predictable Returns（Cohen Frazzini, 2008）	DOI	2008	期刊	已核验
E55	图网络	Graph Attention Networks（Veličković 等, 2018）	arXiv	2018	会议	已核验
E56	图网络	Exploring Graph Neural Networks for Stock Market Predictions with Rolling Window Analysis（Matsunaga 等, 2019）	arXiv	2019	预印本	已核验
E57	图网络	Temporal Relational Ranking for Stock Prediction（Feng 等, 2019）	DOI	2019	期刊	已核验
E58	图网络	Incorporating Corporation Relationship via Graph Convolutional Neural Networks for Stock Price Prediction（Chen 等, 2018）	DOI	2018	会议	已核验
E59	图网络	HATS: A Hierarchical Graph Attention Network for Stock Movement Prediction（Xu, 2019）	arXiv	2019	预印本	已核验
E60	图网络	Temporal and Heterogeneous Graph Neural Network for Financial Time Series Prediction（Wang, 2021）	arXiv	2021	预印本	已核验
E61	图网络	Deep Attentive Learning for Stock Movement Prediction from Social Media Text and Company Correlations（Sawhney 等, 2020）	DOI	2020	会议	已核验
E62	另类	Big Data as a Governance Mechanism（Zhu, 2019）	DOI	2019	期刊	已核验
E63	另类	The Value of Crowdsourced Earnings Forecasts（Jame 等, 2016）	DOI	2016	期刊	已核验

表 7: 证据表 A：元数据

ID	族	标题（作者，年）	来源	年	类型	核验
E64	另类	On the Capital Market Consequences of Big Data: Evidence from Outer Space（Katona 等, 2018）	DOI	2018	期刊	已核验
E65	组合执行	Generalized Autoregressive Conditional Heteroskedasticity（Bollerslev, 1986）	DOI	1986	期刊	已核验
E66	组合执行	A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle（Hamilton, 1989）	DOI	1989	期刊	已核验
E67	组合执行	Optimal Execution of Portfolio Transactions（Almgren Chriss, 2000）	DOI	2000	期刊	已核验
E68	组合执行	Direct Estimation of Equity Market Impact（Almgren 等, 2005）	无 DOI	2005	期刊	已核验
E69	组合执行	Optimization of Conditional Value-at-Risk（Rockafellar Uryasev, 2000）	DOI	2000	期刊	已核验
E70	组合执行	Estimation of Tail-Related Risk Measures for Heteroscedastic Financial Time Series（McNeil Frey, 2000）	DOI	2000	期刊	已核验
E71	组合执行	A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices（Ledoit Wolf, 2004）	DOI	2004	期刊	已核验
E72	组合执行	Drawdown Measure in Portfolio Optimization（Chekhlov 等, 2005）	DOI	2005	期刊	已核验
E73	组合执行	The Impact of Volatility Targeting（Harvey 等, 2018）	DOI	2018	期刊	已核验
E74	组合执行	Algorithmic and High-Frequency Trading（Cartea 等, 2015）	无 DOI	2015	专著	已核验
E75	组合执行	End-to-End Risk Budgeting Portfolio Optimization with Neural Networks（Costa Iyengar, 2022）	DOI	2022	期刊	已核验
E76	组合执行	Deep Learning for Portfolio Optimization（Zhang 等, 2020）	arXiv	2020	期刊	已核验
E77	评测	A Reality Check for Data Snooping（White, 2000）	DOI	2000	期刊	已核验
E78	评测	Data-Snooping, Technical Trading Rule Performance, and the Bootstrap（Sullivan 等, 1999）	DOI	1999	期刊	已核验
E79	评测	... and the Cross-Section of Expected Returns（Harvey 等, 2016）	DOI	2016	期刊	已核验
E80	评测	Does Academic Research Destroy Stock Return Predictability?（McLean				

表 7： 证据表 A：元数据

ID	族	标题（作者，年）	来源	年	类型	核验
	Pontiff,	DOI	2016	期刊	已核	
	2016）				验	
E81	评测	Is There a Replication Crisis in Finance?（Jensen 等,	DOI	2023	期刊	已核
		2023）				验
E82	评测	Pseudo-Mathematics and Financial Charlatanism: The	DOI	2014	期刊	已核
		Effects of Backtest Overfitting on Out-of-Sample				验
		Performance（Bailey 等, 2014）				
E83	评测	The Deflated Sharpe Ratio: Correcting for Selection Bias,				
		Backtest Overfitting, and Non-Normality（Bailey				
	Prado,	DOI	2014	期刊	已核	
	2014）				验	
E84	评测	The Probability of Backtest Overfitting（Bailey 等, 2016）	DOI	2016	期刊	已核
						验
E85	评测	Advances in Financial Machine Learning（Prado, 2018）	无 DOI	2018	专著	已核
						验
E86	评测	What Survives Honest Evaluation? Leakage-safe,	arXiv	2026	预印	部分
		Search-aware Assessment of LLM-Driven Trading			本	核验
		（Ratnaike, 2026）				
E87	评测	The Corporate Bond Factor Replication Crisis	arXiv	2026	预印	部分
		（Dickerson, 2026）			本	核验
E88	工具	Qlib: An AI-Oriented Quantitative Investment Platform	arXiv	2020	预印	已核
		（Yang, 2020）			本	验
E89	工具	Deep Learning for Financial Applications: A Survey	DOI	2020	期刊	已核
		（Sezer 等, 2020）				验
E90	工具	Machine Learning in Finance: A Topic Modeling	DOI	2021	期刊	已核
		Approach（Aziz 等, 2021）				验

表 A 中“关键定位”列（见表 B）的填写规范：限定为该条目在本文论证中承担的角色（如“机制来源”“基准”“失效边界例证”），不作质量评价，以免把主观判断混入事实栏。

表 8： 证据表 B：纳入理由与评测属性

ID	关键定位（纳入理由）	样本外检验	成本口径	复现状态
E1	现代组合理论起点	不适用	不适用	不适用（理论）
E2	有效市场三档定义	不适用	不适用	不适用（理论）
E3	信息效率悖论（OA 版本链接）	不适用	不适用	不适用（理论）
E4	价格冲击系数　与信息租金耗散	不适用	不适用	不适用（理论）
E5	套利限制	不适用	不适用	不适用（理论）

表 8: 证据表 B：纳入理由与评测属性

ID	关键定位（纳入理由）	样本外检验	成本口径	复现状态
E6	均值回归成本敏感性	不适用	解析式	可复现（理论）
E7	机器学习资产定价基准	滚动前向	未报告	部分复现
E8	自编码条件因子模型	时间切分	未报告	部分复现
E9	无套利结构注入网络	时间切分	未报告	部分复现
E10	复杂性红利（争议）	时间切分	未报告	未核实
E11	双重选择 Lasso	不适用（方法论）	不适用	可复现
E12	三类模型统计套利对照	时间切分	未报告	部分复现
E13	LSTM 方向预测与回测	时间切分	报告成本敏感性	部分复现
E14	订单簿 CNN-LSTM	时间切分	未报告	部分复现
E15	订单簿 CNN	时间切分	未报告	部分复现
E16	FI-2010 公开订单簿基准	标准划分	不适用	可复现
E17	空间-订单簿深度网络	时间切分	未报告	部分复现
E18	注意力机制	标准划分	不适用	可复现
E19	可解释多步时序预测	标准划分	不适用	可复现
E20	长序列 Transformer	标准划分	不适用	可复现
E21	分解式长序列预测	标准划分	不适用	可复现
E22	线性基线反证	标准划分	不适用	可复现
E23	时序基础模型（零样本）	标准划分	不适用	可复现
E24	时序基础模型 TimesFM	标准划分	不适用	可复现
E25	概率时序基础模型	标准划分	不适用	可复现
E26	直接 RL 信号与交易	时间切分	未报告	部分复现
E27	端到端组合管理 RL	时间切分	报告费率	部分复现
E28	RL 交易开源框架	时间切分	可配置	部分复现
E29	执行 RL 开山	时间切分	内生化	部分复现
E30	RL 做市	时间切分	内生化	部分复现
E31	深度 RL 做市	时间切分	内生化	部分复现
E32	媒体情绪与价格	时间切分	不适用	部分复现
E33	情绪指数	时间切分	不适用	部分复现
E34	金融情感词典	标准划分	不适用	可复现
E35	金融情感 BERT	标准划分	不适用	可复现
E36	金融语料继续预训练	标准划分	不适用	可复现
E37	FinBERT 信息抽取	标准划分	不适用	可复现
E38	金融领域大模型	标准划分	不适用	部分复现
E39	开源金融大模型	标准划分	不适用	部分复现
E40	LLM 新闻信号回测	时间切分	未报告	不可复现
E41	文本预测收益	时间切分	未报告	部分复现
E42	LLM 交易智能体	时间切分	未报告	不可复现
E43	LLM 交易智能体综述	不适用（综述）	不适用	不适用
E44	LLM 前视偏差实测	时间切分	不适用	可复现
E45	LLM 投资策略长周期评测	前向留出	未报告	未核实

表 8: 证据表 B：纳入理由与评测属性

ID	关键定位（纳入理由）	样本外检验	成本口径	复现状态
E46	LLM 交易智能体基准	前向留出	未报告	未核实
E47	金融决策 LLM 基准	标准划分	不适用	部分复现
E48	金融时序 GAN 生成	风格化事实检验	不适用	部分复现
E49	GAN 建模金融时序	时间切分	不适用	部分复现
E50	监督式时序生成	标准划分	不适用	部分复现
E51	生成模型 + 对冲联合训练	时间切分	交易成本	部分复现
E52	离散事件市场仿真器	不适用	内生化	部分复现
E53	生成式智能体	不适用	不适用	可复现
E54	供应链动量传导	时间切分	未报告	部分复现
E55	图注意力网络	标准划分	不适用	可复现
E56	GNN 股票预测滚动窗对照	时间切分	未报告	部分复现
E57	时序关系排序	时间切分	未报告	部分复现
E58	公司关系图卷积	时间切分	未报告	部分复现
E59	层次图注意力	时间切分	未报告	部分复现
E60	时序异质图	时间切分	未报告	部分复现
E61	文本 + 公司关联图	标准划分	不适用	部分复现
E62	大数据与公司治理	时间切分	不适用	不可复现
E63	众包盈利预测	时间切分	不适用	部分复现
E64	卫星大数据与资本市场	时间切分	不适用	不可复现
E65	GARCH 波动率模型	不适用	不适用	可复现
E66	制度切换模型	不适用	不适用	可复现
E67	最优执行解析解	不适用	解析式	可复现（理论）
E68	平方根冲击律的经验估计	不适用	冲击模型	部分复现
E69	CVaR 优化	不适用	不适用	可复现
E70	极值理论尾部风险	未报告	不适用	可复现
E71	协方差收缩估计	未报告	不适用	可复现
E72	回撤约束优化	不适用	不适用	可复现
E73	波动率目标化	时间切分	不适用	可复现
E74	算法与高频交易理论专著	不适用	解析式	可复现（理论）
E75	端到端风险预算	时间切分	报告	部分复现
E76	端到端组合学习	时间切分	报告费率	部分复现
E77	Reality Check 数据窥探检验	不适用（方法论）	不适用	可复现
E78	近八千条规则联合检验	不适用（方法论）	不适用	可复现
E79	多重检验 t>3 门槛	不适用（方法论）	不适用	可复现
E80	发表后收益衰减	时间切分	不适用	可复现
E81	因子复现危机	时间切分	不适用	可复现
E82	回测过拟合批判	不适用（方法论）	不适用	可复现
E83	缩水夏普 DSR	不适用（方法论）	不适用	可复现
E84	过拟合概率 PBO（CSCV）	不适用（方法论）	不适用	可复现
E85	金融机器学习评测纪律专著	不适用（方法论）	不适用	可复现

表 8: 证据表 B：纳入理由与评测属性

ID	关键定位（纳入理由）	样本外检验	成本口径	复现状态
E86	泄漏安全评估	前向留出	未报告	未核实
E87	债券因子复现危机	时间切分	不适用	部分复现
E88	开源量化研究平台	滚动前向（内置）	可配置	可复现
E89	方法罗列型综述代表	不适用（综述）	不适用	不适用
E90	文献计量/主题建模型综述代表	不适用（综述）	不适用	不适用

共收录 90 条核心来源。“样本外检验/成本口径/复现状态”三列仅填可确证者，未核实的一律写“未报告/未核实”，不替作者补齐。元数据核验脚本见 `scripts/` 下的 `verify_refs*.py`，结果见 `outputs/`。

13 统一比较矩阵

第 12 章的证据表回答“来源是什么”，这一章的矩阵回答另一个问题：“把不同工作的数字放在一起看，它们究竟可比吗?”矩阵按六列对齐——数据与样本、任务、样本外检验、成本口径、开源与许可、复现状态；**每行首列给出对应的证据表编号**，可与证据表 B 逐条对照。填表原则是：原文未报告的项一律写“未报告”，绝不替作者补齐。

表 9: 统一比较矩阵（代表性工作，含证据表编号）

ID	工作	数据/样本	任务	样本外	成本口径	开源/许可	复现状态
E7	Gu 等（2020）	美股 CRSP/Compustat 1957–2016	月度横截面收益、排序	滚动前向	未报告	部分代码/数据受限	部分复现
E9	Chen 等（2024）	美股 1967–2016	条件因子/定价核	时间切分	未报告	部分/数据受限	部分复现
E10	Kelly 等（2024）	美股长样本	收益预测（高维）	时间切分	未报告	部分	未核实
E12	Krauss 等（2017）	标普 500 成分 1992–2015	日度统计套利	时间切分	未报告	部分代码	部分复现
E13	Fischer Krauss（2018）	标普 500 成分 1992–2015	日度方向预测	时间切分	报告成本敏感性	部分代码	部分复现
E14	Zhang 等（2019）	限价订单簿（多资产）	短时价格方向	时间切分	未报告	数据受限	部分复现
E17	Sirignano（2019）	美股限价订单簿	短时中间价	时间切分	未报告	数据受限	部分复现

表 9: 统一比较矩阵（代表性工作，含证据表编号）

ID	工作	数据/样本	任务	样本外	成本口径	开源/许可	复现状态
E16	Ntakaris 等（2018）	FI-2010 公开订单簿	中间价方向	标准划分	不适用	公开数据/代码	可复现
E27	Jiang 等（2017）	加密/多资产日频	组合权重	时间切分	报告费率	公开代码	部分复现
E28	Liu（2020）	美股日频	交易/组合	时间切分	可配置	MIT、公开	部分复现
E29	Nevmyvaka 等（2006）	历史订单簿（私有）	最优执行	时间切分	内生化	未公开	部分复现
E30	Spooner 等（2018）	仿真订单流	做市报价	时间切分	内生化	公开代码	部分复现
E31	Guéant Manziuk（2019）	公司债仿真	做市报价	时间切分	内生化	公开代码	部分复现
E35	Araci（2019）	金融语料	情感分类	标准划分	不适用	公开权重	可复现
E37	Huang 等（2023）	财报 10-K/电话会	信息抽取	标准划分	不适用	公开权重	可复现
E40	Lopez-Lira Tang（2023）	新闻标题	收益信号	时间切分	未报告	未公开	不可复现
E41	Ke 等（2019）	新闻文本	收益预测	时间切分	未报告	部分	部分复现
E42	Yu 等（2023）	股票日频 + 新闻	LLM 智能体交易	时间切分	未报告	部分代码	不可复现
E48	Wiese 等（2020）	金融时序	生成	风格化事实检验	不适用	公开代码	部分复现
E50	Yoon 等（2019）	通用时序	生成	标准划分	不适用	公开代码	部分复现
E51	Buehler 等（2019）	合成/半合成	对冲	时间切分	交易成本	公开代码	部分复现
E52	Byrd 等（2020）	仿真市场	仿真环境	不适用	内生化	公开代码	部分复现
E57	Feng 等（2019）	美股关系图	排序	时间切分	未报告	部分代码	部分复现
E59	Xu（2019）	美股 + 概念图	股价动向	时间切分	未报告	部分代码	部分复现
E54	Cohen						

表 9: 统一比较矩阵（代表性工作，含证据表编号）

ID	工作	数据/样本	任务	样本外	成本口径	开源/许可	复现状态
	Frazzini（2008）	美股供应链	横截面收益	时间切分	未报告	数据受限	部分复现
E64	Katona 等（2018）	卫星数据	资本市场后果	时间切分	不适用	数据私有	不可复现
E62	Zhu（2019）	招聘/评价大数据	公司治理	时间切分	不适用	数据私有	不可复现
E76	Zhang 等（2020）	多资产	端到端组合	时间切分	报告费率	公开代码	部分复现
E75	Costa Iyengar（2022）	多资产	风险预算组合	时间切分	报告	公开代码	部分复现
E67	Almgren Chriss（2000）	理论	最优执行	不适用	解析式	不适用	可复现（理论）
E6	Martin Schöneborn（2011）	理论/数值	均值回归最优带	不适用	解析式	不适用	可复现（理论）

读这张表，有三点值得单独指出。

第一，**“成本口径”一列里“未报告”出现的频率高得惊人**。这意味着大量方法学结论，是在没有计入摩擦的前提下得出的；而按第 2 章的缝隙判据，未扣成本的结论无法判断是否可交易。这不是苛责，而是选择偏差的温床。

第二，**“样本外”一列里“时间切分”与“滚动前向”混杂**。一次性的时间切分容易被反复用于选模型，从而失去样本外的意义；真正可信的是滚动前向。表格区分这两者，是希望读者在读原文时能分辨。

第三，**可复现性与“离摩擦的远近”高度相关**。理论工作（Almgren–Chriss、Martin–Schöneborn）与公开数据工作（FI-2010、FinBERT）复现状态最好；一旦涉及私有数据（另类数据）或商业模型（LLM），复现状态立刻掉到“不可复现”。这与第 15 章的结论互相印证。

本章要记住的一句话是：**把工作摆进同一张矩阵，你才会发现——真正无法比较的，往往不是方法，而是它们各自缺的那几列。**

14 评测数据污染与不可比设定审计

这一章是整份综述里最不讨喜、但可能最有用的一部分。金融机器学习的论文浩如烟海，真正值得重读的却不多，原因不在于方法不够新，而在于**评测本身出了问题**。审计围绕五类风险展开，前四类是老问题在 AI 时代的放大，第五类是 AI 带来的新问题。

14.1 幸存者偏差与上市偏差

用“今天还在交易的股票”回溯过去，会系统性高估收益，因为退市、被并购、破产的样本被剔除了。含完整退市记录的数据库（如 CRSP）能把这一类偏差压到较低水平；而用现成分股名单回测的做法，在大量“深度选股”论文里仍然常见。判断一条结论是否可信，第一件事就是看它用的是时点（point-in-time）成分股，还是事后名单。

14.2 前瞻偏差（look-ahead）

前瞻偏差在 AI 交易里无处不在，且形态隐蔽：

- **特征与标签的时点错位**：t 期收盘算出信号，却假设 t 期开盘成交。
- **财报的可用日**：用报告期而非实际披露日对齐财务数据。
- **标准化泄漏**：用全样本均值方差做特征标准化，把未来信息带进训练。
- **数据处理的全样本操作**：去极值、中性化、缺失值填充若在全样本上做，同样泄漏。
- **图结构的时点**：第 9 章提到，用“今天的行业/供应链关系”回测十年前。

这些错误不会让代码报错，只会让回测好看，因此极难自查。工程上唯一可靠的防线是**用“事件时间线”重放数据，并在每个时点只允许访问当时可见的信息**。

14.3 数据窥探与多重检验

这是量化研究最古老的陷阱：测一万条规则，总能找到一条赚钱的。White（2000）[19] 的 Reality Check 用 bootstrap 对大量候补规则做联合检验；Sullivan、Timmermann 与 White（1999）[20] 对约近八千条技术规则做了联合检验，结论是整个规则集合并不显著优于“什么都不做”。Harvey、Liu 与 Zhu（2016）[21] 给出截面研究的修正：在数百个已发表因子面前，新因子的 t 阈值应从 2 提到约 3。

AI 把这个问题放大了一个量级。神经网络的超参数（层数、宽度、学习率、正则、早停点）、特征工程、甚至随机种子，都构成隐含的“试验次数”。如果模型选择是在同一个样本外集合上反复进行，这个“样本外”就已经被污染，不再是真正的样本外。一个常被忽略的事实是：**深度学习选股论文报告的“样本外”夏普，多数是在被反复用来选模型的那个集合上算出来的**。需要补充的是，复现危机并非只存在于股票因子——近期对债券因子的复现研究 [88] 显示，同类问题在其他资产类别上同样严重。

14.4 回测过拟合与选择性报告

Bailey 等（2014）[24] 用“伪数学”一词批评了回测报告中的常见误导；Bailey 与 López de Prado（2014）[25] 提出**缩水夏普比率**（DSR），把试验次数、样本长度与收益非正态都纳入显著性；Bailey 等（2016）[26] 提出**回测过拟合概率**（PBO）与组合对称交叉验证（CSCV）。López de Prado（2018）[27] 系统整理了金融机器学习的评测纪律。

这里有一条对 AI 交易尤其重要的量化关系：**若在 M 个候选策略中选样本内最优者，其样本内夏普的期望最大值随 $\sqrt{\ln M}$ 增长，即使所有策略都是纯噪声**。这意味着“多试几次”本身就会制造出看起来显著的策略——而强化学习与大规模超参数搜索，恰恰是“多试几次”的极端形式。

14.5 AI 时代的新污染：模型知道答案

前三类是老问题，第四类是第五类的基础，而这一节要讲的是 AI 带来的、可能最严重的**知识泄漏**。

（一）大模型的预训练语料泄漏。用一个 2024 年发布的 LLM 回测 2020–2023 年的新闻，如果这段文本在其预训练语料中，模型是在“背答案”而非“推理”。第 7 章已讨论过这一点，这里再强调其后果：**这类泄漏不会表现为异常高的精度，而会表现为“看起来合理的高收益”，因此极难通过常规手段发现**。唯一可靠的处理是使用模型知识截止日之后的前向样本。

（二）生成数据中的训练/测试泄漏。用生成模型造数据来增强训练集时，若生成器的训练数据与测试集重叠，测试集就被间接泄漏。合成数据的“信息回收”是隐蔽的第二条泄漏通道。

（三）强化学习的环境泄漏。用历史回放作为 RL 环境时，测试期的行情出现在训练环境里，策略对“未来”提前适应。

14.6 跨论文不可比设定

即便单篇论文内部干净，把多篇论文放在一起比较仍然困难，因为设定差异巨大：

表 10: 跨论文不可比设定的典型来源

设定维度	差异举例
任务定义	“预测次日方向”“预测 5 日收益”“排序”是三种不可比的任务，指标也不同
样本区间	含 2020 年疫情行情的样本与不含的样本，不可比
资产池	美股大盘、A 股全市场、加密永续合约的微结构差异巨大
频率	日频选股、分钟级执行、逐笔做市，对模型的要求完全不同
成本口径	零成本、固定费率、含冲击成本，三者可差一个数量级
标签构造	未来 1 期 vs k 期、绝对收益 vs 超额收益，信号方向可能相反
基准选择	与“无脑买入持有”比，还是与“最强已知因子”比，结论不同
评测协议	随机切分 vs 滚动前向；单次切分 vs walk-forward

14.7 一个最低可接受的评测协议

把上述五类风险合起来，可以给出一份“最低可接受”的评测协议。它不是理想标准，而是**低于这个标准的结果就不该被当作证据**的下限：

1. **数据**：声明数据来源、样本区间、时点对齐方式；公布或描述成分股/关系/文本的时间戳口

径。

2. **切分**：使用滚动前向或明确的前向留出段；禁止用测试段调参；随机切分一律视为不合格。
3. **成本**：至少报告固定费率与含冲击两档；说明冲击模型与参与率上限。
4. **基准**：与“最强简单基线”对照（买入持有、经典因子、VWAP 等），并说明基线的口径。
5. **显著性**：报告试验次数 N、样本长度 T，并给出 DSR 与 PBO；“未报告试验次数”按不合格处理。
6. **泄漏**：若使用 LLM 或生成式模型，必须证明测试样本不在其训练语料/训练分布的知识范围内。
7. **可复现**：给出代码或可重建的完整流程说明；数据私有者需说明替代验证途径（如前向样本、外部数据集复现）。

这份协议里，前四条是“统计上诚实”，后三条是“AI 时代新增的要求”。本文认为，未来一段时间内，领域最大的边际改进空间不在算法，而在于把这份协议变成投稿与发布的默认门槛——就像临床试验的 CONSORT 之于医学那样。

14.8 审计结论

把上面的风险合起来，本文给出一条审计判据，供读者在读到任何一条“AI 交易”结论时套用：

1. 是否用时点数据（成分股、财报、关系、文本）？
2. 是否报告了扣成本后的样本外结果？
3. 是否报告了试验次数并做多重检验校正（DSR/PBO）？
4. 若用到 LLM，是否证明了模型知识截止日早于样本期？
5. 是否与强基线（而非“无脑持有”）对照？
6. 是否提供了可复现的代码与数据口径？

六问全过，结论才值得认真对待；六问中间任何一问为否，都应在结论上打一个显著的折扣。本文的证据表与复现状态核验表，正是按这套判据逐条标注的。本章要记住的一句话是：**金融机器学习里，最贵的错误不是模型选错了，而是你用来选模型的那把尺子本身就是歪的。**

15 复现状态核验表

这一章回答一个很实际的问题：文献里的工作，哪些你真的能重跑。判定依据分两类——对开源工具与基准，查其仓库的公开可见信息（可用性、许可、最近更新、基准披露）；对论文结论，看去数据与代码是否可得、评测协议是否可重建。所有仓库信息经 GitHub API 实测（核验时间：2026-10-09），未编造。

15.1 公开工具与基准的仓库核验

表 11: 公开工具/基准仓库核验（GitHub API 实测，2026-10-09）

仓库	Stars	许可	最近推送	复现评估
microsoft/qlib	49.2k	MIT	2026-10-08	可复现：公开基准 + 活跃维护
AI4Finance-Foundation/FinRL	16.6k	MIT	2026-10-08	部分：流程可跑，收益随设定变
AI4Finance-Foundation/FinRL-Meta	1.9k	MIT	2026-10-06	部分：数据/环境封装，活跃
AI4Finance-Foundation/FinGPT	21.4k	MIT	2026-09-23	部分：模型权重与许可受限
hudson-and-thames/mlfinlab	4.9k	未声明	2023-10-02	部分：停更，许可不明确
esvhd/pypbo	142	AGPL-3.0	2026-07-06	可复现：PBO 参考实现
mementum/backtrader	23.4k	GPL-3.0	2024-08-19	可复现（引擎）：已停更
quantopian/alphalens	4.5k	Apache-2.0	2024-02-12	可复现：因子分析，已停更
quantopian/zipline	20.1k	Apache-2.0	2024-02-13	部分：回测引擎，已停更
polakowo/vectorbt	9.3k	未声明	2026-09-26	可复现：活跃，许可待核
quantopian/empyrical	1.5k	Apache-2.0	2024-07-26	可复现：指标库，已停更
quantopian/pyfolio	6.4k	Apache-2.0	2023-12-23	可复现：业绩分析，已停更
abides-sim/abides	579	未声明	2023-07-06	部分：市场仿真，停更
stefan-jansen/ML-for-trading	21.3k	MIT	2026-10-08	可复现：教材配套代码，活跃

从这张表能读出一条清晰的规律：**越靠近“研究基础设施”（数据、评测、教材）的工具，越活跃、越可复现；越靠近“策略本体”的代码，可复现性越差**。另一个值得注意的现象是，Quantopian 系（zipline、alphalens、empyrical、pyfolio）虽然质量高、许可清晰，但都已停止更新，反映了量化开源生态“研究平台易建、维护难续”的现实。

两点使用说明：其一，表中数据为 2026-10-09 的 GitHub API 快照，**star 数、最近推送时间等会随时间变化，重跑脚本得到的结果可能与本文不同**；其二，**star 数高不等于质量高、更不等于结论可复现**，它只是一个活跃度与关注度的粗略信号；判断可复现性应看“是否公开基准、有无许可、评测协议是否可重建”这几项，本表把它们列在“复现评估”一列。

15.2 代表性论文的复现状态

表 12: 代表性工作复现状态

工作	复现状态	依据 / 障碍
Gu, Kelly & Xiu (2020) 机器学习资产定价	部分复现	特征来自商业数据库（CRSP/Compustat），许可受限；结论在换市场后存疑
Chen, Pelger & Zhu (2024) 深度学习资产定价	部分复现	数据许可受限；结构假设需复刻
Zhang et al. (2019) DeepLOB	部分复现	数据（FI-2010）与代码公开，协议较清晰
Araci (2019) / Yang et al. (2020) FinBERT	可复现	预训练权重与语料公开，任务可重建
Liu et al. FinRL	部分复现	代码公开，但报告收益高度依赖环境与成本设定
Nevmyvaka et al. (2006) 执行 RL	部分复现	数据（历史订单簿）私有，难以完全复刻
一般“LSTM 预测股价”类论文	不可复现	多数不给代码、切分与成本口径不明
一般“LLM 交易智能体”论文	不可复现	API 版本漂移 + 训练语料泄漏无法排除
私有另类数据类研究	不可复现	数据私有，外部无验证途径

15.3 为什么复现状态如此分化

把两张表放在一起看，分化的原因可以归结为三点，且都不是“作者不努力”：

1. **数据许可壁垒**。越是有价值的金融数据（CRSP、TAQ、私有另类数据），许可越严，代码再完整也无法替代数据。这是结构性障碍。
2. **环境与成本设定的自由度**。同样的算法，换一个成本模型或影响模型，结论可能从“有效”翻到“无效”。评测协议不统一时，“复现”本身就没有唯一答案。
3. **模型漂移与泄漏**。依赖商业 LLM 的工作，其“可复现性”被模型升级直接摧毁；而训练语料泄漏又让复现出的高收益无法区分于“背答案”。

15.4 一个可操作的结论

对本综述的读者，最实用的建议是：**先看复现状态，再决定要不要读方法细节**。一个复现状态为“不可复现”的工作，无论方法多新颖，都无法成为你决策的依据；而一个复现状态为“可复现”的工作，即使方法朴素，也值得作为你系统的基线。这也是本文把复现审计单列一章的原

因——它是把前面所有方法学讨论，落回到“能不能用”的最后一道关。

本章要记住的一句话是：**在金融机器学习里，“公开了代码”和“能被复现”之间隔着的，往往不是工程能力，而是数据许可、评测口径与模型漂移这三道非技术鸿沟。**

16 可复现实验方案：从 P0 到 P3

前面几章反复指出一件事：现有研究的结论之所以难以互证，根源在于口径不统一与评测污染。这一章把它变成可执行的方案。方案分四级，P0 是地基，P3 是前沿对照；每一级都给出**可验证的成功标准**，配套的参考实现骨架放在随附的 `code/` 目录。

16.1 P0：把数据、成本、评价三层统一钉死

这一级不追求新方法，只追求“让不同方法在同一把尺子下比较”。

（1）统一数据层。

- 使用**时点（point-in-time）**数据：时点成分股、按实际披露日对齐的财报、按首次可见时间对齐的文本。
- 固定交易时点约定：信号在 t 收盘计算，$t+1$ 开盘或 VWAP 成交，全流程禁止盘中信息前移。
- 冻结一份数据快照（含校验和），保证任何人重跑得到同一份输入。
- **交易制度掩码**：涨跌停、停牌、退市的股票构成“不可成交单元”，必须在数据层显式标出；回测中不得假设这些单元仍可自由调仓（涨跌停不可买、不可卖，停牌不可交易）。这一条直接改变可交易性与成本，遗漏会让回测系统性偏乐观。

（2）统一成本层。对每个策略至少报告三档：零成本 / 固定费率 / 含冲击成本。冲击成本用参与率模型，参与率设上限（如不超过当日成交量的 10%），超限标记；冲击形态采用平方根律（Almgren 等 2005[9]）。

（3）统一评价层。强制报告六类指标：收益（年化、累计）、风险（波动、最大回撤、CVaR）、信号（IC/IR）、显著性（t 统计量、DSR）、成本（换手率、成本占比）、稳健性（PBO、跨市场一致性）。缺一不可。

成功标准：同一策略在固定快照上，由不同人重跑得到数值一致（差异在浮点容差内）的结果。

16.2 P1：统一评测协议

- **滚动前向（walk-forward）**：用扩展窗或滚动窗，逐段训练、逐段前向测试，禁止用测试段信息调参。
- **多重切分**：至少用一个“时间上更晚”的留出段做最终确认，模拟真实上线的时间顺序。
- **跨市场/跨资产**：同一管线在 ≥ 3 个市场（如 A 股、美股、期货）上运行，报告迁移结果。

- **基线对齐**：与“最强已知简单基线”对照（如等权买入持有、经典动量/价值因子、VWAP 执行），而非与“无脑策略”对照。

成功标准：同一策略在 ≥ 3 个市场的样本外结果同号，且相对最强基线的增量在成本后仍为正；否则结论记为“无可复现增益”。

16.3 P2：多重检验纪律

这一级是本文与前人工作最大的分歧点，也是最容易被跳过的一级。

- **维护“试验账本”**：把每一次模型、参数、特征的尝试都计入试验次数 N，并在报告时公开 N。
- **缩水夏普（DSR）**：用 DSR[25] 校正选择偏差、样本长度与非正态，报告 DSR 而非原始夏普。
- **回测过拟合概率（PBO）**：用 CSCV[26] 计算 PBO，要求 PBO < 0.2 才允许进入下一阶段。
- **多重比较校正**：对多市场多参数的结果做 Benjamini–Hochberg 或 Romano–Wolf 校正；对因子类研究采用 Harvey–Liu–Zhu 的 $t > 3$ 门槛 [21]。

成功标准：报告“试验次数 N、样本长度 T、DSR、PBO、校正后 p 值”五项，且校正后结论仍显著。

16.4 P3：前沿方法的公平对照

- **同数据、同成本、同协议**：把深度/强化/LLM 方法放在 P0–P2 的统一口径下，与 P0 的经典基线对照。
- **增量归因**：明确区分“增量来自模型”还是“增量来自设定”（数据、成本、频率、资产池）。
- **LLM 类方法的前向验证**：使用模型知识截止日**之后**的样本，或提供证据证明测试文本不在训练语料中（第 7 章、第 14 章）。
- **公开可复现资产**：固定随机种子、公开数据快照、公开代码与超参数搜索空间。

成功标准：前沿方法在统一口径下的 DSR 超过经典基线且通过 PBO 与多重检验校正；否则如实报告“在当前口径下无可复现增益”。

16.5 协议条款与参考实现的对照

为避免把“协议要求”误读为“已经做到”，下表逐条列出每一项条款在随附代码中的落实状态。凡标“仅协议”者，本文并未实现，读者需自行接入。

16.6 参考实现骨架

随附的 `code/` 目录给出一个最小但完整的研究骨架，用于承载上述 P0–P2：

表 13: 协议条款 ↔ 参考实现对照

协议条款	实现位置	状态	说明
时点数据快照（含校验和）	`data.py`、`real_data.py`	部分实现	合成面板 + 通达信真实日线（后复权、封板价精确判定、新股剔除）；完整时点库（成分、按披露日对齐财报、按首次可见时间对齐文本）仍需替换
三档成本 + 平方根冲击	`costs.py`	已实现	参与率设上限并记录超限次数；真实数据侧 ADV 取逐股成交额中位数，费率含佣金、过户费与分段卖出印花税
交易制度掩码（涨跌停/停牌/退市）	`data.py`、`real_data.py`、`baseline.py`	已实现	真实数据侧按封板价精确判定（5/10/20/30% 自动区分）、一字板与停牌不可成交、新股上市初期剔除；不可成交单元沿用上一期权重
六类指标（含 IC/IR）	`eval.py`、`run.py`	已实现	信号类指标 IC/IR 已补齐；成本类已按本节要求报告换手率与成本占比
滚动前向（walk-forward）	`eval.py`、`run.py`	已实现	并保留单次切分作对照
跨 ≥ 3 市场泛化	——	仅协议	需接入多市场数据后才可实现
缩水夏普（标准误口径）	`eval.py`	已实现	另附截面离散口径作对照
回测过拟合概率 PBO + 切分敏感性	`eval.py`	已实现	报告多个切分段数下的 PBO 区间
多重比较校正（BH / Romano–Wolf）	——	仅协议	参考实现未提供，需自行接入
试验账本（覆盖搜索空间）	`run.py`	已实现	计入随机组合数与岭参数网格
LLM 前向验证	——	仅协议	依赖具体模型与数据，本文不实现

- `data.py`：时点数据加载与快照冻结（伪实现，接口稳定）。
- `costs.py`：三档成本与平方根冲击模型。
- `eval.py`：walk-forward 切分、六类指标、DSR/PBO 计算。
- `baseline.py`：经典基线与一个最小学习型基线，用于对照。
- `run.py`：端到端串起数据–成本–评测，输出结构化结果与试验账本。

需要说明的是，这套骨架不绑定任何具体数据源与第三方库，读者可把 `data.py` 换成自己的数据接入。**它的价值不在于跑出什么收益，而在于提供一个“按 P0–P2 记账”的容器**——把评测纪律固化进代码，而不是靠人自觉。

本章要记住的一句话是：**可复现不是把代码传上去就完了，而是要让别人用你没想到的参数组合重跑时，得到的结论和你一致——做到这一点，靠的是把口径、成本与试验次数写死在流程里。**

17 开源生态与工具链

方法是抽象的，工具是具体的。这一章梳理支撑“AI 交易”研究的开源生态，分四类：量化研究平台、回测与评测工具、市场仿真环境、以及数据与基准。对想落地的人而言，工具链的成熟度往往比方法的新旧更决定成败。

17.1 量化研究平台

Qlib（Microsoft）[87] 是目前集成度最高的开源量化研究平台之一，覆盖数据处理、特征库（Alpha158/Alpha360）、模型训练、回测与公开基准。它的核心价值有两层：一是提供了**统一口径的公开基准**，让不同模型的比较有共同底座；二是它的流程化设计把“数据–特征–模型–回测”串成了一条可审计的管线。局限也清楚：其内置基准聚焦截面因子选股，不覆盖执行与做市，且默认数据为中低频 A 股。

FinRL（Liu 等 [51]）是强化学习交易的主要开源框架，提供环境封装、数据处理与多种 RL 基线。它把 RL 交易的工程复杂度大幅降低，是这一族可复现性最好的资产；但如第 6 章所述，**它的价值在标准化流程，而不在证明 RL 能赚钱**——用它得到的高收益高度依赖环境与成本设定。

17.2 回测与评测工具

- **回测引擎**：Backtrader、Zipline、VectorBT 等，提供事件驱动或向量化回测。选用时最该确认的是：是否支持逐笔/分钟级成交、是否内置冲击成本模型、是否避免前视。
- **因子分析**：Alphalens 与 empyrical 用于因子 IC、换手、分层收益与风险指标计算，是截面研究的标配。
- **机器学习评测纪律**：Hudson & Thames 的 mlfinlab 提供多重检验、去噪标注与特征重要性方法，是把第 14 章纪律落到代码的工具；ESVHD 的 `pbo` 包是回测过拟合概率的参考实现。

这里有一条实用建议：上述工具的默认设置大多“偏乐观”（零成本、全样本标准化、随机切分）。用之前应先按其默认之外的方式显式配置成本与切分，否则工具会替代你犯下前面几章反复警告的错误。

17.3 市场仿真环境

- **ABIDES**（Byrd 等 [73]）：离散事件市场模拟器，支持多智能体交互，是学术研究中较完整的开源选择。
- **JAX-LOB** 与队列反应（queue-reactive）模型：面向订单簿的高性能仿真，适合为执行/做市 RL 提供训练环境。
- **LLM 驱动的市场仿真**：如 MarS 一类工作试图用生成式基础模型驱动市场仿真，方向新，成熟度低。

仿真环境的评价标准只有一条：**它是不是能对“策略自己的行为”作出反应**。一个只为回放历史、不因你的下单而改变价格的仿真器，无论多快，都不是真正的环境。

17.4 数据与公开基准

- **学术数据**：CRSP/WRDS（含完整退市记录，许可受限）、Compustat（财报）、TAQ（逐笔）。这些是干净学术基准的来源，但商业使用受许可约束。
- **公开订单簿基准**：FI-2010[38] 与 LOBSTER 样本，是订单簿建模可比性的稀缺资产。
- **公开选股基准**：Qlib 的 CSI300 基准系列，是目前最透明的截面选股公开结果之一。

17.5 生态的缺口

把生态铺开来看，会发现一个明显的不对称：**数据与基准的开放程度，远低于方法与代码的开放程度**。选股因子的公开基准相对成熟（Qlib），订单簿有少量公开数据集，而执行、做市、另类数据这几块，公开、可信、可复现的基准几乎空白。这直接导致了一个后果：**越是靠近“摩擦”的环节，越缺乏可比证据；而这些环节恰恰是决定净收益的地方**。这既是研究缺口，也是本文第 20 章研究路线图的重点。

本章要记住的一句话是：**工具链的成熟不改变一个事实——开源给你的是流程，不是收益；越是默认设置友好的工具，越需要你用纪律去抵消它的乐观。**

18 结论置信度分级

把全篇的判断收拢到一张表里，并按证据强度分级。分级标准：**高** = 多源独立证据、跨市场/跨样本稳健、且经得起成本与多重检验；**中** = 有权威来源或明确机制，但存在清晰的边界条件；**低** = 预印本为主、单一样本、缺乏独立复现或存在未排除的数据泄漏。

表中“低”并不等于“错”，而是“尚不足以作为决策依据”。本文对该类结论的处理方式是：在正文中如实呈现，但不将其纳入任何推荐做法。反过来，凡是在统一口径下无法判定增量的方向，

表 14: 核心结论与置信度

结论	置信度	依据与边界
金融预测信噪比极低（月度 R^2 常在 0.5% 以下），但低 R^2 可经杠杆/横截面聚合转化为可交易收益	高	多源一致 [28]；边界：取决于成本与容量
信息租金随参与者增多而耗散，被广泛使用的信号毛利被压薄	高	机制清晰 [3, 4]；经验证据 [22]
交易成本与冲击常常决定策略净收益的生死	高	理论与实证一致 [8, 86]；边界：低频/大容量策略影响较小
评测污染（数据窥探、前瞻、幸存者、回测过拟合）是重现性危机的系统性根源	高	方法论文献一致 [19, 21, 26]；因子复现证据 [23]
监督学习/树模型在横截面选股上相对线性基线存在稳定增量	中	[28, 33]；边界：增量随市场与样本变化，需成本后确认
把经济结构（如无套利）注入模型优于纯黑箱拟合	中	[30, 29]；边界：结构假设错误时反受其害
“复杂性红利”在高维稀疏设定下存在	中–低	[31]；争议大，对假设敏感，需独立复现
深度序列模型在日频选股上的增量缺乏独立复现	低–中	精度指标多、交易绩效少，且常缺成本与 OOS 审计
订单簿/微观结构建模是深度学习在交易中最可复现的落地场景	中–高	公开数据集与代码 [38, 36]；边界：数据成本高
RL 在最优执行与做市上有价值	中	[52, 54, 53]；边界：强依赖仿真环境保真度
RL 在组合管理上相对经典方法有稳定增量	低	反例与工程问题多，缺成本后独立复现
LLM 直接预测收益的证据被“模型知道答案”严重污染	高（方法论）	泄漏机制明确 [64, 65]
LLM 交易智能体整体证据强度低	低	评测协议薄弱、泄漏难排除、成本与可复现性问题突出 [63]
生成式模型能缓解样本稀缺，但不能外推“未发生过的历史”	中	方法论共识；边界：平静期训练无法做真正的极端压力测试
GNN 的关系增量高度依赖“边如何定义”，证据混杂	中–低	[76, 78]；边界：关系可能已被价格吸收
另类数据的超额收益衰减快，且私有数据结果无法独立验证	中–高	机制明确；边界：微观结构类数据衰减较慢

本文统一标记为“增量不可判定”，留待第 20 章的路线图中以严格协议检验。

19 局限性摘要与反方证据

一份诚实的综述，应该把自己的边界写到别人能攻击的程度。这一章的写法是：先列出本文自身的局限，再把文献里与本文判断相反的证据摆出来，最后给出修正后的判断。

19.1 本综述自身的局限

1. **检索覆盖偏差**：检索以英文文献与 arXiv 为主，可能低估中文与非英语圈的实证工作；对期刊的覆盖也偏向金融与机器学习主流刊物。
2. **私有数据不可见**：对冲基金与做市商的真实业绩不可得，本文关于“学术结论与实盘落差”的判断，依据的是公开证据的衰减模式，而非直采的实盘数据。
3. **参数细节需全文复核**：证据表中若只依据摘要与元数据，样本区间、阈值、成本模型等细节仍可能被简化，已逐条标注核验状态。
4. **方法演进的时效**：大模型与生成式模型进展极快，本文对 LLM 类工作的保守评价，可能随前向验证证据的积累而需要修正。
5. **篇幅取舍**：全景的双轴框架降低了单格的深度；对某一具体方法族想深挖的读者，仍需回到原始论文。

19.2 反方证据

反方一：AI 的增量可能被高估。这一派（以有效市场传统的实证为据）认为，考虑交易成本、流动性与容量后，绝大多数所谓 AI 策略的超额收益会消失；把机器学习用在截面上，本质上只是“更高效地挖已知因子”，而非创造新信息。支持这条的间接证据是：因子被发表后收益衰减 [22]、大批因子无法复现 [23]。本文承认这条批评的分量，这也是为什么全篇把“扣成本后的样本外”作为唯一有效判据。

反方二：AI 的增量可能被低估。“复杂性红利”[31] 与部分端到端 [84]、结构注入 [30] 的结果显示，在正确定义的问题上，更复杂的模型确有增量。这一派的潜台词是：传统实证低估了非线性与高维交互的价值，因为它的工具够不到那里。本文对此保持开放，但坚持一点——**这类增量必须在统一口径、扣成本、经多重检验后仍然存在，才算数**。

反方三：LLM 智能体是被低估的范式。乐观者认为，LLM 带来了“理解世界”的能力，而不仅是“拟合数据”，因此智能体交易的潜力被本文的保守评价低估。本文的回应是：**潜力不等于证据**。在“模型知道答案”这一污染被系统性排除之前，任何乐观判断都缺少认识论基础；本文并不否认范式潜力，只是拒绝在没有前向证据前给它定高的证据等级。

19.3 本文的立场，修正后

综合正反两方，本文修正后的判断是三条：

1. **AI 提升的是“转化效率”，其可交易增量应随市场效率递减。**需要说明的是，“AI 不改变利润总量”这一说法本身不可观测、也不可证伪，本文不把它当作结论，而给出一个可检验的弱化形式：**在统一口径（同数据、同成本、同评测协议）下，AI 类方法相对“最强简单基线”的成本后净增量，随市场效率的提升而递减。**检验设计是：取三个成熟度不同的市场（如美股大盘、A 股主板、加密永续），在同一管线上估计相对净增量，再看其排序是否与常见的效率代理（买卖价差、机构持股占比、信息半衰期）呈同序。排序成立则该命题获得支持；不成立则本文关于“效率上限”的论证需要修正。这正是第 20 章路线图 Phase 3 的任务之一。
2. **越靠近摩擦的环节，AI 的增量越可靠；越靠近纯预测的环节，增量越不确定。**因为摩擦是可以被工程降低的客观量，而预测增量必须与市场效率上限竞争。这与“执行/做市类工作复现性好、选股类工作复现性差”的经验一致。
3. **当前文献最大的问题不是模型，而是评测。**因此对读者而言，最高性价比的动作不是追逐更新奇的模型，而是先把口径与纪律立起来——这也是本文把 P0–P2 放在 P3 之前的原因。

本章要记住的一句话是：**一份有用的综述不该让读者更兴奋，而该让读者更清醒——如果读完它你既没有高估 AI 也没有轻视它，那它就达到了目的。**

20 研究现状、遗留课题与未来路线图

20.1 当前研究现状

把六个方法族横过来看，能看到一条清晰的分层：**监督学习已是常规工具，深度序列模型到达平台期，强化学习在摩擦相关环节站稳、在选股环节证据薄弱，大模型仍在爆炸期但证据等级最低，生成式模型从“造数据”走向“造环境”，图神经网络从狂热回归理性。**与之形成反差的是评测层：方法在进步，可比性却在退步——因为每出一族新方法，就多一批自定口径、缺成本、缺审计的结果，跨论文的可比性反而被稀释。

如果用一句话概括现状：**我们缺的不是新模型，是能把新模型和旧模型放在一起公平比较的公共基础设施。**

20.2 遗留课题

1. **泄漏难排除下的 LLM 评估。**LLM 的知识截止日使“样本外”这一概念本身失效，而前向样本需要时间积累。在积累到足够前向数据之前，如何设计可信的代理评测（如强制使用截止日后数据、语料排除证明、或合成对照），是当前最关键的方法论缺口。
2. **摩擦环节的公开基准缺失。**执行、做市、另类数据几乎无可复现基准，导致越关键、越靠近净收益的环节，证据越薄。
3. **试验次数不可完全观测下的多重检验。**真实的超参数搜索与特征尝试次数，研究者自己也未必全知，DSR/PBO 需要的 N 因此难以精确。如何在这种不确定下给出稳健的显著性判断，仍开放。

4. **非平稳下的持续学习。**现有模型多假设“学到即固定”，而市场制度会漂移。如何在有限前向反馈下做在线适应而不被噪声带偏，是把实验室结果推向长期实盘的必经问题。
5. **端到端与可诊断性的张力。**端到端能协调环节冲突、提升上限，却牺牲可诊断性，而交易恰恰是出错代价极高的场景。
6. **容量与拥挤度的联合估计。**策略能赚多少、能装多少资金、别人用了它还剩多少，三者纠缠在一起，现有研究很少同时处理。
7. **合成数据能否用于风控。**第 8 章指出生成模型无法外推未发生事件，那么用于压力测试的合成数据，其结论可信边界在哪，需要专门研究。

20.3 研究路线图（Phase 0–4）

路线图按“先立尺子、再比方法、再验前沿、最后沉淀”的顺序设计，每阶段带交付物与验证门（G1–G9）。与第 16 章 P0–P3 的关系是：P 级是**方法纪律**，Phase 是**工程路线**，二者一一对应但阶段更长。

表 15: 研究路线图：阶段、交付物与验证门

阶段	目标	交付物	验证门
Phase 0 基建	立尺子	时点数据快照（含校验和）、三档成本层、评测容器（含 DSR/PBO）、试验账本模板	G1 时点审计通过；G2 成本层数值可复现
Phase 1 基准复现	对齐已知结论	复现 Qlib 选股基准、经典动量/价值因子、VWAP 执行基线	G3 复现数值落在容差内；G4 确定“最强简单基线”
Phase 2 前沿对照	公平比较	在统一口径下对照监督/深度/RL 方法与基线，输出增量归因表	G5 增量归因完成（模型 vs 设定）；G6 DSR 与 PBO 双通过
Phase 3 前沿验证	检验高风险方向	LLM 前向样本评测、生成式压力测试、跨市场泛化实验	G7 泄漏排除证明成立；G8 跨 ≥ 3 市场 OOS 同号
Phase 4 沉淀	公共资产	开源协议与基准、可复现排行榜、负面结果库	G9 第三方在无作者协助下复现同一结论

为什么把 Phase 0 放在最前：因为如果数据、成本与评测三样不统一，后面所有比较都是沙上建塔。这也是本文与前人综述最大的不同——它不推荐你去追最新的模型，而推荐你先把地基打平。

为什么单列负面结果库：金融机器学习领域最稀缺的不是成功案例，而是“这个方向我试过、在统一口径下不成立”的记录。负面结果的公开，能直接降低整个领域重复踩坑的成本，它的公

共价值不低于任何一篇正结果论文。

本章要记住的一句话是：**这个领域下一步最大的进展，可能不是某个模型刷出了更高的夏普，而是一套让所有人的夏普可信地接受比较的公共协议——先把尺子造出来，比抢着去量更有意义。**

21 复核清单：已执行结果与剩余待办

这一章把本综述做过的核验、跑过的实验、以及尚未完成的部分如实列出，供读者判断本文每条结论的可靠程度。

21.1 检索与来源池

- **多源检索已执行**：OpenAlex 标题检索（覆盖资产定价、最优执行、强化学习、NLP、生成式、图网络、评测方法论等锚点文献）、arXiv 关键词检索（q-fin 与 cs 分类，覆盖六个方法族与五个交易环节）、Crossref 补核验。
- **来源池规模**：去重后共 528 条候选来源（期刊/Crossref 178 条、arXiv 350 条）；目录 `outputs/pool.json`。检索脚本见 `scripts/retrieve_sources.py`。
- **引用键核验**：正文引用的来源逐条经 OpenAlex/Crossref/arXiv 核对元数据，脚本见 `scripts/verify_refs.py`，结果见 `outputs/refs_verified.json`。

21.2 参考实现实跑记录（P0–P2）

`code/run.py` 在合成时点面板（$T = 1200$，$N = 60$，$K = 8$，快照校验和 `432bdae19c9533ed`）上端到端运行，候选池 61 个（8 个单特征 + 50 个随机线性组合 + 3 个岭参数网格），试验账本口径见下。关键输出如下：

这组数字本身就是本文论点的演示：**按样本内挑选，选出来的是一条纯噪声组合；它的 IC 与零无异；扣掉冲击成本后夏普几乎归零；而 DSR 与 PBO 都明确指出，这个结果经不起选择偏差与过拟合的检验。**流程的价值不在于跑出收益，而在于它能在结果看起来不错时就先给出否定信号。

性质声明（重要）：本演示使用**合成面板**，其信噪比、涨跌停比例、停牌率均为作者设定。因此它**只能验证评测流程本身是否按预期工作，不能作为“真实市场中普遍存在过拟合”的证据**——在一个低信噪比的设定下，“按样本内选择会选中噪声”几乎是被设计出来的结果。要把它上升为经验结论，必须在公开真实数据上做同样的最小实证；这一步已在下一小节补上。

还有一处口径差异需注明：本演示的成本用**单一 5bp 费率与常数 ADV** 10^9 **元**（合成面板不含成交额字段，无法逐股取 ADV），而下一小节的真实数据实证用**佣金＋过户费＋分段印花税与逐股 ADV**。两处的“成本三档”因此**不可直接比较**，只能各自内部比较。

表 16: 参考实现实跑结果（合成数据，见下方性质声明）

项目	实跑结果
不可成交单元占比	0.1921（含涨跌停 / 停牌 / 非成分）
试验账本 N	61（单特征 8 + 随机组合 50 + 岭参数网格 3）
样本内最优候选	`rand11`（**纯噪声**线性组合），样本内夏普 1.196
其滚动前向 OOS 夏普	0.477（单次切分为 0.868，两者不一致本身即是警示）
OOS 夏普高于它的纯噪声候选数	15
信号类指标（该候选）	IC 均值 0.0074、IR 0.052、IC>0 占比 0.501（与纯噪声一致）
成本三档（该候选，全样本）	零成本夏普 0.833 / 固定费率 0.518 / 含冲击 0.057
缩水夏普 DSR（$N = 61$）	标准误口径 DSR $= 0.053$（$\mathrm{SR}_0 = 0.096$）；截面离散口径 DSR $= 0.027$
回测过拟合概率 PBO	0.567；切分敏感性 $\{8{:}0.400,\ 12{:}0.567,\ 16{:}0.516,\ 20{:}0.584\}$，区间 $[0.400, 0.584]$

21.3 真实数据最小实证（P0–P2）

合成面板只能验证流程本身，不能替代经验证据。为补上这一步，本文令同一套 P0–P2 流程直接跑在**本地通达信 vipdoc 日线**（`.day`）上。复现命令 `python code/run.py --real`，数据加载见 `code/real_data.py`。[1]

数据与口径：样本为沪深（含北交所 15 只）A 股，窗口 2019-01-02 至 2026-10-08（$T = 1881$ 个交易日）。universe 要求窗口内交易日覆盖率不低于 90%（按上市后活动窗口计）、日成交额中位数不低于 2000 万元，按代码等距抽样至 $N = 400$。抽样框依赖本地库清单，故**随快照一并冻结**于 `outputs/real_universe.json`（400 只代码与逐股 ADV），他人可用同一清单复算。

价格底座为通达信原始日线，再乘后复权因子，先于一切特征与收益计算，消除分红与送转造成的跳空。这里有一处须如实说明的外部依赖：通达信本地权息文件 `gbbq` 在本机三个安装中均为**加密存储**，无法解析，故复权因子取 AKShare 并缓存至 `outputs/hfq_factors.json`（第三方仅作必要兜底）。该拼装链已对**全部 400 只逐股交叉核验：**通达信原始价乘因子与 AKShare 独立后复权价相比，相对偏差中位数 2.3×10^{-4}、95 分位 9.1×10^{-4}、最大 3.1×10^{-3}（17 只超过 10^{-3}，无一只超过 10^{-2}）。核验脚本 `scripts/verify_adjust.py`，结果缓存于 `outputs/adjust_check.json`。

交易制度掩码按**封板价精确判定：**对 $\{5\%, 10\%, 20\%, 30\%\}$ 四档涨跌幅分别计算 $\mathrm{round}(\text{前收}\times(1\pm\mathrm{lim}), 0.01)$，当收盘价与最高价（涨停）或最低价（跌停）同时等于该价时判为封板、不可调仓。该判定逐日直接识别，ST 的 ±5% 与主板/创业科创/北交所的 10/20/30% 自动区分，不依赖

[1]本节的口径与举例在修订过程中更正过四处：冲击成本的 ADV 由常数改为逐股取值、封板占比统一为有效单元格分母、复权核验由抽样扩到全量 400 只、单特征异象举例按多重检验结果更正。更正前后的对照与影响见 `docs/change_summary_round2.tex`，正文只保留更正后的口径。

名称表、也不引入前视。一字板（开 = 高 = 低 = 收且封板）与停牌一并记为不可成交；新股上市后前 20 个交易日剔除。以下占比一律**以有效单元格为分母**（有效单元格指已上市且特征可算的单元，占全部单元的 80.1%）：封板合计 1.96%，其中涨停 1.49%、跌停 0.48%；一字板 0.20%。

成本口径：冲击成本按**逐个股 ADV** 计算——ADV 取该股在窗口内日成交额的中位数（样本中位为 7.46×10^7 元），参与率 = 成交额 / ADV，冲击率 $=0.02\sqrt{\text{参与率}}$，参与率设 10% 上限。费率按 A 股实际构成计入：佣金 2.5bp 与过户费 0.1bp 双边，另加**卖出印花税分段**（2023-08-28 之前 10bp、之后 5bp）。作为对照：若对全部个股取同一常数 ADV（如 10^9 元，恰为样本中位数的 13.4 倍），参与率会被系统性低估——这是把成本算轻最常见的一种做法，本文不使用。

特征仍是 $K = 8$ 的价量因子（1/5/20/60 日动量、20 日波动、量比、距 20 日均线偏离、Amihud 非流动性），逐期截面 z 标准化，只用 t 期及以前信息；标签为后复权收盘到收盘的下一日收益。快照校验和 `781cadd68dfbd170`。

表 17：参考实现实跑结果（本地通达信真实日线，含后复权、交易制度掩码与逐股成本口径）

项目	实跑结果
数据来源	通达信 vipdoc 日线（价格）+ AKShare 后复权因子（第三方兜底，400 只全量核验）
窗口与规模	2019-01-02 至 2026-10-08；$T = 1881$，$N = 400$（含北交所 15 只、窗口内上市 153 只）
不可成交单元占比	0.2134；其中有效样本内封板 1.96%，其余为上市前与历史不足
试验账本 N	61（单特征 8 + 随机组合 50 + 岭参数网格 3）
样本内最优候选	`rand10`（随机线性组合），样本内夏普 3.649
其滚动前向 OOS 夏普	2.671（单次切分 3.595）
OOS 夏普高于它的候选数	1
信号类指标（该候选）	IC 均值 0.0129、IR 0.088、IC>0 占比 0.548（$n = 1820$）
换手率	日均合计 $\sum\lvert\Delta w\rvert = 0.721$，年化约 182 倍
成本三档（年化 / 夏普）	零成本 0.273 / 3.057；固定费率 0.154 / 1.720；含冲击 −0.134 / −1.492
成本占毛收益	零成本 0；固定费率 0.44；含冲击 1.49（即成本已超过毛收益本身）
缩水夏普 DSR（$N = 61$）	标准误口径 0.9991；截面离散口径 0.0022（取舍见下文）
回测过拟合概率 PBO	0.000；切分敏感性区间 $[0.000, 0.000]$

这组数字推翻了合成演示的一条外推。在合成面板上，“按样本内挑选会选中噪声”几乎是设定好的结果；到真实数据上，同样按样本内夏普挑选，选中的随机组合样本内 3.649、滚动前向 OOS 2.671，DSR 标准误口径 0.9991、PBO 0.000，都指向“不是选择偏差的产物”。**合成面板得到的“选到噪声”不能外推为经验规律**——这正是最小实证该做的事：用真实数据检验框架自己。

按第 16 章自己援引的标准，单特征结论必须过多重检验校正，故此处补齐 t 值（$t = \text{IC-IR} \times \sqrt{n}$，$n = 1820$）与 Benjamini–Hochberg 校正，结果见表 18 后四列。该式假设逐期 IC 序列独立，故另做序列相关检验：各特征 IC 的 AR(1) 多在 0.05 以内，Newey–West 调整后仅非流动性由 3.92 降到 3.45（仍过门槛）、量比几乎不动，可见上述判定对序列相关稳健（脚本 `code/audit_significance.py`）。

DSR 两口径的取舍：两个口径的标准化方式相同，差别只在 sr_0 中 $V(\widehat{SR})$ 的取法——标准误口径用单个夏普估计的解析方差，截面离散口径用 61 个候选样本外夏普的截面方差。本文**以标准误口径为准**，理由是：**截面离散度把两类东西混在了一起**——各候选真实夏普的差异，与每个候选夏普的估计噪声。本池里真实强弱差异很大（量比与波动率的真实表现相差悬殊），实测两者的合成量比纯估计方差大 20 倍，多出来的部分主要是质量差异而非估计误差，因此它不能充当 $V(\widehat{SR})$；代入后会把 sr_0 抬到 0.2556（标准误口径为 0.0722）。

另做一项稳健性检查：候选样本外收益的平均两两相关约为零（-0.012，最大 0.977），说明 $N = 61$ 作为试验数是合适的、无需按相关结构折减；即便改用按相关结构折算的有效试验数（193）重算，sr_0 也只是由 0.0652 升到 0.0764，DSR 由 0.9999 变为 0.9995——**结论对这一选择不敏感**。仍须如实留下两点边界：原文 DSR 的 $V(\widehat{SR})$ 取自试验集夏普的方差，解析方差是试验集不可用时的替代，两者并不等价；且 $E[\max_N]$ 项假设试验相互独立，候选相关会使其偏大，故标准误口径在该方向上略偏保守。

需要说清的是，这个“随机组合”在合成与真实两种数据上的含义并不相同。合成面板里只有 3 个特征带信号，随机组合大多由噪声主导；真实数据里 8 个价量特征本身都含信号，随机组合只是它们的随机线性混合，因此“选到噪声”这一合成结论本就没有外推基础。

复权口径本身改变了什么，本文另做了一项对照：保持特征与权重不变，只把标签由后复权换成不复权重算，8 个特征的截面 IC 变化均不超过 0.0011（脚本 `code/diag_adjust_effect.py`）。也就是说，在日频价量特征上，除权跳空并不是截面相关的显著来源——这一点与“必须复权否则信号被污染”的直觉预期相反，故如实记下。

读这张表要注意两件事。第一，**“多空夏普高”与“IC 显著”并不一致**：距均线偏离与 5 日动量的多空 OOS 夏普分别有 1.952 与 2.142，但它们的截面 IC 在 BH 校正下并不显著；反过来说，真正稳健的只有 3 个特征（量比、1 日反转、非流动性，均过 $|t| > 3$ 门槛），另有 2 个仅过 BH。第二，按同一标准，**5 日动量不应与量比并列**——它 $|t| = 1.32$，既不过 BH 也不过 $|t| > 3$；而真正过硬门槛的 1 日反转与非流动性在原文举例中反而没被提到。

表注：末列“通过校正”中，BH 指 Benjamini–Hochberg 5% 校正，$|t| > 3$ 指 Harvey–Liu–Zhu 门槛。两者严格程度并不同阶——$|t| > 3$ 相当于 $p < 0.003$ 的单次检验，而 BH 在多检验中段更宽松，因此上表按“两项都过 / 仅过 BH / 未通过”三级标注，判定顺序是先看 $|t| > 3$ 再看 BH。

统计上稳健，不等于可交易；但“不可交易”也不是一个笼统的结论。门槛有三道：做空的可实施性、换手带来的成本、以及市场暴露。前两道与**换手**直接相关，而换手在候选之间的跨度极大，因此必须逐候选看，不能用一个候选代表全部——详见下一小节。

表 18: 单特征对照：多空（不可实施）与仅多头（可实施）的 OOS 夏普，以及截面 IC 的显著性

特征	多空 OOS 夏普	仅多头 OOS 夏普	IC-IR	t	通过校正	读法
量比	3.056	0.838	−0.212	−9.03	BH、$\|t\|>3$	多空最强，方向压倒性依赖做空
1 日反转	1.211	0.435	0.159	6.77	BH、$\|t\|>3$	多头化后大幅回落
非流动性	1.516	1.271	0.092	3.91	BH、$\|t\|>3$	多头端最强，但混入市场 beta
20 日动量	1.409	0.694	−0.056	−2.38	仅 BH	多头化后回落
60 日动量	1.200	0.737	−0.053	−2.28	仅 BH	同上
距均线偏离	1.952	0.767	−0.044	−1.89	未通过	多空强、多头弱，IC 不显著
波动率（低波）	0.862	0.884	−0.040	−1.71	未通过	多头端贡献不低于多空
5 日动量	2.142	0.739	−0.031	−1.32	未通过	多空强，但 IC 不显著

21.4 可实施性核查：成本、换手与市场暴露

前两小节说明“信息层确有稳定信号”。这一小节要问的是：这些信号里**哪些能扛住摩擦**。答案高度依赖候选——换手在候选之间的跨度是 26 倍，用一个候选代表全部会得出错误结论。把 8 个特征的两种构建方式各算一遍（`code/audit_cost_by_candidate.py`），得到表 19。

表 19 里最要紧的一行是**非流动性**：年化换手只有 14–18 倍，含冲击后多空夏普仍为 1.014、仅多头仍为 0.892。16 种构建方式中只有这 2 种在含冲击后为正。换手分布为最小 14 倍、中位 86 倍、最大 358 倍。因此正确的表述不是“可预测但不可交易”，而是——**成本后能否存活取决于换手，低换手候选可以活下来，高换手候选活不下来**。表 17 所用的 `rand10` 恰落在最贵的一类里（年化换手 182 倍，含冲击档 −1.492、成本占毛收益 1.49），它演示的是这个条件的一端，而不是全部。

关于非流动性这一行,必须配一句限定,而且这条线索已被单独跟进（见 `docs/illiquidity_note.tex`）。这类因子的收益很可能反映的是**流动性补偿**而非可提取的 alpha——Amihud 类信号靠持有别人不愿持有的股票获利，而成本模型只能捕捉正常时段的成交冲击，捕捉不到“需要卖的时候恰好卖不掉”这件事。跟进分析给出了量化支持：按当期 ADV 分位**时点安全地**逐级筛除较不流动的个股后，含冲击夏普单调衰减（全部个股 1.02、保留较流动的 70% 为 0.69、50% 为 0.47、30% 仅 0.08），即**这份收益长在最不流动的那一端**。另有两点支撑与两点保留：十层收益近乎完全单调（层序相关 0.975，不是尾部噪声）、与其余七个因子的相关最大不过 0.27（不是已知异象的替身）、对成本假设不敏感（ADV 打到四分之一后仍有 0.91）；但逐年看 2019–2020 两年含冲击为负（−1.47、−0.30），稳定性不如全样本夏普暗示的那样好，且流动性压力期依赖的均值差 t 值

表 19: 候选级换手与成本敏感性（全样本；符号按原特征方向，未取样本内更优方向）

特征（口径）	年化换手	零成本夏普	含冲击夏普	读法
非流动性（多空）	14	1.221	**1.014**	成本后仍成立
非流动性（仅多头）	18	1.026	**0.892**	成本后仍成立
波动率（多空）	28	−1.123	−1.518	换手低，但信号方向为负
60 日动量（多空）	46	−1.394	−1.984	中低换手
20 日动量（多空）	77	−1.630	−2.800	成本耗损约 1.2
距均线偏离（多空）	92	−1.998	−3.496	成本耗损约 1.5
量比（多空）	154	−3.422	−7.190	高换手
5 日动量（多空）	152	−2.150	−5.166	高换手
1 日反转（多空）	322	−1.294	−10.235	换手最高，成本耗损 8.9
`rand10`（多空）	182	3.057	−1.492	论文表 17 所用候选

仅 1.47、不显著。

这一读法还要排除一个竞争解释：它会不会只是小市值因子？按单独方案做的规模中性化（流通市值取逐日股本，时点安全）给出了“无法分离”的中间答案——中性化后毛夏普由 1.221 降到 1.001（规模解释不了全部），但含冲击夏普被压到 0.611，跌破预设的 0.7 阈值，主因是换手从 14 倍升到 19 倍；且层内价差随规模单调衰减（最小规模层 15.1 个基点对最大规模层 2.0 个基点），效应确实集中在小盘端。**结论是：它过了成本关，但没过多可提取性关；且“不可提取”的理由经中性化后更清楚——收益集中在低流动端，中性化本身还会抬高换手。**

接下来是最后一道门：市场暴露。用同期等权全市场组合作基准（年化 12.1%、夏普 0.523、滚动前向 OOS 夏普 0.597），对两个代表候选各做一元回归分解——`rand10` 与分析中存活下来的非流动性，结果见表 20。

表 20: beta / alpha 分解（基准为同期等权全市场组合；alpha 为年化）

候选（口径）	beta	alpha	OOS 夏普	剥 beta 后夏普	读法
`rand10`（多空）	0.025	27.0%	2.671	3.030	近似市场中性
`rand10`（仅多头）	0.991	5.5%	0.780	1.082	几乎全是市场暴露
非流动性（多空）	0.027	11.4%	1.516	1.190	近似市场中性
非流动性（仅多头）	1.005	16.6%	1.271	1.061	市场暴露高，但 alpha 厚
基准本身	1.000	——	0.597	——	等权全市场

这张表把两个候选的差别摆清楚了。`rand10` 的仅多头口径 beta 为 0.991，基本是“加了一

层选股的市场组合”，剥离市场暴露后年化 alpha 只剩 5.5%；而非流动性虽然 beta 同样接近 1（1.005），剥离后的年化 alpha 有 16.6%——比 `rand10` 厚三倍。两者叠加换手差异（182 倍对 18 倍），结论就统一起来了：**可交易性不是“信号强弱”的函数，而是“换手与 alpha 之比”的函数**。表 18 里“仅多头 OOS 夏普 1.271”这类数字，其 beta 部分确实很大，但它对应的 alpha 也并非可以忽略；而 `rand10` 的 0.780 则主要是 beta。

还有一处必须交代：样本内最优的 `rand10` 虽是“随机线性组合”，但它与**量比的逐期截面相关为** -0.862——它基本是量比因子的反向近似（另与 1 日反转相关 -0.545、与非流动性 -0.270）。所以“随机组合在真实数据上胜出”并不意味着凭空出现了一个新信号，而是它把最强的单因子反着复制了一遍再稀释。这一点是对合成演示那一节的必要补充。

这组核查落在第 2 章的缝隙判据上：信息（IC 显著、DSR 通过）只是必要条件。从“可预测”到“可交易”，中间横着做空可实施性、换手成本与市场暴露三道门；真实数据把这句论断从口号变成了可量化的落差，并且给出了落差量的分布——而不是一个统一的否定。按本节与跟进分析的结果，三道门的通过情况可以分三档：`rand10` 这类高换手候选在第一道门就被成本拦下；非流动性过了成本关却卡在可提取性上（收益长在最不流动的一端，且有两个年度为负）；而真正三道全过的候选，在这 8 个因子里**一个也没有**。

边界（重要，且方向上偏乐观）：universe 只保留窗口末仍在市、且成交额达标的股票，存在**幸存者偏差**；作为基准的等权全市场组合是日频、零成本、且同样建在存活样本上，alpha 与 beta 均继承了这一口径的偏差；复权因子来自第三方而非本地权息文件，全量核验下最大相对偏差 3.1×10^{-3}，若该因子在某处滞后于真实除权日仍会残留局部跳空；涨跌停判定按四档固定幅度尝试，未处理上市首日、重大资产重组复牌等无涨跌幅限制或特殊安排；ADV 用窗口内成交额中位数而非滚动值，会平滑掉流动性骤降的时段；未按停牌频率进一步筛除标的。这些都会影响具体数值，方向上倾向于**高估可交易性**，故上文的可实施性对照应读作一个上界性质的结果，而非收益预测。

21.5 核验状态约定

证据表中的每条来源标注核验状态。本文实际使用两级：**已核验**（DOI/arXiv/官方链接与元数据互证）、**部分核验**（元数据确认，样本区间或参数细节待全文复核）。若仅能定位来源、无法确证元数据，则不入表。本文对定性叙述广泛引用，对具体数值一律谨慎——凡未在正文给出精确数值的结论，均因原文数值未经全文逐项核验。

21.6 剩余待办与已知缺口

1. **参数级复核**：证据表中标注“部分核验/待复核”的条目，其样本区间、阈值、成本模型等细节仍需逐篇读全文核对。
2. **复现状态的实际验证**：第 15 章的复现状态核验表依据公开仓库的可见信息（可用性、许可、基准披露、活跃度）判定；对“可复现”等级的工作，尚未全部做端到端实跑复算。
3. **私有数据结论不可验证**：另类数据与商业 LLM 类结论，因数据/模型不可得，本文只能标注“不可独立验证”。
4. **非英语文献**：检索以英文为主，中文及其他语种的实证工作可能被低估。

5. **真实数据实证的边界待收敛：**第 21.3 节已补后复权、交易制度掩码、逐股成本口径、全量复权核验、候选级换手对照与 beta 分解，但复权因子依赖第三方（本地权息文件加密不可解析），universe 带幸存者偏差，ADV 用窗口内中位数而非滚动值，且成本后的存活判定只在“多空 / 仅多头 × 8 个单特征”这 16 种构建方式上做过——更细的权重构造（如分层、行业中性）未逐一检验。
6. **非流动性跟进的未决项：**规模中性化已完成并给出“无法分离”的结论（见 `docs/illiquidity_note.tex`），但股本数据只有单一来源（本地 `base.dbf` 布局不可解析、无法交叉校验）。已对该来源做过五项形态自检（全部通过）与两次外部核对，残余风险仅限规模中性化一节、且方向使结论偏乐观；详见 `docs/share_source_note.tex`。压力期检验的证据也偏弱（$t = 1.47$）。

本文的态度是：**一份综述的可信度，不在于它覆盖了多少，而在于它诚实标注了多少没做到。**

22 术语表

下表给出正文反复使用的核心术语，便于非本领域读者快速对齐口径。术语按主题分组，不做穷尽罗列。

表 21：核心术语表

术语	释义与本文用法
可交易缝隙	**本文工作术语**。指扣除交易成本与冲击成本后、经多重检验校正仍为正的风险调整收益机会。与文献中 mispricing、profitable trading opportunity、limits to arbitrage 相关，但对齐关系见第 1 章的对齐表。
定价偏差（mispricing）	价格与基本面价值（或模型隐含价值）之间的偏离。本文视其为可交易缝隙的原材料，而非其本身。
alpha	相对基准的超额收益。本文强调其“净额”含义：扣成本、扣多重检验校正后仍存在者才算数。
信噪比	可预测成分与噪声成分的比值。金融预测的信噪比极低（月度截面 R^2 常在 0.5% 以下），这是过拟合风险的结构性来源。
IC / IR	信息系数/信息比率。IC 为信号与下期收益的截面相关系数，IR 为 IC 的均值与标准差之比。属“信号类”必报指标。
DSR（缩水夏普）	对夏普比率做选择偏差、样本长度与非正态校正后的显著性度量。数值为分位数（越大越显著）。
PBO（回测过拟合概率）	用组合对称交叉验证（CSCV）估计“样本内最优策略在样本外落到中位数以下”的概率。PBO 越高越可疑。
walk-forward（滚动前向）	逐段训练、逐段前向测试的切分方式。与一次性时间切分相对，后者容易被反复用于选模型而失去样本外意义。

表 21: 核心术语表

术语	释义与本文用法
前视偏差（look-ahead）	在计算时点使用了当时尚不可得的信息（如用披露日之前的财报、用全样本统计量标准化）。不会报错，只会让结果变好。
数据窥探与多重检验	测足够多的候选，总能找到“看起来有效”的。校正方法包括 Reality Check、DSR、PBO，以及提高 t 阈值。
冲击成本与参与率	大额成交对价格的自我冲击。参与率 = 成交额/当日成交量；冲击率常用平方根形式 $k\sqrt{\text{参与率}}$。
平方根律	市场冲击随参与率近似按平方根增长的经验规律，是本文成本层的默认形态。
Kyle λ	微观结构中价格对订单流的敏感度（价格冲击系数）。λ 越大，单位信息能换取的利润越薄。
信息租金耗散	信息被越多参与者使用，其超额收益越薄，机制由 Grossman–Stiglitz 悖论与 Kyle 模型刻画。
信息半衰期	信号预测力衰减到一半所需的时间。它决定了最优调仓频率（见第 2.5 节命题）。
CVaR	条件在险价值（尾部损失的期望），用于刻画极端情形下的风险。
波动率目标化	按预测波动率反向调整仓位，使组合风险保持在目标水平。
制度（regime）	市场所处的宏观/结构状态（如高波动、低波动、趋势、震荡）。制度切换是模型失效的主要来源之一。
容量与拥挤度	容量指策略能承载的资金规模；拥挤度指多少资金在用相似信号。二者共同决定超额收益的可持续性。
LLM 智能体	以大型语言模型为核心、能记忆与调用工具并做多步决策的交易代理。本文对其证据强度评价较低（见第 7 章）。
训练语料泄漏	用于回测的样本落在模型预训练语料覆盖期内，模型“知道答案”，使回测收益不可信。

参考文献

[1] H. Markowitz. Portfolio Selection. *The Journal of Finance*, 1952. doi.

[2] E. F. Fama. Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, 1970. doi.

[3] S. J. Grossman, J. E. Stiglitz. On the Impossibility of Informationally Efficient Markets. *American Economic Review*, 1980. doi.

[4] A. S. Kyle. Continuous Auctions and Insider Trading. *Econometrica*, 1985. doi.

[5] A. Shleifer, R. W. Vishny. The Limits of Arbitrage. *The Journal of Finance*, 1997. doi.

[6] T. Bollerslev. Generalized Autoregressive Conditional Heteroskedasticity. *Journal of Econometrics*, 1986. doi.

[7] J. D. Hamilton. A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle. *Econometrica*, 1989. doi.

[8] R. Almgren, N. Chriss. Optimal Execution of Portfolio Transactions. *Journal of Risk*, 2000. doi.

[9] R. Almgren, C. Thum, E. Hauptmann, H. Li. Direct Estimation of Equity Market Impact. *Risk*, 2005. （无 DOI）.

[10] R. T. Rockafellar, S. Uryasev. Optimization of Conditional Value-at-Risk. *Journal of Risk*, 2000. doi.

[11] A. J. McNeil, R. Frey. Estimation of Tail-Related Risk Measures for Heteroscedastic Financial Time Series. *Journal of Empirical Finance*, 2000. doi.

[12] O. Ledoit, M. Wolf. A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices. *Journal of Multivariate Analysis*, 2004. doi.

[13] A. Chekhlov, S. Uryasev, M. Zabarankin. Drawdown Measure in Portfolio Optimization. *International Journal of Theoretical and Applied Finance*, 2005. doi.

[14] C. R. Harvey, E. Hoyle, R. Korgaonkar, S. Rattray, M. Sargaison, O. Van Hemert. The Impact of Volatility Targeting. *The Journal of Portfolio Management*, 2018. doi.

[15] L. Cohen, A. Frazzini. Economic Links and Predictable Returns. *The Journal of Finance*, 2008. doi.

[16] P. C. Tetlock. Giving Content to Investor Sentiment: The Role of Media in the Stock Market. *The Journal of Finance*, 2007. doi.

[17] M. Baker, J. Wurgler. Investor Sentiment and the Cross-Section of Stock Returns. *The Journal of Finance*, 2006. doi.

[18] T. Loughran, B. McDonald. When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks. *The Journal of Finance*, 2011. doi.

[19] H. White. A Reality Check for Data Snooping. *Econometrica*, 2000. doi.

[20] R. Sullivan, A. Timmermann, H. White. Data-Snooping, Technical Trading Rule Performance, and the Bootstrap. *The Journal of Finance*, 1999. doi.

[21] C. R. Harvey, Y. Liu, H. Zhu. ... and the Cross-Section of Expected Returns. *The Review of Financial Studies*, 2016. doi.

[22] R. D. McLean, J. Pontiff. Does Academic Research Destroy Stock Return Predictability?. *The Journal of Finance*, 2016. doi.

[23] T. I. Jensen, B. T. Kelly, L. H. Pedersen. Is There a Replication Crisis in Finance?. *The Journal of Finance*, 2023. doi.

[24] D. H. Bailey, J. M. Borwein, M. López de Prado, Q. J. Zhu. Pseudo-Mathematics and Financial Charlatanism: The Effects of Backtest Overfitting on Out-of-Sample Performance. *Notices of the AMS*, 2014. doi.

[25] D. H. Bailey, M. López de Prado. The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *The Journal of Portfolio Management*, 2014. doi.

[26] D. H. Bailey, J. M. Borwein, M. López de Prado, Q. J. Zhu. The Probability of Backtest Overfitting. *Journal of Computational Finance*, 2016. doi.

[27] M. López de Prado. Advances in Financial Machine Learning. *Wiley*, 2018. （无 DOI）.

[28] S. Gu, B. Kelly, D. Xiu. Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 2020. doi.

[29] S. Gu, B. Kelly, D. Xiu. Autoencoder Asset Pricing Models. *Journal of Econometrics*, 2021. doi.

[30] L. Chen, M. Pelger, J. Zhu. Deep Learning in Asset Pricing. *Management Science*, 2024. doi.

[31] B. Kelly, S. Malamud, K. Zhou. The Virtue of Complexity in Return Prediction. *The Journal of Finance*, 2024. doi.

[32] G. Feng, S. Giglio, D. Xiu. Taming the Factor Zoo: A Test of New Factors. *The Journal of Finance*, 2020. doi.

[33] C. Krauss, X. Do, N. Huck. Deep Neural Networks, Gradient-Boosted Trees, Random Forests: Statistical Arbitrage on the S&P 500. *European Journal of Operational Research*, 2017. doi.

[34] T. Fischer, C. Krauss. Deep Learning with Long Short-Term Memory Networks for Financial Market Predictions. *European Journal of Operational Research*, 2018. doi.

[35] Y. Deng, F. Bao, Y. Kong, Z. Ren, Q. Dai. Deep Direct Reinforcement Learning for Financial Signal Representation and Trading. *IEEE Transactions on Neural Networks and Learning Systems*, 2017. doi.

[36] Z. Zhang, S. Zohren, T. Roberts. DeepLOB: Deep Convolutional Neural Networks for Limit Order Books. *IEEE Transactions on Signal Processing*, 2019. doi.

[37] A. Tsantekidis, N. Passalis, A. Tefas, J. Kanniainen, M. Gabbouj, A. Iosifidis. Forecasting Stock Prices from the Limit Order Book Using Convolutional Neural Networks. *IEEE Conference on Business Informatics*, 2017. doi.

[38] A. Ntakaris, M. Magris, J. Kanniainen, M. Gabbouj, A. Iosifidis. Benchmark Dataset for Mid-Price Forecasting of Limit Order Book Data with Machine Learning Methods. *Journal of Forecasting*, 2018. doi.

[39] J. Sirignano. Deep Learning for Limit Order Books. *Quantitative Finance*, 2019. doi.

[40] Á. Cartea, S. Jaimungal, J. Penalva. Algorithmic and High-Frequency Trading. *Cambridge University Press*, 2015. （无 DOI）.

[41] A. Vaswani, et al.. Attention Is All You Need. *NeurIPS*, 2017. link.

[42] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio. Graph Attention Networks. *ICLR*, 2018. link.

[43] B. Lim, S. Ö. Arık, N. Loeff, T. Pfister. Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting. *International Journal of Forecasting*, 2021. link.

[44] H. Zhou, et al.. Informer: Beyond Efficient Transformer for Long Sequence Time-Series Forecasting. *AAAI*, 2021. link.

[45] H. Wu, J. Xu, J. Wang, M. Long. Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting. *NeurIPS*, 2021. link.

[46] A. Zeng, M. Chen, L. Zhang, Q. Xu. Are Transformers Effective for Time Series Forecasting?. *AAAI*, 2023. link.

[47] A. F. Ansari, et al.. Chronos: Learning the Language of Time Series. *TMLR*, 2024. link.

[48] A. Das, W. Kong, A. Sen, Y. Zhou. A Decoder-Only Foundation Model for Time-Series Forecasting. *ICML*, 2024. link.

[49] K. Rasul, et al.. Lag-Llama: Towards Foundation Models for Probabilistic Time Series Forecasting. *arXiv*, 2023. link.

[50] Z. Jiang, D. Xu, J. Liang. A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem. *arXiv*, 2017. link.

[51] X.-Y. Liu, et al.. FinRL: A Deep Reinforcement Learning Library for Automated Stock Trading in Quantitative Finance. *arXiv*, 2020. link.

[52] Y. Nevmyvaka, Y. Feng, M. Kearns. Reinforcement Learning for Optimized Trade Execution. *ICML*, 2006. doi.

[53] T. Spooner, J. Fearnley, R. Savani, C. Koukorinis. Market Making via Reinforcement Learning. *AAMAS*, 2018. link.

[54] O. Guéant, I. Manziuk. Deep Reinforcement Learning for Market Making in Corporate Bonds. *Applied Mathematical Finance*, 2019. link.

[55] D. Araci. FinBERT: Financial Sentiment Analysis with Pre-Trained Language Models. *arXiv*, 2019. link.

[56] Y. Yang, M. C. S. UY, H. Huang. FinBERT: A Pretrained Language Model for Financial Communications. *arXiv*, 2020. link.

[57] A. H. Huang, H. Wang, Y. Yang. FinBERT: A Large Language Model for Extracting Information from Financial Text. *Contemporary Accounting Research*, 2023. doi.

[58] S. Wu, et al.. BloombergGPT: A Large Language Model for Finance. *arXiv*, 2023. link.

[59] H. Yang, X.-Y. Liu, C. D. Wang. FinGPT: Open-Source Financial Large Language Models. *arXiv*, 2023. link.

[60] A. Lopez-Lira, Y. Tang. Can ChatGPT Forecast Stock Price Movements? Return Predictability and Large Language Models. *SSRN*, 2023. doi.

[61] Z. Ke, B. T. Kelly, D. Xiu. Predicting Returns with Text Data. *NBER Working Paper 26186*, 2019. doi.

[62] Y. Yu, H. Li, Z. Chen, Y. Jiang, Y. Li, D. Zhang, R. Liu, J. W. Suchow, K. Khashanah. FinMem: A Performance-Enhanced LLM Trading Agent with Layered Memory and Character Design. *arXiv*, 2023. link.

[63] Z. Ding, et al.. Large Language Model Agent in Financial Trading: A Survey. *arXiv*, 2024. link.

[64] P. Glasserman, C. Lin. Assessing Look-Ahead Bias in Stock Return Predictions Generated by GPT Sentiment Analysis. *The Journal of Financial Data Science*, 2023. doi.

[65] O. Ratnaike. What Survives Honest Evaluation? Leakage-safe, Search-aware Assessment of LLM-Driven Trading. *arXiv*, 2026. link.

[66] Z. Li, et al.. Can LLM-Based Financial Investing Strategies Outperform the Market in the Long Run?. *arXiv*, 2025. link.

[67] A. Wang, et al.. StockBench: Can LLM Agents Trade Stocks Profitably in Real-World Markets?. *arXiv*, 2025. link.

[68] H. Li, et al.. INVESTORBENCH: A Benchmark for Financial Decision-Making Tasks with LLM-Based Agent. *ACL*, 2025. doi.

[69] M. Wiese, R. Knobloch, R. Korn, P. Kreibich. Quant GANs: Deep Generation of Financial Time Series. *Quantitative Finance*, 2020. doi.

[70] S. Takahashi, Y. Chen, K. Tanaka-Ishii. Modeling Financial Time-Series with Generative Adversarial Networks. *Physica A*, 2019. doi.

[71] J. Yoon, D. Jarrett, M. van der Schaar. Time-Series Generative Adversarial Networks. *NeurIPS*, 2019.（无 DOI）.

[72] H. Buehler, L. Gonon, J. Teichmann, B. Wood. Deep Hedging. *Quantitative Finance*, 2019. link.

[73] D. Byrd, M. Hybinette, T. H. Balch. ABIDES: Towards High-Fidelity Market Simulation for AI Research. *arXiv*, 2020. link.

[74] J. S. Park, et al.. Generative Agents: Interactive Simulacra of Human Behavior. *UIST*, 2023. link.

[75] D. Matsunaga, T. Suzumura, T. Takahashi. Exploring Graph Neural Networks for Stock Market Predictions with Rolling Window Analysis. *arXiv*, 2019. link.

[76] F. Feng, X. He, X. Wang, C. Luo, Y. Liu, T.-S. Chua. Temporal Relational Ranking for Stock Prediction. *ACM TOIS*, 2019. doi.

[77] Y. Chen, Z. Wei, X. Huang. Incorporating Corporation Relationship via Graph Convolutional Neural Networks for Stock Price Prediction. *ACM CIKM*, 2018. doi.

[78] W. Xu, et al.. HATS: A Hierarchical Graph Attention Network for Stock Movement Prediction. *arXiv*, 2019. link.

[79] H. Wang, et al.. Temporal and Heterogeneous Graph Neural Network for Financial Time Series Prediction. *arXiv/CIKM*, 2021. link.

[80] R. Sawhney, S. Agarwal, A. Wadhwa, T. Derr. Deep Attentive Learning for Stock Movement Prediction from Social Media Text and Company Correlations. *EMNLP*, 2020. doi.

[81] C. Zhu. Big Data as a Governance Mechanism. *The Review of Financial Studies*, 2019. doi.

[82] R. Jame, R. Johnston, S. Markov, M. C. Wolfe. The Value of Crowdsourced Earnings Forecasts. *Journal of Accounting Research*, 2016. doi.

[83] Z. Katona, M. Painter, J. Tsoukalas, J. Zhang. On the Capital Market Consequences of Big Data: Evidence from Outer Space. *SSRN*, 2018. doi.

[84] G. Costa, G. N. Iyengar. End-to-End Risk Budgeting Portfolio Optimization with Neural Networks. *Annals of Operations Research*, 2022. doi.

[85] Z. Zhang, S. Zohren, T. Roberts. Deep Learning for Portfolio Optimization. *The Journal of Financial Data Science*, 2020. link.

[86] R. J. Martin, F. Schöneborn. Mean Reversion Pays, but Costs. *arXiv*, 2011. link.

[87] X. Yang, et al.. Qlib: An AI-Oriented Quantitative Investment Platform. *arXiv*, 2020. link.

[88] A. Dickerson, et al.. The Corporate Bond Factor Replication Crisis. *arXiv*, 2026. link.

[89] O. B. Sezer, M. U. Gudelek, A. M. Ozbayoglu. Deep Learning for Financial Applications: A Survey. *Applied Soft Computing*, 2020. doi.

[90] S. Aziz, M. Dowling, H. Hammami, A. Piepenbrink. Machine Learning in Finance: A Topic Modeling Approach. *European Financial Management*, 2021. doi.