复权因子修正与交易制度掩码收紧

变更摘要（面向交接与复核）

叨客宁宁

1　这份摘要解决什么问题

综述第 21 章的真实数据实证此前用两处简化口径：价格不复权、涨跌停按固定阈值近似判定。这两处都会污染结果——除权跳空会混入收益与特征，近似阈值会把并未封板的交易日误判为不可成交（或相反）。本次变更把两处口径补齐，重跑 P0–P2 全流程，并同步论文、评审报告与说明文档。

变更只动真实数据那一支：合成面板（`code/data.py`）与评测层（`code/eval.py`）、成本层（`code/costs.py`）未改。合成路径已回归验证，结果与变更前逐位一致（PBO 0.567、区间 $[0.400, 0.584]$）。

2　口径变更对照

封板判定之所以逐日对四档幅度都试一遍，是为了不依赖任何名称表：ST（±5%）、主板（±10%）、创业板与科创板（±20%）、北交所（±30%）在判定式里自动区分，且只用当日及以前信息，不引入前视。

3　一处阻塞及其处置（须如实说明）

通达信本地权息文件 `gbbq` 是复权的标准本地方案，但本机三个安装中的该文件**均为加密存储**：文件头为记录数（193245 条、每条 29 字节，算术自洽），记录区首字节恒为密文前缀，无明文日期与代码。逐一验证并排除了明文、单字节异或、自密钥异或等假设后，判定逆向解密不可靠—解出错误因子的后果比不复权更严重，故放弃该路径。

改走第三方兜底：复权因子取 AKShare，缓存落盘。这条拼装链（通达信原始价 × AKShare 因子）与 AKShare 独立后复权价做了交叉核验，结果见表 2。

核验脚本 `scripts/verify_adjust.py`。结论：8 只中 7 只偏差不超过 1.2×10^{-4}，最大偏差出现在一只北交所个股、量级 7.8×10^{-4}，对日频价量特征可忽略。因子缓存现含 605 只、抓取失败 0 只。

表 1: 两处口径的变更前后对照

维度	变更前	变更后
价格口径	通达信原始日线，不复权；极端跳空（$\lvert r\rvert > 45\%$）按事件剔除	原始价乘后复权因子，先于一切特征与收益计算；跳空由复权自然消除，不再需要事件剔除
复权因子来源	无（未做复权）	AKShare 后复权因子，缓存至 `outputs/hfq_factors.json`；首次联网、之后离线复用
涨跌停判定	按板块固定阈值 $\lvert r\rvert \geq 10\%$ 或 20% 近似，含 0.5% 容差	封板价精确判定：四档幅度分别算 $\mathrm{round}(\text{前收} \times (1 \pm \mathrm{lim}), 0.01)$，收盘与最高（涨停）/最低（跌停）同时等于该价才判封板
ST 特殊处理	未处理	由 ±5% 档位直接识别，不依赖名称表、无前视
北交所	未纳入	纳入（±30% 档位），样本含 15 只
一字板	未单独处理	开 = 高 = 低 = 收且封板者记为不可成交
新股	未处理	上市后前 20 个交易日剔除
流动性	未筛除	日成交额中位数低于 2000 万元者剔除
覆盖率计算	按整个窗口计算，新股因历史不足被整体排除	按上市后活动窗口计算，新股保留至上市日之后（样本含窗口内上市 153 只）

表 2: 复权拼装链交叉核验（抽样 8 只）

代码	对照日数	最大相对偏差	备注
sh600519	1881	1.1×10^{-6}	因子末值 8.8825
sz000001	1881	4.1×10^{-6}	因子末值 154.0324
sz300750	1881	7.1×10^{-5}	—
sh600000	1881	4.8×10^{-5}	—
sh601318	1881	4.9×10^{-5}	—
sz002594	1881	1.1×10^{-4}	—
bj920002	571	6.6×10^{-5}	北交所
bj920000	1385	7.8×10^{-4}	北交所，全部样本中最大

表 3: 文件级变更清单

文件	类型	内容
code/real_data.py	重写	后复权、封板价精确判定、一字板、新股剔除、流动性筛除、北交所、因子抓取与增量落盘、快照返回 fac/adj/raw 便于审计
code/run.py	修改	--real 分支打印数据统计、统计写入试验账本、输出 trial_ledger_real.json
code/diag_ls_lo.py	新增	单特征多空与仅多头（可实施）对照，为论文第 21 章表提供数字
code/diag_adjust_effect.py	新增	复权与否对截面 IC 的影响对照
scripts/verify_adjust.py	新增	复权拼装链交叉核验
outputs/hfq_factors.json	新增	复权因子缓存（605 只）
sections/checklist.tex	修改	§21 真实数据最小实证按新口径重写，数字与边界全部更新
sections/repro_protocol.tex	修改	协议对照表中“时点快照”“交易制度掩码”两行
docs/peer_review.tex	修改	M13 状态与页数
README.md	修改	目录结构、运行命令、数据说明、外部依赖标注

4 变更清单

实现中有个中途修掉的缺陷值得记录：新股剔除最初取的是“窗口内序列的首个交易日”，这会把窗口开始前就已上市的股票误剔除 20 天。已改为按真实上市日判定—只有窗口内上市者才剔除，且覆盖率也按上市后活动窗口计算。

5 实测结果对照

样本为沪深与北交所 A 股，窗口 2019-01-02 至 2026-10-08，$T = 1881$、$N = 400$、$K = 8$，候选池 61 个。变更后快照校验和 781cadd68dfbd170（变更前为 a08b6e4eca17d7c4）。

结论方向没有变：信息层确有稳定信号（DSR 标准误口径 0.9991、PBO 0.000），但换成可实施的仅多头口径后夏普从 3.056 落到 1.271，成本再把多空从 3.057 压到 1.164。也就是说，缝隙判据里“可预测不等于可交易”这一条，在收紧口径后依然成立。

有一处**数字不可直接对比**需要点明：“不可成交单元占比”从 0.0563 升到 0.2134，并非可交易性恶化。变更后 universe 纳入了 153 只窗口内上市的新股（覆盖率改按活动窗口计算），这些股票上市前的单元格天然无数据、计入不可成交，从而抬高了总量。真正可比的是有效样本内的封板占比—变更后为 1.97%（涨停 1.19%、跌停 0.38%），一字板 0.16%。

表 4: 实跑结果：变更前（`real_run.txt`）与变更后（`real_run_v2.txt`）

项目	变更前	变更后
样本内最优候选	rand26，样本内夏普 3.404	rand10，样本内夏普 3.649
滚动前向 OOS 夏普	3.109	2.671
单次切分 OOS 夏普	3.129	3.595
OOS 高于它的候选数	2	1
IC 均值 / IR	0.0299 / 0.208	0.0129 / 0.088
成本三档夏普	3.176 / 2.394 / 1.876	3.057 / 2.043 / 1.164
DSR（标准误 / 离散口径）	1.0000 / 0.0000	0.9991 / 0.0022
PBO（切分区间）	0.000（$[0.000, 0.002]$）	0.000（$[0.000, 0.000]$）
量比多空 OOS 夏普	3.839	3.056
最优仅多头 OOS 夏普	1.721	1.271

6 复权到底改变了什么：一项独立对照

最初起草时写过一句“复权后 IC 从 0.0299 降到 0.0129，因除权跳空被消除”——这是错的。两轮实跑的 IC 来自**不同的候选**（rand26 与 rand10），且 universe 与掩码口径同时变了，不能归因于复权。

为把这件事做实，另做了一项单变量对照：保持特征与权重不变，只把标签换成原始收盘价的相邻比，两列 IC 之差便只可能来自除权跳空。结果见表 5。

表 5: 复权口径对截面 IC 的影响（同特征、同掩码，仅标签不同）

特征	后复权 IC	不复权 IC	差
1 日反转	0.0240	0.0241	−0.0001
5 日动量	−0.0051	−0.0061	+0.0011
20 日动量	−0.0098	−0.0101	+0.0004
60 日动量	−0.0094	−0.0101	+0.0006
波动率	−0.0072	−0.0067	−0.0005
量比	−0.0303	−0.0304	+0.0000
距均线偏离	−0.0077	−0.0087	+0.0009
非流动性	0.0108	0.0114	−0.0005

八项差异的绝对值全不超过 0.0011。也就是说，在日频价量特征上，除权跳空**不是**截面相关的显著来源——这与“不复权就会污染信号”的直觉预期相反。复权仍然应该做（收益口径正确、极端跳空不必再靠人为规则剔除），但它带来的收益是口径干净，而非信号结构改变。两轮 IC 的差别应主要归于 universe 与掩码收紧以及候选不同。

这条对照的价值不在于复权，而在于它示范了一件事：把“看起来合理的因果解释”拿去单变量验证，结论可能相反。文档与代码中因此保留该脚本（`code/diag_adjust_effect.py`），供

后续复核。

7 复现与核验

表 6: 复现步骤与核验证据

步骤	命令与产出
复权核验	`python scripts/verify_adjust.py` → 表 2
全流程实跑	`cd code; python run.py --real` → `trial_ledger_real.json`
多空/仅多头对照	`python diag_ls_lo.py` → 论文第 21 章表
复权影响对照	`python diag_adjust_effect.py` → 表 5
合成路径回归	`python run.py` → PBO 0.567、区间 $[0.400, 0.584]$，与变更前一致
论文编译	`xelatex main.tex` 连续三次
质量门	编译错误 0、Overfull 0、正文引用键 90 = 参考文献 90

试验账本中的关键字段已逐项与论文表格核对（快照校验和、选中候选、OOS 夏普、IC/IR、成本三档、DSR 两口径、PBO 及切分区间、不可成交占比）全部一致。

8 未收敛的边界

1. **复权因子依赖第三方**。本地权息文件加密不可解析，因子来自 AKShare；若该因子在某处滞后于真实除权日，会残留局部跳空。这是本次变更引入的唯一新增外部依赖，已在论文与 README 中标注。
2. **幸存者偏差仍在**。universe 只保留窗口末仍在市且成交额达标的股票，退市股不在本地库中。
3. **仅多头未做 beta 中性**。“最优仅多头 OOS 1.271”中含市场 beta，未剥离。
4. **涨跌停判定的例外情形**。按四档固定幅度尝试，未处理上市首日、重大资产重组复牌等无涨跌幅限制或特殊安排。
5. **停牌频率未进一步筛除**。仅用成交额中位数做了一道流动性门槛。

以上都会影响具体数值，方向上倾向于高估可交易性，故“仅多头更弱”这一对照应读作上界性质的结果，而非收益预测。

9 后续变更（第二轮评审之后）

本摘要表 4 中“成本三档”一列反映的是本摘要所述变更刚完成时的状态。此后第二轮评审指出：冲击模型的 ADV 取常数 10^9 元，而样本个股成交额中位数只有 7.46×10^7 元，相差 13.4 倍，使参与率与冲击成本被系统性低估。该问题已修正：**“含冲击”一档由年化** 0.104、**夏普** 1.164

变为年化 −0.134、**夏普** −1.492（即由正转负），费率也改为按 A 股构成计入并按日期分段印花税。

该轮同时补齐了单特征多重检验校正、DSR 两口径的取舍说明、universe 清单冻结与 beta/alpha 分解。完整的口径对照、实测数据与残留边界见**另一份文档**：`docs/change_summary_round2.tex`（成本口径修正与统计披露补齐：变更摘要）。本文不再重复其表格，以免同一组数字出现两个版本。

这一变化不改变本摘要所述变更的任何结论，反而使“可预测不等于可交易”的证据更强；论文第 21 章、第 11 章与第 16 章协议表均已同步。

此后第三轮评审又指出一处更细的问题：第 21 章用样本内最优候选演示成本吞噬收益，而该候选恰好是换手最高的一类（年化 182 倍），用它代表全体会得出过宽的结论。实测表明换手在候选间跨度达 26 倍，低换手的候选（非流动性，年化 14–18 倍）在含冲击后夏普仍为 1.01 / 0.89，是 16 种构建方式中仅有的两种存活者。因此论文把结论由“可预测但不可交易”改写为条件式：**成本后能否存活取决于换手**。该轮的八条意见与逐条证据见 `docs/peer_review_round3.tex`。

值得记一笔的是：本文面向非技术读者的摘要（`docs/investor_brief.tex`）早就用“同一个信号，仅仅因为交易频率不同，就从亏钱变成赚钱”表述过同一件事——这一轮实际是把正文的结论收回到摘要一直以来的口径上。