股本数据单一来源风险：补充说明

已知什么、未知什么、影响往哪个方向偏

叨客宁宁

1　这份说明针对什么

《非流动性线索的跟进分析》第 5 节的规模中性化，其规模代理为流通市值 = 原始收盘价 × 当日流通股本。股本只有 **AKShare** 一个来源：本地 `base.dbf` 的记录布局无法可靠解析（`LTAG` 字段读出恒为 0），原计划的来源间交叉校验因此无法执行。该节把这一点标注为“残留风险”，但没有说明风险的**确切边界**与**影响方向**。

本说明补上这两件事。核心结论先行：**风险不能消除，但可以被界定；且在方向上是温和的——它使中性化后的结果偏乐观，而不是偏悲观。**

2　风险分三层，逐层界定

把“单一来源”这个笼统说法拆开，风险其实是三个不同的问题，可验证程度依次递减。

表 1: 风险的三层分解

层次	问题	状态
第一层：脏数据	序列里有没有非正、缺失、明显错位的值	**已排除**（形态自检 5 项全过，见表 2）
第二层：口径与锚点	字段是不是流通股本、量级对不对	**已抽样验证**（口径判定 1 只、外部锚点核对 1 只）
第三层：系统性偏差	口径定义是否整体偏离、变动日是否整体滞后	**无法排除**——内部检验对这类错误天然不敏感

第三层是这份说明真正要交代的东西。第一、二层可以靠检验解决，第三层不能：如果数据源在定义上整体偏了（例如把某个口径当成流通股本），或者所有变动都比真实生效日晚一天，那么**所有内部一致性检验都会照常通过**——因为序列依然干净、分段常数、变动集中在合理月份。能发现这类错误的只有来源间比对或人工核对，而前者在本环境不可得。

3 已做的四项验证

3.1 口径判定

字段单位是股，量级与 A 股流通股本一致。用中国平安（sh601318）判定口径：取值 1.0660×10^{10}，对应 A 股流通约 108 亿股，而非总股本约 182 亿股。** 确认是流通股本 **——这一点重要，因为用总股本会系统性放大大盘股的规模分位。

3.2 外部锚点核对（G1）

这是唯一一次与数据源之外的比对。宁德时代（sz300750）期末流通股本取值为 4.2606×10^9 股，与东方财富披露的 **426,061.71 万股**完全一致；同期总股本为 46.27 亿股，进一步印证口径。

需要如实说明这次验证的覆盖范围：**它证明的是“一只股票的期末值正确”，不是“400 只的整条历史序列正确”**。把单个锚点的可信度外推到全样本，本身就是一种未经检验的推断。

3.3 序列形态自检

既然无法做来源间比对,退一步做不依赖外部来源的形态检验（脚本 `code/audit_share_source.py`，输出见 `outputs/audit_share_source.txt`）。这类检验不能证明数值正确，但能排除若干类明显错误。

表 2: 五项形态检验的结果

编号	检验项	结果	判定
C1	非正 / 缺失股本	400 只全部合格，0 只异常	通过
C2	变动次数与幅度	总变动 5195 次；幅度中位 1.0005（即多为微幅增量）；>3 倍或 <0.5 倍的跳变 70 次	通过（见下）
C3	变动月份分布	6 月 19.7%、12 月 13.9%、3 月 10.8%、9 月 10.1%、7 月 8.7%、1 月 7.3%	通过
C4	变动后短期回退（抖动）	928 次，但**幅度中位** 0.0001%、**最大** 0.06%；**>1% 的 0 次**	通过
C5	异常值清单	76 条，均为大额跳变	通过（见下）

两处需要解释，否则容易被误读为问题。

关于 70 次大跳变：它们不是错误，而是 A 股**限售股解禁**的真实形态——上市初期流通股本很小，首发限售股解禁当日阶跃式放大数倍。例如京沪高铁 2021-01-21 由 3.21×10^9 股跳至 2.73×10^{10} 股（8.5 倍）。这类跳变若被“修正”掉，反而会引入错误。

关于 928 次抖动：数量看着多（占全部变动的 17.9%），但幅度中位仅 0.0001%、最大 0.06%，且没有一次超过 1%。这符合数据源的**精度噪声**特征（某几日按较少小数位给出），对规模分位的

影响可以忽略。这一项若只看次数会得出“数据不稳定”的错误印象，所以必须连幅度一起看。

3.4 该自检能排除什么、不能排除什么

能排除：非正与缺失、字段互换这类结构性错误、按年度或报告期错位的大规模错误、单位换算错误（若单位错了，跳变幅度会呈现统一的量级偏移，C2 的分位数形态会异常）。

不能排除：任何“整体一致、方向一致”的错误。这正是第三层的定义。

4 残余风险的影响方向：上界性质

这一点比风险本身更重要。规模中性化用 ln(流通市值) 作控制变量；若该变量含有测量误差，横截面回归会出现**衰减偏误**——控制变量越噪，能“剔除”的规模成分越少，残差里留下的规模暴露越多，中性化后的表现就越接近未中性化的原值。

也就是说：**在股本数据完全准确的情形下，规模中性化后的表现不会高于实测值**。实测的含冲击夏普 0.611 因此是一个**上界**。这个方向的含义很具体：

- 若真实值明显低于 0.611，则本轮“无法分离”的判定应向**“由规模驱动”**一侧移动；
- 换言之，当前的结论**已经是对“存在独立流动性维度”这一读法最有利的一侧**。即便股本数据有系统性噪声，也不会把它推向“存在独立维度”，只会推向更强的否定。

反过来也要说清：日常噪声的量级很小（C4 抖动最大 0.06%、C2 变动幅度中位 1.0005），因此这一衰减偏误在实际量级上大概有限；真正可能造成较大偏差的是“变动日整体滞后”这类时点错误，而它恰好无法用内部检验发现。

5 影响范围：哪些结论受影响

表 3: 结论受影响情况

结论	依赖股本？	说明
规模中性化三组结果（M1 层内价差 8.5bp、M2 0.611、M3 0.607）	**是**	唯一受影响的结论；且如上所述方向偏乐观
十层收益的单调性（相关 0.975）	否	只用非流动性信号与收益
与其余七个因子的相关（最大 0.27）	否	同上
成本稳健性（ADV 打到四分之一仍有 0.91）	否	只用成交额与收益
可投资子集的衰减（1.02 → 0.08）	否	用 ADV 分位，不用股本

换句话说：股本来源风险**只影响规模中性化这一节，不影响整条非流动性线索的其他部分**。这也意味着该风险的处置成本应当与它的影响范围相称——不值得为它推翻已经成立的其他结论，但足以要求把“无法分离”这一判定标注为**依赖单一来源**。

6 补强路径

表 4: 从“已做”到“可做”的四级补强

级别	做法	能解决哪一层	状态
一	形态自检（本说明第 3.3 节）	第一层	**已完成**
二	抽样人工核对：取 20 只跨规模分位的个股，逐只比对股本结构历史（含变动日期）	第二层＋部分第三层	可立即执行，约需人工访问公开资料
三	解析本地 `vipdoc/cw` 逐股财务文件中的股本字段，作为第二来源	第三层	需先验证格式；参照 `gbbq` 先例，解析不可靠则放弃
四	引入付费数据源的股本变迁表（Wind / 聚源）	第三层	超出本项目的数据边界

建议的处置是：**把二级补强列为待办，但不阻塞当前结论**。理由是影响范围已被界定（只涉及规模中性化一节）、方向已知（偏乐观），且该项验证需要人工核对，与“先记录缺口、再按优先级补”的一贯做法一致。

7 结论

三句话：

第一，股本数据的单一来源风险**无法在本环境内消除**——内部检验对系统性偏差天然不敏感，这是方法论上的限制，不是执行上的疏忽。

第二，风险已被**界定到可操作的颗粒度**：已排除脏数据与口径错误（五项形态检验、一次口径判定、一次外部锚点核对），无法排除的是整体一致的系统性偏差；影响范围仅限规模中性化一节。

第三，也是最重要的一点：残余风险的方向是**使实测的中性化后表现偏乐观**。因此本轮“无法分离”的判定不是被数据问题撑住的结论，而是在对“存在独立流动性维度”这一读法最有利的一侧给出的——若股本数据更准确，结论只会更偏向“由规模驱动”。

这与本文的一贯口径一致：**承认一项风险时，要说清它把结论推向哪一边**。只说“存在风险”而不说方向，等于把判断的负担转给了读者。