剥离规模因子的补充方案

为非流动性线索收尾：数据来源、中性化方法与验收判据

叨客宁宁

1　要解决什么，以及什么算解决

1.1　问题

《非流动性线索的跟进分析》的结论是：Amihud 非流动性过了成本关，但没过多可提取性关——含冲击夏普 1.02，可是这份收益长在最不流动的一端（时点安全地逐级筛到只保留较流动的 30% 时，夏普衰减到 0.08）。据此推断它更像流动性补偿而非可提取 alpha。

这个推断有一个**尚未排除的竞争解释**：Amihud 非流动性在横截面上与市值高度相关，因此上述结果也可能只是说“小市值因子在小盘股里更有效”——那样的话，本文关于“流动性补偿”的表述就需要改写，因为收益的驱动变量不是流动性，而是规模。

本方案要排除的正是这一项：**在控制规模之后，非流动性的收益还剩多少**。

1.2　判据（先说清什么算通过）

主判据沿用第 21 章的成本口径（逐股 ADV、佣金＋过户费＋分段印花税、平方根冲击）：

- **规模中性化后，含冲击夏普仍** ≥ 0.7：判定存在超出规模解释的流动性维度；
- **中性化后落在 0.3 以下**：判定此前结果主要由规模驱动，流动性补偿的表述须撤回或大幅弱化；
- 落在两者之间：如实报告为“无法分离”，并把区间写进论文。

辅助判据两条：十层收益的单调性（0.975）在中性化后是否保留；2019–2020 两个负年度是否依旧。

2　数据来源：三条路线的实测取舍

“算不出市值”这个限制来自本地日线不含股本。本轮把三条可能的数据路线都实测了一遍，结论与依据如下。

路线 A 不只是“覆盖不全”的问题。它是**当前快照**——用今天的股本去除 2019 年的价格，等于把七年里所有送转与增发都提前告诉了模型。这个错误的量级很大，见表 2。

表 1: 股本数据三条路线的实测结果

路线	实测情况	结论
A. 本地 `T0002/hq_cache/base.dbf`	含 `ZGB`（总股本）、`LTAG`（流通 A 股）等字段；但去重后仅 2139 只代码，**缺贵州茅台、宁德时代、北交所全部个股**；且为**当前快照**，无历史	否决（覆盖不全＋前视）
B. 本地 `vipdoc/cw` 逐股财务文件	文件齐全（9229 个：gpsh 4544、gpsz 4051、gpbj 339、gpcw 295），`gpsh600519.dat` 存在（347632 字节）	备选（格式未公开、需逆向，参见 `gbbq` 加密不可解析的先例）
C. AKShare `stock_zh_a_daily` 的 `outstanding_share` 字段	**逐日时点值**，在股本变动处阶跃；沪深北均可取	**主选**

表 2: 流通股本在样本期内的变化（AKShare 时点数据实测）

代码	期初流通股本	期末流通股本	变化倍数	取值阶跃次数
sh600519	1.2562×10^{9}	1.2501×10^{9}	0.995	3
sz002594	1.1422×10^{9}	3.4871×10^{9}	3.053	16
sz300750	2.1724×10^{8}	4.2606×10^{9}	19.612	66
bj920002	4.7500×10^{6}	4.4597×10^{7}	9.389	8

宁德时代的流通股本在样本期内放大了近 20 倍。用当前快照回填 2019 年的市值，这家公司会被误判成一只大盘股——它的规模分位会从当年的位置被拉到完全不同的地方。这正是本文反复强调的那类错误：不是算错，而是口径里混进了未来信息。

口径确认：该字段是**流通股本**而非总股本。用中国平安（sh601318）验证：取值为 1.0660×10^{10}，对应 A 股流通约 108 亿股，而非总股本约 182 亿股。以流通市值作为规模代理是 A 股研究的通行做法，本方案沿用。

交叉校验（沿用复权因子的做法：本地验证第三方）：把 `base.dbf` 中 2139 只重叠个股的 `LTAG` 与 AKShare 的最新 `outstanding_share` 比对，报告偏差分布。两者若一致，说明第三方字段在“当前时点”这一锚点上可信；不一致的个股单独列出，不纳入。

3 中性化方法：三种，互相印证

单用一种方法容易被“方法本身的假设”绊住，故设计三种由粗到细的做法，结论一致才采信。

3.1 M1 双重排序（最直观，无模型假设）

每个截面先按**当期流通市值**分 5 层，再在每层内部按非流动性分 5 层，得到 5×5 网格。观察两件事：同一规模层内“最不流动减最流动”的价差是否稳定为正；以及该价差随规模层的变化。这一方法不依赖任何回归假设，任何异常都能被直接看见。

3.2 M2 截面回归取残差（主判据用）

每期做横截面回归 $\text{Amihud}_i = a + b\ln(\text{流通市值}_i) + e_i$，用残差 e_i 作为规模中性的流动性信号，重建多空组合，按第 21 章口径计算含冲击夏普。这一口径与国际文献里“规模中性化的流动性因子”一致。

可选加强：本地 `T0002/hq_cache/tdxhy.cfg`（150550 字节）含行业分类，可在回归中加行业哑变量，同时做行业中性化。是否加入取决于该文件能否可靠解析——按路线 B 的同一标准，解析不可靠则只做规模中性。

3.3 M3 规模中性组合（最保守的构造）

在每个规模层内分别构造非流动性多空，再对各层的结果等权合成。此法不依赖回归，且组合的规模暴露被构造性地压掉；代价是多空两端的个股更少、噪声更大。它用于给 M2 的结论做一个下界式的对照。

表 3: 风险与本方案的应对

风险	应对
股本变动日的时点对齐	该字段按日给出，但“何时生效”需核对：抽 sz300750 的 66 次阶跃中的 3 次，与公开送转 / 增发公告日期比对（验证门 G1）。若生效日晚于公告日，属保守（不会前视）；若早于，则须回退。
第三方字段的重述风险	与复权因子同样的处置：结果缓存到 outputs/outstanding_shares.json，记录快照日期；若后续重述，以缓存为准并标注。
流通股本　总股本	明确采用流通市值；A 股限售股占比在样本期内变化，故规模分位会有噪声。此点写入论文边界。
规模分层本身的前视	M1 / M2 / M3 一律使用**当期**流通市值，不使用全窗口均值。这正是《跟进分析》里踩过的坑：同一检验用不用时点信息会给出**方向相反**的结论。
样本被分层后变薄	5×5 网格下每格约 16 只（$N = 400$ 时），噪声上升。故同时报告 2×5 的粗网格结果作对照。

4 风险、边界与验证门

验证门三条：**G1** 股本变动日的时点对齐抽样核对通过；**G2** M1 / M2 / M3 三种方法的结论方向一致（都保留或都消失）；**G3** 中性化前后使用完全相同的成本口径与 ADV，差异只来自信号本身。

5 交付物与工作量

表 4: 交付物

交付物	内容
code/audit_size_neutral.py	M1 / M2 / M3 三种中性化，输出含冲击夏普、十层单调性、逐年夏普；附 2×5 粗网格对照
outputs/outstanding_shares.json	400 只的逐日流通股本缓存（首次联网，之后离线复算）
docs/illiquidity_note.tex 增补一节	把结论并入现有跟进报告，不另立文档
论文第 21 章	按第 1 节的三档判据更新那句限定；若结论反转，剩余待办中的“无法剥离规模因子”一项相应删除

工作量与已知任务同量级：约 400 次接口调用（与复权核验的 400 只同规模），缓存后离线

可复算。核心计算（分层、回归、组合）都是轻量的横截面操作，不涉及此前导致内存问题的岭回归路径。

6 两种结果各意味着什么

先把两种结果的含义写下来，是为了避免“无论跑出什么都讲得通”的事后解释。

若中性化后消失（夏普 ≤ 0.3）：说明此前的 1.02 主要由规模解释，非流动性只是小市值因子的一个代理。论文应把结论从“流动性补偿”改成更强的否定：*在这 8 个因子里，没有任何一个能同时通过信息关、成本关与可提取性关*——这比现在的表述更彻底，也更符合本文的主题。

若中性化后存活（夏普 ≥ 0.7）：说明存在一个超出规模的流动性维度。论文应更新为：*该维度在规模中性化后仍然存在，但收益仍集中在低流动端，因此仍应理解为承担流动性风险的报酬而非免费 alpha*。

若落在中间：如实标注“本样本无法分离规模与流动性”，并在剩余待办中保留该项——不为了给结论一个漂亮的收尾而把中间结果说成两端之一。

一句话概括本方案：它要买的不是一个新的收益来源，而是一次**证伪机会**——用规模中性化去检验上一轮那个“流动性补偿”的判断是否站得住。若站不住，论文的结论会更强；若站得住，结论会更准。两者都比现在这种“推断存在竞争解释但未排除”的状态好。