

生成式 AI 文本的“AI 味”：成因、检测、去除与审稿实践

一份基于实证文献的综述

配套文件：证据表与比较矩阵（证据表与比较矩阵.md）

摘要：大语言模型生成的文本在统计上可被识别，这一可识别性在写作实践里被称作“AI 味”。本文基于 2023–2026 年间的实证文献，把“AI 味”从一个审美直觉还原为一组可测量的统计签名——低困惑度、低突发性（句长波动）、模板化词汇、过度连贯的语篇与缺乏立场的认识论姿态——并逐一解释这些签名为什么必然出现：自回归采样天然偏向低熵路径，RLHF 进一步奖励“无害且得体”的中庸表达，两者叠加造成风格的统计坍缩。随后综述检测技术的谱系（统计法、分类器、水印、检索式防御与商业工具）及其固有边界，梳理去除 AI 味的三条真实路径与两类常见误区，给出审稿人可执行的识别清单，最后落到符合人类写作习惯的写作建议。全文区分已核实验事实与行业观察，引用均链接原始来源。

关键词：AI 生成文本检测；文体计量；困惑度；突发性；学术诚信；人机协同写作

1 引言：AI 味不是一个审美问题，而是一个统计问题

在讨论如何“去除论文 AI 味”之前，先要回答一个问题：我们凭什么说一段文本“有 AI 味”？直觉给出的答案五花八门——太工整、没个性、爱用“值得注意的是”、每段都三点式……这些印象都对，但它们只是症状。实证研究给出的判断是：AI 文本之所以能被识别，不是因为“写得差”，恰恰相反，是因为它在特定统计维度上“好得太均匀”了。检测器抓得最准的 AI 文本，是那种流畅、规范、语法零瑕疵的文本；真正的问题不是写得不好，而是写得过于稳定地“正确”。

这个观察来自两方面的证据。其一是检测技术本身：从 DetectGPT 的概率曲率到 Binoculars 的跨模型困惑度，再到以 burstiness（句长波动）为核心的文体计量，检测器捕捉的都是统计签名而非语义内容 [D1] [D2] [D5]。其二是语料层证据：Liang 等对 95 万篇论文的统计显示，LLM 修改文本的比例在计算机科学摘要中升至 17.5%，并伴随特定词汇的异常升频 [S1]。

本文讨论三个不同立场的读者：写作者想知道怎么让文字像自己的；审稿人想知道怎么识别；技术研究者想知道检测与去除的边界在哪里。三者的利益并不完全一致，甚至互相冲突——写作者希望文本自然，审稿人希望文本可核验，而“去除 AI 味”既是写作改进，也可能沦为规避检测的手段。因此本文在实证综述之外，也划出伦理边界：让 AI 辅助的写作成为自己的写作，与用工具伪造人工作品，是两件事。

2 为什么会产生 AI 味：生成机制与统计坍缩

“AI 味”不是偶然的缺陷，而是大语言模型生成机制的必然产物。可以从三个层次理解它。

2.1 自回归采样：低困惑度是天然属性

大语言模型按“给定前文，预测下一个词”的方式生成文本，每一步都从词表上取一个概率分布。为了得到流畅输出，解码必须偏向高概率路径。结果是：模型每一步都选择“最不让人意外”的下一个词。人类读者会对这种文本感到乏味，但检测器看到的是另一回事——文本中几乎每个词都在模型的预测之内，整段文本的困惑度（perplexity）系统性偏低。DetectGPT 利用的正是这一点：把一段文本随机扰动后，若原文本的模型对数概率显著高于扰动样本，就判定为机器生成 [D1]。

困惑度偏低的直接后果是词汇选择的“回归平均”：罕见词、方言、个性化搭配被过滤，留下的是在训练语料中出现频率最高的表达。这解释了为什么不同厂商、不同训练管线的大模型生成同一主题的文本，读起来却像孪生——它们在收敛到同一条统计平均路径。

2.2 RLHF：把“得体”锻造成平庸

训练的后半程通常引入基于人类反馈的强化学习（RLHF），奖励模型输出“有用、无害、诚实”的回应。问题在于，“无害”在统计上意味着回避立场、弱化断言、面面俱到；“有用”意味着结构完整、分段工整、结论兜底。这两项奖励叠加，把模型推向一种统计学意义上的“中庸表达”：

- 对冲与平衡措辞：*on the other hand*、“值得注意的是”“综上所述”这类套语被高频使用，因为它们在语义上安全；
- 自信化普遍断言：为了“有用”，模型倾向于给出确定性的总结性判断，而非带着条件与例外的具体陈述；
- 情感与隐喻的压制：句法上更标准，隐喻更少，情绪表达更平 [S6]。

2.3 突发性缺失：没有意图，就没有节奏

人类写作有一个检测器最看重的统计特征——burstiness，即句长与复杂度的波动。人写文章时，一句长句铺陈，紧接着一个短句收束，这种节奏变化来自修辞意图：哪里该强调，哪里该喘息，是作者在具体语境中做出的选择。模型没有这种意图，它在每一步只追求局部最优，于是句长分布趋于均匀。多项研究在不同语料上一致发现，AI 文本的 burstiness 显著低于人类文本 [S5]。值得注意的是，这个差异在人类读者已经无法在内容层面区分人机文本时依然存在——它存在于统计层，而不在语义层。

2.4 小结

AI 味的三个来源——自回归的低熵路径、RLHF 的得体奖励、缺乏意图的节奏——共同造成一种“风格坍塌”：文本在统计上高度可预测，在表达上高度均质。理解这一点很重要，因为后续的检测与去除，本质上都是围绕这三个来源展开的。

3 AI 味的具体表现：五层信号

把文献中的发现组织成五层信号。前两层可以被机器精确测量，后三层更多依赖人的判断。

3.1 概率信号：困惑度与突发性

这是最可测量的一层，也是 GPTZero 等工具的检测依据：AI 文本困惑度低（词的选择高度可预测），突发性低（句长波动小）。一项针对创意写作的文体计量研究显示，AI 文本在所有测试语料上 burstiness 均显著更低，即使人类评分者无法区分人机内容 [S8]。需要强调的是，这层信号与“文笔好坏”无关：法律文书、学术正文这类经过精修的正式人类文本，同样表现为低困惑度、低突发性——这正是检测器误报的根源。

3.2 词汇信号：模板词与连接词

语料层面的统计给出了最直观的证据。Liang 等在 arXiv/bioRxiv/Nature 系期刊论文中发现与 LLM 使用强关联的词汇异常升频 [S1]；医学与生物学领域的独立研究追踪到 *delve*、*underscore*、*meticulous*、*commendable* 等词在 ChatGPT 发布后的频率飙升 [S3]。另一项教育场景研究用可解释 AI 定位了更细的差异：人类文本倾向实用词（*use*、*allow*），AI 文本倾向抽象正式词（*realm*、*employ*）[D7]。中文场景同样有对应物：“值得注意的是”“综上所述”“不言而喻”“在当今……”这类高频套语。

3.3 语篇信号：过度连贯与模板结构

AI 文本的段落衔接异常顺滑——连接词（*furthermore*、*moreover*、*it is worth noting*）密度高，段落遵循可预测的“主题句—展开—收束”模式 [S7]。人类作者会允许段落之间的跳跃、话题的偏离、论证的迂回；

模型为了“有用”把这些都抹平了。典型的表现还包括“结论回响”：结尾段落几乎逐句复述前文的要点，而不是给出新的落点。

3.4 认识论信号：无立场的自信

这是审稿人最容易感知也最难量化的信号。AI 文本倾向做出确定性、普遍化的断言（“这将彻底改变……”），但缺乏具体的支撑细节；引用是“示意式”的（提到某研究存在，却不给出可核验的出处与边界）；对冲是平衡模板式的，而非来自真实的证据权衡。用写作研究的话说：文本有自信的腔调，却没有作者的立场。

3.5 表达信号：情感与隐喻的扁平

比较语言学证据显示，ChatGPT、Gemini、BingAI 生成的媒体文本比人类文本语法更标准、句法更同质、隐喻更少、情感表达更低 [S6]。所谓“AI 味”里最难言说的那部分——“没有灵魂”——在这个证据面前有了操作化定义：表达层的方差被人为压缩了。

4 如何检测一篇文章是否有 AI 味

检测技术在谱系上可以分成五类。它们的共同点是：都是统计假设检验，因此天然带有两类错误——把 AI 文本放过（漏报），或把人类文本错杀（误报）。

4.1 统计检测：概率与曲率

DetectGPT 利用“采样文本占据模型对数概率的负曲率区域”这一结构性质做零样本检测，把 GPT-NeoX 假新闻的检出 AUROC 从 0.81 提升到 0.95 [D1]。Binoculars 用两个相近模型的交叉困惑度作分数，零样本下对 ChatGPT 等模型的检出率超过 90%，误报率仅 0.01% [D2]。这类方法的弱点在于依赖参考模型：一旦文本由扩散模型生成，其 perplexity 与 burstiness 贴近人类，面向自回归模型的检测器便大面积漏报 [D6]。

4.2 分类器：数据驱动

在人类/AI 标注语料上训练的分类器（RoBERTa 等）在受控基准上表现优异：定制 RoBERTa 模型 F1 达 0.992 [D8]；基于文体特征的轻量模型以 25MB 的体积做到 97% 准确率 [D5]。但分类器受语料分布限制：跨领域、跨语言、跨模型会掉点；对经过改写或深度编辑的文本，分类器的可靠性骤降。

4.3 水印与检索式防御

水印在生成时注入统计信号，理论上可提供统计保证的检测 [D4]。实测表明，人类改写会稀释但未必消除水印——强改写后约观察 800 个 token 仍可在极低误报率下检出 [D3]。但攻击方同样活跃：颜色感知替换可去除任意长度文本的水印 [R6]，黑盒逆向可让水印失效 [R5]。检索式防御（API 记录所有生成、比对语义相似性）在 Krishna 等的实验中能抓回 80%-97% 的改写文本 [R2]，但它要求模型提供商配合，只能覆盖自家 API。

4.4 商业工具与实测分化

对 10 款免费检测器的实测显示，灵敏度从 0% 到 100% 不等；对改写文本，Sapling 与 Undetectable AI 做到了 100% 检出 [E1]。另一项 34 篇文献的系统综述结论更冷静：多数检测器准确率过半但不可靠，付费工具通常优于免费，且存在对非英语母语作者的偏误 [E3]。

4.5 检测的固有边界

必须如实说明：检测从来不是判定，而是统计提示。

- **误报是结构性的。**正式的人类写作（法律文本、经过编辑的学术正文）与 AI 文本共享低困惑度、低突发性签名。一项研究显示，要求模型“写得更像人”的提示反而让检测分数上升，并导致形式化人类写作 76.3% 的误报 [R4]。
- **改写显著削弱检测。**DIPPER 将 DetectGPT 检出率从 70.3% 打到 4.6% [R2]；人类改写是所有攻击中最难检测的 [R3]。
- **“AI 编辑”比“AI 生成”更难查。**最新研究显示，AI 生成文本存在稳定且跨模型一致的文体足迹，而 AI 编辑后的文本没有稳定足迹 [D9]——这与“多数作者只是用 AI 改稿”的现实叠加，意味着检测的难度正在系统性上升。

5 如何去除 AI 味

去除 AI 味的讨论必须区分两个目标：让文本更像自己写的（写作改进），与让文本骗过检测器（规避检测）。前者正当，后者涉及学术诚信，多数期刊明确禁止 [P6] [P7]。本节的技术论述以写作为主，但对规避手段也如实呈现——审稿人需要知道攻击面在哪里。

5.1 两个被证伪的误区

误区一：换词。同义替换只改变表层词汇，不改变困惑度与突发性签名，对现代检测器几乎无效 [E4]。

误区二：让 AI “写得更像人”。实验证据表明，要求模型输出更“人类化”并不使文本更难检测 [R3]；甚至适得其反——动词多样性上升、统计复杂度升高，文本反而更易被检出 [R4]。所谓“统计放大”：改动越多，偏离原分布越多，反而把文本推离人类分布。¹

误区三：堆砌词汇多样性。刻意引入生僻词或风格化措辞，只会增加检测器可见的“统计复杂度”，并不必然接近人类分布（R4 的结论）。

5.2 有效路径：把 AI 草稿变成自己的文字

文献支持的可行路径只有一条主线：人类深度参与。

- **人类重写是最有效的去 AI 化。**在多项评测中，人类改写后的文本是检测器最难识别的 [R3]；AI 编辑文本无稳定文体足迹 [D9]。这印证了一个朴素的判断：人的节奏、人的立场、人的口误，是统计签名无法复制的。
- **针对统计靶点的结构化改写。**理解检测器在看什么之后，可以有针对性地重建节奏：有意拉大句长落差（长句铺陈后接短句收束），替换模板连接词，删除套语，引入具体的数字与实例替代抽象断言。注意，这些动作的正当动机是“让文本读起来更像人写的”，而不是“骗过 GPTZero”。
- **注入个人语料。**把自己的历史文章、审稿意见、笔记作为改写锚点，让 AI 的草稿向个人语料对齐。这在写作上等价于“用 AI 当秘书，不当代笔”。
- **人工核验认识论层。**把自信化断言降级为带边界的判断，为每个“研究表明”补上真实出处，删除无法核验的引文——这既是去 AI 味，也是科研诚信本身。

¹这与直觉相反，但对检测器而言是合理的：人类文本的高突发性来自意图而非刻意的不规则，刻意制造的不规则仍是无规则。

5.3 humanizer 工具：本质与局限

针对 19 款 humanizer 工具的审计显示，这些工具的核心动作是调整 perplexity 与 burstiness，绕过检测器的统计阈值；但多数工具无法保持语义保真，质量分三档 [R1]。更关键的是，检测侧已开始针对性训练——新一代检测器针对改写后的内容做了对抗增强。工具与检测器之间的军备竞赛仍在继续，但信号是：任何“一键去 AI 味”都不解决认识论层的空洞。文本逃过检测，并不等于文本像人写的。

5.4 伦理边界

把“去除 AI 味”用于正当写作（润色、组织、翻译），与用于规避检测（洗稿、伪造作者身份）之间只有一线之隔。期刊政策已划定清晰边界：AI 不得署名；AI 可用于辅助（文献检索、语言润色、格式规范），但核心观点、研究设计、数据分析与主要结论必须人类完成；AI 使用须披露 [P3] [P5]。中文期刊（如《川北医学院学报》《贵州医药》）进一步细化：禁止用 AI 改写拼接他人成果规避检测，违规退稿并列入失信名单 [P7] [P8]。知网对 AI 署名论文采取下架处理 [P10]。

6 作为审稿人：如何识别一篇文章是否有 AI 味

审稿人的处境与检测器不同：不能把误报的代价转嫁给作者。识别流程应当是“证据导向的怀疑”，而非“看气质定罪”。以下是可操作的清单。

6.1 第一步：统计快检

对稿件运行检测器与文体计量指标（perplexity、burstiness、句长变异系数），但只把结果当作提示，不当判决。检测器的高分需要结合下面的定性信号交叉验证；低分不能排除 AI 编辑 [D9]。

6.2 第二步：语篇与结构检查

- 段落是否全部遵循“主题句—展开—收束”的模板，是否缺少人类作者常见的话题偏离与论证迂回；
- 连接词密度是否异常（*furthermore*、*it is worth noting*、“值得注意的是”成片出现）；
- 结尾是否“回响”式复述前文，而非给出新落点。

6.3 第三步：认识论检查（权重最高）

- 断言与证据是否匹配：普遍化断言是否配有具体、可核验的出处；
- 引用是否“示意式”：提到某研究但无作者年份、无边界条件、无法溯源；
- 不确定性是否真实：对冲是来自证据权衡，还是模板化的“平衡措辞”。

6.4 第四步：词汇与表达检查

警惕高频模板词（*delve*、*underscore*、“值得注意的是”“综上所述”）的集中出现 [S1] [S3]；警惕全文零隐喻、零情感、零句法变化。但注意：单个模板词不是证据，词汇漂移随模型迭代而变，不能固化为黑名单。

6.5 第五步：交叉验证与沟通

疑点累积到阈值时，与作者直接沟通（要求提供数据与代码、描述写作过程），而非仅凭文本判定。参考文献中的提示：生物医学文献中 AI 段落高度集中于 Limitations 与讨论尾部 [S4]——优先检查这些区域的文本。若作者承认 AI 用于润色而未披露，按期刊政策处理而非定罪。

审稿人识别 AI 味的根本约束是：误报会伤害真实作者（尤其非英语母语者），漏报会让 AI 文本混入学术记录。前者的成本远高于后者，因此“存疑时偏向证据，而非偏向怀疑”。

7 符合人类写作习惯的建议

把前六章的实证结论转译成写作建议。人类写作的可记忆性来自四个来源，每一个都是 AI 文本的统计弱点：

1. **具体性 (specificity)**。用数字、实例、边界条件替代抽象断言。AI 说“显著提升”，人写“该方案在 5000 样本上把误报率从 8.2% 降到 3.1%，但未覆盖极端行情”。具体性是认识论层的最佳去 AI 味。
2. **节奏 (rhythm)**。有意制造句长落差：一句长句展开，一句短句收束。这是 burstiness 的人工重建，来自修辞意图而非统计操作。
3. **立场 (stance)**。说出你的判断、你的取舍、你不做的部分。AI 的对冲是模板，人的立场是选择。立场让文本从“关于主题”变成“来自作者”。
4. **诚实的边界 (honest hedging)**。区分“已知”“推断”“未知”。真正的人类写作会承认不确定性，并以证据强度控制断言强弱——这正是 scientific humanization 的核心规则：相关性不写证明，无检验不写显著。

落到工作流：用 AI 起草，但把它当第一稿的秘书而非作者——重排论证顺序、替换模板表达、注入个人语料、逐句核验事实与引用。检测器难以识别、且更重要的，读者能读出一个真实的人在说话。

8 结论与开放问题

“AI 味”可被还原为低困惑度、低突发性、模板词汇、过度连贯与无立场认识论这五层信号，其根源是自回归的低熵偏好与 RLHF 的得体奖励造成的风格坍缩。检测技术已能可靠识别“纯 AI 生成”，但对“AI 编辑”与人类深度改写几乎无能为力；商业工具分化严重，误报对正式文本与非母语作者构成系统性伤害。去除 AI 味的唯一可靠路径是人的深度参与——这不是遗憾，而是把写作的主权交还给写作者。

开放问题留待后续研究：其一，中文文本的 AI 味信号与英文存在何种差异，目前几乎没有实证；其二，AI 编辑（而非生成）的可检测性是否稳定（目前仅单篇多域证据 [D9]）；其三，当主流文本本身被 AI 重塑之后，人类的统计签名是否会被重新定义——到那时，“AI 味”或许不再是一个边界，而是一个新的基准。

A 证据表（核心条目）

完整证据表（35 条）见配套文件。以下为核心文献速查。

文献	出版状态	核心发现	链接
DAMAGE: Detecting Adversarially Modified AI Text	arXiv 2025	审计 19 款 humanizer 工具；多数检测器无法识别去 AI 化文本	arXiv
Paraphrasing evades detectors	NeurIPS 2023	DIPPER 将 DetectGPT 检出率 70.3%→4.6%	arXiv
A Practical Examination of AI-Generated Text Detectors	arXiv 2025	7 检测器 ×7 任务；人类改写最难识别	arXiv
The Paradox of “Humanizing” LLM Text	arXiv 2026	改写得更像人反而更易检出；形式化人类写作误报 76.3%	arXiv
DetectGPT	ICML 2023	概率曲率零样本检测，AUROC 0.81→0.95	arXiv
Binoculars	arXiv 2024	交叉困惑度；检出率 >90%，FPR 0.01%	arXiv
On the Reliability of Watermarks	ICLR 2024	水印抗人类改写，800 token 检出	arXiv
NEULIF (stylometric lightweight)	arXiv 2025	25MB 模型 97% 准确率	arXiv
Can You Detect the Difference?	arXiv 2025	扩散模型文本贴近人类统计，检测器漏报	arXiv
AI Writers Have a Footprint, AI Editors Do Not	arXiv 2026	AI 生成有稳定文体足迹；AI 编辑没有	arXiv
Mapping the Increasing Use of LLMs in Scientific Papers	Nat. Hum. Behav. 2025	语料级统计；delve 等词异常升频	arXiv
Sensitivity of Free AI-detector Tools	Indian J. Psychol. Med. 2024	10 款工具灵敏度 0%-100%	PMC
Editors’ Statement on Responsible Use of GenAI	AJOB Neurosci. 2023	跨期刊政策共识：AI 不署名、须披露	PMC
《中国组织工程研究》AI 使用规则	中文期刊 2025	系统梳理国际期刊与 COPE/WAME 立场	PDF
《贵州医药》GenAI 声明	中文期刊 2026	9 类禁止情形；披露模板；失信名单	声明

B 统一比较矩阵（摘要）

完整矩阵见配套文件。检测方法维度：困惑度/曲率类对改写鲁棒性低，误报对正式文本偏高；深度分类器泛化受限；水印有统计保证但可被颜色感知攻击与黑盒逆向绕过；检索式防御最稳但仅覆盖自家 API；商业

工具分化严重。改写维度：换词与提示工程被证伪；DIPPER 式改写逃逸强但可被检索防御识别；humanizer 工具语义保真参差；人类深度改写最难检测且正当。

C 结论置信度（摘要）

高置信度：低困惑度/低突发性是 AI 文本统计签名；改写显著削弱检测；人类改写最难检测；AI 不署名已成跨出版方共识。中置信度：特定词汇升频与 LLM 使用相关但词表漂移；扩散文本贴近人类统计；商业检测器可靠性整体存疑。低置信度/争议：五类信号框架与 Nature 子刊研究仅二手核验；检测器绝对准确率多为受控基准数字；AI 编辑不可检测仅单篇证据。

D 可复现实验建议（摘要）

四项建议：改写逃逸重建（对照 DIPPER 结论）；中文 AI 味信号测量（填补空白）；三分类可检测性实验（纯生成/生成 + 人类改写/AI 编辑草稿）；审稿人识别流程可用性测试。通用要求：固定检测器版本与种子、报告置信区间、区分受控基准与真实分布。

配套文件：证据表与比较矩阵.md（含 35 条来源、两个比较矩阵、置信度分级、核验记录、可复现实验细节）。检索与核验日期 2026-10-06。