

从 Alpha/Beta 到因子中性化与标准化

一套完整的因子量化链路（深度版）

量化投研学习笔记

摘要

本教程以一条可落地的因子生产线为主线：先分清「市场贡献」与「能力贡献」，再把行业与市值等显性/隐性暴露剥除（中性化），最后把信号标准化并交给回测评估。文中给出完整推导、数字算例、可运行代码与统计检验口径，并把“量化工程师为何盯准 Alpha”这一世界观问题一并收束。

目录

1 Alpha 与 Beta 到底是什么	3
1.1 本质问题	3
1.2 从组合理论到 CAPM（为什么是这个公式）	3
1.3 用回归估计 Beta（实证口径）	3
1.4 Alpha：剥掉市场后的骨架	4
1.5 Alpha 的统计现实：噪声、标准误、显著性	4
1.6 矩阵形式与多因子推广	4
1.7 这个分解为什么有意义：可复制性	5
2 为什么要中性化	5
2.1 暴露：显性与隐性	5
2.2 不做中性化：遗漏变量偏差（fake Alpha）	5
2.3 中性化的目标（一句话）	6
3 行业 + 市值中性化的具体操作	6
3.1 数学模型（矩阵形式，核心）	6
3.2 为什么保证正交（线性代数证明）	6
3.3 逐日重估 / 滚动 / 半衰期	7

目录	2
3.4 四个必须注意的坑	7
3.5 为什么极端值影响中性化本身	7
3.6 算例（感受数字）	7
3.7 代码实现	8
4 残差 z-score 标准化的具体步骤	9
4.1 这一步解决什么	9
4.2 严格步骤	9
4.3 z 与评估指标的关联	9
4.4 两个必须注意的坑	9
5 完整信号流水线与 Alpha 评估	10
5.1 完整 pipeline	10
5.2 如何评估 Alpha（别只看多空曲线）	11
5.3 多头 vs 多空的取舍	11
5.4 前视偏差（工程红线）	12
6 为什么量化工程师盯着 Alpha	12
6.1 四个理由（第一性原理）	12
6.2 假 Alpha（fake alpha）从哪来	12
6.3 诚实的边界（反方视角）	12
附录	13
延伸阅读	14
一句话收束	14

1 Alpha 与 Beta 到底是什么

1.1 本质问题

Alpha 与 Beta 不是两个“指标”，而是一套收益归因的分解装置。它们回答的唯一本质问题是：

一只证券赚的钱里，多少是“跟着市场波动”赚的，多少是“市场都没给你、你靠别的本事赚的”？

这个问题的价值不在于记账，而在于判定一件事：这份收益是否可以被低成本复制、是否可持续、是否真是你的能力。

1.2 从组合理论到 CAPM（为什么是这个公式）

CAPM 的 Beta 来自一条严格论证链：

1. **Markowitz 均值-方差框架**：假设投资者只用期望收益与方差决策，所有“给定期望、方差最小”的组合连成有效前沿。
2. **资本市场线 CML**：引入无风险利率后，最优配置是无风险资产 + 市场组合 M 的线性组合。
3. **均衡 (SML)**：在均衡中，任一资产 i 要想住进有效前沿且无套利，其期望超额收益必须正比于它与市场组合的协方差——这就是 Beta 的来源。

定义 (CAPM 均衡定价 / SML)：

$$E[R_i] - R_f = \beta_i (E[R_m] - R_f), \quad \beta_i = \frac{\text{Cov}(R_i, R_m)}{\text{Var}(R_m)}. \quad (1)$$

- **CAPM**：均衡定价模型，说“期望超额收益由市场 Beta 唯一决定”。
- **市场模型 (market model)**：实证回归，仅把一个资产的收益拆成“市场相关部分 + 残差”，并不声称定价。因子分析用的是后者。

1.3 用回归估计 Beta（实证口径）

对已实现收益，用无截距的回归斜率估计：

$$\hat{\beta} = \frac{\sum_t (R_{i,t} - \bar{R}_i)(R_{m,t} - \bar{R}_m)}{\sum_t (R_{m,t} - \bar{R}_m)^2}. \quad (2)$$

1.4 Alpha: 剥掉市场后的骨架

市场模型写成

$$R_{i,t} - R_f = \alpha_i + \beta_i (R_{m,t} - R_f) + \varepsilon_{i,t}, \quad (3)$$

其 OLS 截距就是 Alpha:

$$\hat{\alpha}_i = \overline{R_i - R_f} - \hat{\beta}_i \overline{(R_m - R_f)}. \quad (4)$$

一个关键陷阱: 单期数据分不出 α 与 ε 。某一期里, 你只能看到“又能力又运气”的混合残差 $\alpha + \varepsilon_t$; 只有横跨多期、用截距估计, 才能把可复现的 Alpha 从随机运气里分离出来——这正是“Alpha 需要大量样本才可信”的数学根源。

数字例: 设 $R_f = 3\%$, 某股真实 $\beta = 1.2$, 某月市场实际 $R_m = 10\%$, 该股实际 $R_i = 25\%$, 则

$$(25\% - 3\%) = 1.2 \times (10\% - 3\%) + 13.6\%. \quad (5)$$

即超额 $22\% = 8.4\%$ (市场贡献) + 13.6% (混合残差 $\alpha + \varepsilon$)。13.6% 里多少是 α 、多少是 ε , 本月无法判断。

1.5 Alpha 的统计现实: 噪声、标准误、显著性

设月度残差标准差 σ_ε 、样本 T 个月, 则

$$\text{sd}(\hat{\alpha}) \approx \frac{\sigma_\varepsilon}{\sqrt{T}}, \quad t_{\hat{\alpha}} \approx \frac{\hat{\alpha}}{\sigma_\varepsilon/\sqrt{T}}. \quad (6)$$

粗略估算: 月度波动 $\sigma_\varepsilon = 5\%$ 、真实月 $\alpha = 0.5\%$ (年化约 6%), 一年 ($T = 12$) 的 $t \approx 0.35$, 远不显著; 要 $t \approx 2$ 需要约 100 个月——近 8 年数据。结论:

想在统计上验证一个真实的 Alpha, 通常需要多年数据; 任何短期漂亮的 Alpha 都要打上大问号。

1.6 矩阵形式与多因子推广

写成向量形式即可推广到多因子:

$$R = X\beta + \varepsilon, \quad \hat{\beta} = (X^\top X)^{-1} X^\top R, \quad \hat{\varepsilon} = R - X\hat{\beta} = (I - P)R, \quad (7)$$

其中 $P = X(X^\top X)^{-1} X^\top$ 是投影矩阵。单因子时 $X = [1, R_m]$; 多因子时把市场、行业、市值、风格都放进 X , 残差 $(I - P)R$ 就是被所有已定价因子解释完后剩下的东西——这才是“纯 Alpha”。

1.7 这个分解为什么有意义：可复制性

	Beta（市场敞口）	Alpha（超额能力）
本质	系统性风险暴露	偏离市场均值的能力
获取成本	接近 0（买指数/加杠杆即可复制）	极高（定价错误、信息、执行）
能否规模复制	可，容量近似无限	不可，越大越衰减
统计含义	回归斜率（参数）	截距 / 残差均值

Beta 是“租金”——承担市场风险就有的期望回报；Alpha 是“工资”——需要真本事。主动管理就是把 Beta 结构做干净，然后诚实回答：剩下的 Alpha 是真能力，还是样本运气。

2 为什么要中性化

2.1 暴露：显性与隐性

$\beta(R_m - R_f)$ 是**显性暴露**（对市场）。信号还会携带三类**隐性暴露**：

暴露	机制	后果
行业暴露	因子高低可能只是行业整体高/低	在赌行业而非选优
市值暴露	因子与大小盘相关	在做小盘/大盘而非信号强
风格/波动	动量可能隐含高波动高换手	混进另一类可出售的风险溢价

中性化 = 把因子里能“被人为构造出来”的那部分系统性暴露拿掉，只留下来自信息与判断的部分。

2.2 不做中性化：遗漏变量偏差（fake Alpha）

两变量回归演示：真实模型 $y = \beta_1 x_1 + \beta_2 x_2 + u$ ，若只回归 $y = \tilde{b}_1 x_1 + e$ ，则缺失 x_2 造成的偏差为

$$E[\tilde{b}_1] = \beta_1 + \beta_2 \frac{\text{Cov}(x_1, x_2)}{\text{Var}(x_1)}.$$

(8)

只要因子 x_1 与漏掉的暴露 x_2 （行业/市值）相关，估计的系数/残差就会被拖偏，伪装成漂亮的 Alpha，实则是行业或市值的功劳。

2.3 中性化的目标（一句话）

让处理后的因子与“行业哑变量、ln 市值”正交（相关为零，即零显性暴露），从而按该因子排序建仓得到的组合不再隐含行业与市值暴露。

- 中性化处理的是因子值，不是收益率，也不是组合权重（组合层面另有独立的中性化）。
- 本文聚焦横截面因子值中性化。

3 行业 + 市值中性化的具体操作

3.1 数学模型（矩阵形式，核心）

对某一时点横截面（股票 $i = 1, \dots, N$ ），构造设计矩阵 X ，列为：行业哑变量 + ln 市值列 + 全 1 截距列。回归取残差：

$$f = X\gamma + \varepsilon \Rightarrow \hat{\gamma} = (X^\top X)^{-1} X^\top f, \quad \bar{f} = f - X\hat{\gamma} = (I - P)f. \quad (9)$$

3.2 为什么保证正交（线性代数证明）

$(I - P)$ 是正交投影矩阵，对 X 任意一列 v 有 $(I - P)v = 0$ ，故

$$((I - P)f)^\top v = f^\top (I - P)v = 0. \quad (10)$$

即残差与每一列 v 的内积为 0（正交的严格定义）。由此得三条可操作结论：

1. 均值归零：残差与截距列 1 正交 $\Rightarrow$ 残差和 = 0。
2. 行业正交：残差与每个行业哑变量正交 $\Rightarrow$ 每个行业的残差均值 = 0（行业均值对齐）。
3. 市值正交：残差与 ln 市值列正交 $\Rightarrow$ 残差与市值不相关。

3.3 逐日重估 / 滚动 / 半衰期

- **必须逐期重估 γ** : 行业均值、市值溢价随时间漂移。
- **重估频率**: 日频逐日估; 月频可月末估一次、用于下月。
- **半衰期**: 激进用指数加权 (近期权重高) 提高灵敏度但放大噪声; 默认全样本即可, 勿过度复杂化。

3.4 四个必须注意的坑

1. **哑变量陷阱**: 用“全 0 代表基准行业”的编码 (每行业一列, 让截距吸收基准), 而不是每行业独立一列又放截距, 否则 $X^T X$ 不可逆。工程上用 `np.linalg.lstsq` 的最小范数解可规避。
2. **取残差, 不取系数**: 中性化要的是残差 $(I - P)f$; $\hat{\gamma}$ 是“暴露大小”, 是另一回事。
3. **截距别省**: 去掉截距, 残差均值不再为 0, 行业“齐平”性质被破坏。
4. **Winsorize 的顺序**: 极端值会污染 OLS, 建议回归前先粗截尾, 或回归后稳健标准化。

3.5 为什么极端值影响中性化本身

OLS 对离群点敏感: 一个残差巨大的股票会拉动拟合线, 带偏整个横截面的行业均值 / 市值斜率。故在**中性化之前**对原始因子做 winsorize (防止少数股绑架), 中性化后标准化时再截一次或用稳健 z。常见做法“先 win $\rightarrow$ 再中性化 $\rightarrow$ 再 win $\rightarrow$ 再 z-score”, 但别双重过度截尾。

3.6 算例 (感受数字)

5 只股票: A/B/C 属“消费”, D/E 属“制造”:

股票	行业	ln 市值	原始动量 f
A	消费	10.2	+2.0
B	消费	11.0	+4.0
C	消费	12.1	+6.0
D	制造	10.5	+3.0
E	制造	11.8	+5.0

直觉：消费均值 $(2 + 4 + 6)/3 = 4$ 、制造均值 $(3 + 5)/2 = 4$ ，行业均值相等；但 f 随 ln 市值上升故有**市值暴露**。回归去掉“随市值预期的那份”后，残差即中性化动量——你可在练习里验证残差与 ln 市值、行业的协方差都约 0。

3.7 代码实现

```
import numpy as np
import pandas as pd

def neutralize(raw, industry, ln_cap):
    """行业 + 市值中性化：横截面 OLS 取残差（均为同一横截面、按 index 对齐）"""
    X = pd.get_dummies(industry, drop_first=False) # 行业哑变量
    X["ln_cap"] = ln_cap.astype(float) # 市值方向
    X["intercept"] = 1.0 # 截距：保证残差均值为 0
    beta, *_ = np.linalg.lstsq(X.to_numpy(float),
                               raw.to_numpy(float), rcond=None) # 最小范数解
    fitted = X.to_numpy(float) @ beta
    return pd.Series(raw.to_numpy(float) - fitted, index=raw.index)
```

4 残差 z-score 标准化的具体步骤

4.1 这一步解决什么

中性化后的残差已是“零均值、去行业、去市值”，但跨日期、跨因子仍不可比：动量残差是收益率量纲、低波残差是波动量纲；今天横截面与上月的尺度也不同。z-score 一次解决三件事：量纲统一、日期可比、分布对齐。

4.2 严格步骤

Step 1——只用“当前一个横截面”求均值与标准差

$$\mu = \frac{1}{N} \sum_{i=1}^N \bar{f}_i, \quad \sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (\bar{f}_i - \mu)^2}. \quad (11)$$

μ, σ 只在当天全部股票上算，绝不跨历史混合。

Step 2——逐个代入

$$z_i = \frac{\bar{f}_i - \mu}{\sigma}. \quad (12)$$

完成后当天横截面满足：均值 $(z)=0$ 、标准差 $(z)=1$ 。

Step 3——用 z 排序 / 赋权：排序取 z_i 前 N ；赋权 $w_i = z_i / \sum_j |z_j|$ ，或 rank 权重 $\text{rank}(z)/N - \frac{1}{2}$ 。

4.3 z 与评估指标的关联

- **IC**: $\text{IC} = \text{corr}(z, \text{未来收益})$ ，常用 Spearman（对 z 与未来收益取 rank 后求相关）。
- **IR**: 多空组合 $\text{IR} = \alpha / \sigma(\varepsilon)$ ，约与 IC 正相关； z 分布是否被极端值扭曲直接决定 IR 可靠性。
- 与分位映射：某些合成用“ z 排名 $/(N+1)$ ”，前提是 z 已无量纲。

4.4 两个必须注意的坑

坑 1——残差非正态，直接 z-score 会被极端值绑架。市场残差带长尾，极端值把 μ 拉离众数、把 σ 撑大，少数股垄断排序。惯例是 winsorize 后再标准化：

```
def zscore_winsorized(resid, lo=0.01, hi=0.99):
    lo_q, hi_q = np.quantile(resid, [lo, hi])
    resid_c = np.clip(resid, lo_q, hi_q)
    return pd.Series((resid_c - resid_c.mean()) / resid_c.std(ddof=1),
                     index=resid.index)
```

更稳健口径（可选）：中位数替代 μ 、MAD 替代 σ ：

```
def zscore_robust(resid):
    med = resid.median()
    mad = (resid - med).abs().median()
    if mad == 0:
        mad = resid.std(ddof=1)
    return (resid - med) / (mad * 1.4826) # 1.4826 使 MAD 在正态下约等于 sigma
```

坑 2——z 保留多少“量级”取决于怎么用。只排序则 z 与 rank 基本等价；做加权/多因子合成则 z 保留相对强度、更细，但正因保留尾部，才更需要先截尾。

z-score 本身不产生 Alpha，但它保证你排序、合成、跨期比较时用的是干净、可比的信号。

5 完整信号流水线与 Alpha 评估

5.1 完整 pipeline

```
import numpy as np
import pandas as pd

def neutralize(raw, industry, ln_cap):
    X = pd.get_dummies(industry, drop_first=False)
    X["ln_cap"] = ln_cap.astype(float)
    X["intercept"] = 1.0
    beta, *_ = np.linalg.lstsq(X.to_numpy(float), raw.to_numpy(float),
                               rcond=None)
    fitted = X.to_numpy(float) @ beta
    return pd.Series(raw.to_numpy(float) - fitted, index=raw.index)
```

```
def standardize(resid, win=(0.01, 0.99)):
    lo_q, hi_q = np.quantile(resid, win)
    resid_c = np.clip(resid, lo_q, hi_q)
    return pd.Series((resid_c - resid_c.mean()) / resid_c.std(ddof=1),
                     index=resid.index)

def factor_pipeline(raw, industry, ln_cap):
    """原始因子 -> 中性化 -> 截尾 + z-score"""
    resid = neutralize(raw, industry, ln_cap)
    return standardize(resid)
```

月度口径：每个月底对当期横截面调用 factor_pipeline 得 monthly_z，据此排序建仓，例如

```
monthly_z = factor_pipeline(df["mom"], df["ind"], np.log(df["mcap"]))
```

5.2 如何评估 Alpha（别只看多空曲线）

1. **IC / Rank IC**：每期算 $\text{corr}(z_t, r_{t+1})$ 。2. **分层回测**：按 z 分十分位，看最高/最低分位差是否单调显著。3. **Fama-MacBeth 因子收益回归**：把组合收益对一系列暴露回归，剔除市场/行业/市值后再看残差 α 。4. **信息比率与 t 值**：

$$\text{IR} = \frac{\alpha_p}{\sigma(\varepsilon_p)}, \quad t_\alpha = \frac{\alpha_p}{\sigma(\varepsilon_p)/\sqrt{T}}, \quad (13)$$

其中下标 p 表示“组合”。任何 Alpha 产出都要附 IR 与 t ，并用样本外检验。

5.3 多头 vs 多空的取舍

- **纯多头**：区分“因子 Alpha”与“市场 Beta + 因子 Alpha”更难，需回归把 β 剔出。
- **多空（对冲）**：对市场、行业、市值中性化后，多空收益约等于纯因子 Alpha，最能看见信号本身。
- **多空受成本与融券限制**（A 股做空难）；务实中间派是“多头为主 + 回归评估”。

5.4 前视偏差（工程红线）

回溯最隐蔽的错误：用了“当时尚未知道”的信息。

- 中性化 γ 若用“当月末”行业/市值估、再对当月收益归因，属前视。
- 严谨做法：用 $t-1$ 期已知暴露估计、对 t 期应用（ γ 滞后一期）。
- 标准：任何因子值、暴露、成交量在决策时刻必须“可用”。

6 为什么量化工程师盯着 Alpha

6.1 四个理由（第一性原理）

1. 可归因：绝对收益把“能力、市场、运气”打包成一个数字；Alpha 把它们分开。
2. 可检验：Alpha 有标准误，可做 t / IR 检验。
3. 可复用：Beta 是市场的、可被指数替代；只有 Alpha 是不可替代的可持续能力。
4. 可定价：Alpha 是“工程师自己的产品”——他们卖的不是“市场涨我就赚”，而是剥离所有可定价因子后剩下的部分。

6.2 假 Alpha（fake alpha）从哪来

- 未中性化的暴露：单因子回归估的 Alpha 混进行业/市值/风格暴露（遗漏变量偏差）。
- 调参过拟合：在历史上反复选因子/参数直到曲线好看。
- 幸存者/前视偏差：用当前成分股回溯、或偷用未来信息造出“皇帝的新 Alpha”。

“干净的 Alpha”需满足：多因子中性化 + 样本外稳健 + 无前视 + 有显著性（IR、 t ）。

6.3 诚实的边界（反方视角）

- Alpha 是“评价”透镜，不是“发钱”透镜：投资人最终拿到的仍是绝对收益； $\alpha = +20\%$ 在 -40% 市场里体验仍是 -20% 。

- **真实 Alpha 极稀缺：**多数策略 Alpha 扣成本后趋于 0，进场越拥挤，衰减越快。
- **回测 Alpha $\neq$ 实盘 Alpha：**赢了归因、输了甩市场是常见修辞病；钉 Alpha 正是为对抗这种自欺。

附录：符号表 / 练习自测 / 参考阅读

A. 符号表

符号	含义
R_i, R_m, R_f	资产收益、市场收益、无风险利率
α	超额能力 / 截距（剥掉市场后的平均超额）
β	系统性风险暴露 / 斜率
ε	随机扰动 / 残差
X	设计矩阵（行业哑变量 + ln 市值 + 截距）
$P = X(X^\top X)^{-1}X^\top$	正交投影矩阵
$f_i \rightarrow \bar{f}_i$	原始因子 $\rightarrow$ 中性化（残差）因子
$\ln M_i$	对数市值
z_i	标准化后的因子分数
IC/IR/ t	信息系数 / 信息比率 / t 值

B. 练习与自测

1. **概念：**用一句话区分 β 与 α 的本质（参考：可复制/可持续）。
2. **推导：**写出 $\beta = \text{Cov} / \text{Var}$ 的估计式；说明市场模型与 CAPM 的区别。
3. **推演：**为什么用 $\ln M$ 而非 M ？为什么截距列能保证残差均值为 0？
4. **正交性实验：**造一组数据跑 `factor_pipeline`，检验残差与 $\ln$ 市值、行业哑变量的协方差是否约 0， z 均值 0、方差 1。

5. 缺项偏差验证：分别用“只去市值”“只去行业”“二者都去”三种方式中性化，比较残差与漏掉暴露的相关性。
6. 显著性检验：用月度回测算 IR 与 t ，判断多大样本才能“显著”。
7. 前视自查：检查回测里建仓时刻用到的行业/市值/因子是否均为当时已知信息。

C. 参考阅读（按难度递增）

1. Markowitz, H. M. (1952). *Portfolio Selection*.
2. Sharpe, W. F. (1964). *Capital Asset Prices: A Theory of Market Equilibrium*.
3. Fama, E. F. & MacBeth, J. D. (1973). *Risk, Return, and Equilibrium*.
4. Grinold, R. & Kahn, R. (2000). *Active Portfolio Management*.

延伸阅读

趋势溢价、趋势跟踪与仓位的专题及其可运行脚本（单品种 / 多品种等权），已独立成篇：《趋势跟踪与仓位管理：从趋势溢价到可运行的仓位纪律》([trend_position_management.tex / trend_position_management.pdf](#))。本教程只聚焦 Alpha/Beta 认识论与因子中性化、标准化这条生产线。

一句话收束

Beta 衡量你承担多少市场风险（可被替代），**Alpha** 衡量你在市场已定价之后还剩多少本事（不可替代）；“行业 + 市值中性化 → 残差 → z-score → 显著性检验”这条流水线，就是把你托付给市场的 Beta、交给运气的 ε 逐层剥离干净，最后留下那一小撮真正属于你、且经得起统计考验的 Alpha。